Автономная некоммерческая
образовательная организация высшего образования
«НАУЧНО-ТЕХНОЛОГИЧЕСКИЙ УНИВЕРСИТЕТ «СИРИУС»

Научный центр генетики и наук о жизни

направление «Вычислительная биология»

К ЗАЩИТЕ ДОПУСТИТЬ
Руководитель направления
«Вычислительная биология»
д-р биол. наук
_____ Ф.А. Колпаков
«___» _____ 2026 г.

«ПРЕДСКАЗАНИЕ АЭРОБНО-АНАЭРОБНОГО ПЕРЕХОДА ПО ЭЛЕКТРОМИОГРАММЕ И ДАННЫМ ИК-СПЕКТРОМЕТРИИ НА РАБОТАЮЩЕЙ МЫШЦЕ»

Магистерская диссертация по направлениям подготовки
06.04.01 «Биология», 09.04.03 «Прикладная информатика»
направленность (профиль) «Биоинформатика»

Студент гр. _____
_____ И.О. Фамилия
«____» _____ 2026 г.

Согласовано (при наличии консультанта)
Консультант

_____
(должность, ученая степень, звание)

_____ И.О. Фамилия
«____» _____ 2026 г.

Руководитель

_____
(должность, ученая степень, звание)

_____ И.О. Фамилия
«____» _____ 2026 г.

Федеральная территория «Сириус» - 2026

Автономная некоммерческая
образовательная организация высшего образования
«НАУЧНО-ТЕХНОЛОГИЧЕСКИЙ УНИВЕРСИТЕТ «СИРИУС»

Научный центр генетики и наук о жизни

направление «Вычислительная биология»

УТВЕРДИТЬ
Руководитель направления
«Вычислительная биология»
д-р биол. наук
_____ Ф.А. Колпаков

«___» _____ 20___ г.

ТЕХНИЧЕСКОЕ ЗАДАНИЕ
на выполнение магистерской диссертации по направлениям подготовки
06.04.01 «Биология», 09.04.03 «Прикладная информатика»
направленность (профиль) «Биоинформатика»

Тамразов Александр Сергеевич

1. Тема: «Предсказание аэробно-анаэробного перехода по электромиограмме и данным ИК-спектрометрии на работающей мышце»
2. Цель: Разработка и валидация метода неинвазивного онлайн-предсказания аэробно-анаэробного перехода по данным поверхностной электромиографии и ближней инфракрасной спектроскопии работающей мышцы в условиях ступенчатого нагрузочного велоэргометрического теста.
3. Задачи:

– Разработать протокол синхронной записи данных с носимых датчиков (Delsys Trigno: ЭМГ и ИМУ мышцы vastus lateralis (дистальная и проксимальная зоны); Train.Red: мышечная оксигенация SmO_2 на vastus lateralis; Zephyr BioHarness: RR-интервалы).

– Разработать алгоритм предобработки и синхронизации разночастотных физиологических сигналов, включая: сегментацию ЭМГ по

фазам педалирования на основе данных гироскопа, фильтрацию и нормализацию ЭМГ, сглаживание SmO_2, интерполяцию RR-интервалов и расчёт DFA-α1 в скользящем окне.

– Провести экспериментальный сбор данных согласно разработанному протоколу: выполнить ступенчатые велоэргометрические тесты с синхронной записью сигналов всех датчиков, верифицировать индивидуальные пороги LT1 и LT2 по концентрации лактата в капиллярной крови.

– Сформировать датасет для онлайн-предсказания близости к лактатным порогам, включающий классические ЭМГ-характеристики, показатели мышечной оксигенации и вариабельности сердечного ритма, с учётом фазовой структуры цикла педалирования.

– Разработать ML-модель, предсказывающую в скользящем временном окне оставшееся время до наступления лактатных порогов LT1 и LT2 в режиме реального времени; систематически сопоставить базовый подход на классических моделях с ручными признаками (регуляризованная линейная регрессия, метод опорных векторов, градиентный бустинг) и расширенный подход на нейросетевых архитектурах для временных рядов (рекуррентные, темпоральные свёрточные и вейвлет-обогащённые).

– Оценить точность предсказания LT1 и LT2 по носимым данным в сравнении с лактатным порогом, определённым по капиллярной крови, с использованием стратегии Leave-One-Subject-Out (LOSO); провести анализ значимости признаков методом SHAP и сопоставить результаты с данными литературы.

4. Рабочий график (план) выполнения магистерской диссертации:

№	Перечень заданий	Сроки выполнения
1.	Написание литературного обзора	
2.	Изложение материалов и методов	

3.	Представление полученных результатов	

Сроки выполнения магистерской диссертации - любые даты после даты выдачи задания.

Дата выдачи: «___» _____ 20___ г. (Любая после 03.12.2025)

Руководитель:

_____ Д. А. Онищенко (по приказу на день выдачи ТЗ)

Задание принял к исполнению:

Студент группы М69БИ-24

_____ А.С. Тамразов

«___» _____ 20___ г. (Любая после даты выдачи задания)

На второй странице должен продолжаться текст задания, либо все ТЗ с подписями должно умещаться на 1 странице. **Недопустимо** ставить подписи на листе без текста.

Реферат

Позже!

Реферат магистерской диссертации представляет собой краткое изложение содержания работы. Реферат включает в себя:

1. **Общие сведения**:

– объем диссертации (количество страниц);

– количество иллюстраций и таблиц;

– количество использованных источников.

2. **Основное содержание работы**:

Цель и задачи исследования;

– методы исследования;

– результаты и их новизна;

– практическая значимость;

– область применения результатов.

3. **Ключевые слова**:

Перечень терминов, отражающих основное содержание работы (обычно 5–15 слов).

Объем реферата, должен составлять не более 850 символов (без пробелов), но не более 1 страницы А4.

Образец оформления см.: Стандарт, приложение Г.

The Abstract

Тоже самое, что и в реферате, но переведённое на английский язык.

Сокращения, обозначения, термины и определения

В настоящей работе применяют следующие термины и соответствующие определения:

Аэробно-анаэробный переход – диапазон интенсивности физической нагрузки, при котором анаэробный гликолиз начинает вносить существенный вклад в энергообеспечение работающих мышц, сопровождающийся нелинейным ростом концентрации лактата в крови, десатурацией мышечного гемоглобина и изменением паттерна рекрутирования двигательных единиц.

Вейвлетное преобразование – математический инструмент для анализа нестационарных сигналов, позволяющий одновременно получить информацию о частотном составе сигнала и его временной локализации; существует в дискретной (DWT) и непрерывной (CWT) формах.

Вейвлет-энтропия – мера сложности сигнала, вычисляемая как нормированная энтропия Шеннона по распределению энергии вейвлет-коэффициентов по уровням декомпозиции.

Двигательная единица (ДЕ) – мотонейрон и иннервируемые им мышечные волокна; минимальная функциональная единица нервно-мышечной системы.

DFA-α1 (краткосрочный показатель детрендированного флуктуационного анализа) – безразмерный показатель, характеризующий фрактальные свойства временного ряда RR-интервалов в коротких временных масштабах (4–16 кардиоциклов); значение α1 = 0,75 эмпирически соответствует первому аэробному порогу (VT1/LT1).

Лактатный порог (LT) – интенсивность нагрузки, при которой концентрация лактата в крови начинает нелинейно возрастать относительно базального уровня покоя; различают первый (LT1, ~2–2,5 ммоль/л) и второй (LT2, ~4 ммоль/л) лактатные пороги.

Leave-One-Subject-Out (LOSO) – метод перекрёстной валидации, при котором на каждой итерации модель обучается на данных всех испытуемых, кроме одного, и тестируется а оставленном; обеспечивает оценку обобщаемости модели на новых субъектах без утечки данных.

Машинное обучение (ML) – раздел искусственного интеллекта, изучающий методы построения алгоритмов, способных обучаться на данных и делать предсказания без явного программирования правил.

Мышечная оксигенация (SmO_2) – доля оксигенированного гемоглобина в суммарном гемоглобине работающей мышцы, измеряемая методом ближней инфракрасной спектроскопии (NIRS); отражает баланс между доставкой и потреблением кислорода на уровне микроциркуляции.

NIRS (ближняя инфракрасная спектроскопия) – оптический метод неинвазивного мониторинга оксигенации тканей, основанный на различии спектров поглощения оксигемоглобина (O_2Hb) и дезоксигемоглобина (HHb) в диапазоне длин волн 700–900 нм.

Рекрутирование двигательных единиц – последовательное вовлечение дополнительных двигательных единиц в работу по мере нарастания требуемой мышечной силы; при переходе к высокоинтенсивной нагрузке рекрутируются быстрые гликолитические волокна (тип II).

RMS (среднеквадратичная амплитуда) – показатель суммарной электрической активности мышцы, вычисляемый как корень из среднего квадрата амплитуды ЭМГ-сигнала в заданном временном окне; служит основным маркером нарастания мышечного усилия и усталости.

SHAP (SHapley Additive exPlanations) – метод интерпретации предсказаний моделей машинного обучения, основанный на теории кооперативных игр Шепли; позволяет количественно оценить вклад каждого признака в отдельное предсказание модели.

Скользящее окно – метод обработки непрерывного временного ряда путём последовательного извлечения фрагментов фиксированной длины с заданным шагом сдвига; обеспечивает вычисление признаков в режиме реального времени.

Темпоральная свёрточная сеть (TCN) – архитектура нейронной сети для обработки временных рядов, основанная на каузальных свёртках с расширяющимися дилатациями; позволяет учитывать долгосрочные зависимости в сигнале при параллельном вычислении всех временных шагов.

Электромиография (ЭМГ) – метод регистрации суммарной электрической активности скелетных мышц; поверхностная ЭМГ (sEMG) регистрирует сигнал посредством электродов, размещённых на коже над исследуемой мышцей.

В настоящей работе применяют следующие сокращения и обозначения:

АДФ – аденозиндифосфат

ДЕ – двигательная единица

ИК – инфракрасный (-ая, -ое)

ИМУ – инерциальный измерительный модуль

ТЗ – техническое задание

ЧСС – частота сердечных сокращений

ЭМГ – электромиография; электромиограмма

ANT+ – Adaptive Network Topology – беспроводной протокол передачи данных

ATA – naerobic Threshold – анаэробный порог

ATT – Adipose Tissue Thickness – толщина подкожной жировой клетчатки

BLE – Bluetooth Low Energy – протокол беспроводной связи малой мощности

CI – Confidence Interval – доверительный интервал

CNN – Convolutional Neural Network – свёрточная нейронная сеть

CPET – Cardiopulmonary Exercise Testing – кардиопульмональное нагрузочное тестирование

CWT – Continuous Wavelet Transform – непрерывное вейвлетное преобразование

DFA-α1 – Detrended Fluctuation Analysis alpha-1 – краткосрочный показатель детрендированного флуктуационного анализа

DWT – Discrete Wavelet Transform – дискретное вейвлетное преобразование

FFT – Fast Fourier Transform – быстрое преобразование Фурье

GET – Gas Exchange Threshold – газообменный порог

GRU – Gated Recurrent Unit – управляемый рекуррентный блок

HDF5 – Hierarchical Data Format version 5 – иерархический формат хранения данных

HHb – Deoxyhaemoglobin – дезоксигемоглобин

HRVT1 – Heart Rate Variability Threshold 1 – первый порог вариабельности сердечного ритма

HRVT2 – Heart Rate Variability Threshold 2 – второй порог вариабельности сердечного ритма

HRV – Heart Rate Variability – вариабельность сердечного ритма

ICC – Intraclass Correlation Coefficient – коэффициент внутриклассовой корреляции

IEMG – Integrated Electromyography – интегрированная электромиограмма

LOSO – Leave-One-Subject-Out – перекрёстная валидация с исключением одного испытуемого

LSTM – Long Short-Term Memory – нейронная сеть с долгой краткосрочной памятью

LT – Lactate Threshold – лактатный порог

LT1 – Lactate Threshold 1 – первый лактатный порог

LT2 – Lactate Threshold 2 – второй лактатный порог

LT4 – Lactate Threshold at 4 mmol/L – лактатный порог при концентрации 4 ммоль/л

MAE – Mean Absolute Error – средняя абсолютная ошибка

MCT1 – Monocarboxylate Transporter 1 – монокарбоксилатный транспортёр 1MDFMedian Frequency – медианная частота

ML – Machine Learning – машинное обучение

MLSS – Maximal Lactate Steady State – максимальное лактатное стационарное состояние

MN – FMean Frequency – средняя частота

NIRS – Near-Infrared Spectroscopy – ближняя инфракрасная спектроскопия

OBLA – Onset of Blood Lactate Accumulation – начало накопления лактата в крови

O_2Hb – Oxyhaemoglobin – оксигемоглобин

R^2 – Coefficient of Determination – коэффициент детерминации

RF – Rectus femoris – прямая мышца бедра

RMS – Root Mean Square – среднеквадратичная амплитуда

RNN – Recurrent Neural Network – рекуррентная нейронная сеть

RMSE – Root Mean Square Error – среднеквадратичная ошибка

RMSSD – Root Mean Square of Successive Differences – квадратный корень из среднеквадратичной разности последовательных RR-интервалов

RRRR-интервал – интервал между последовательными зубцами R на ЭКГ

SHAP – SHapley Additive exPlanations – метод интерпретации моделей машинного обучения на основе значений Шепли

SMD – Standardised Mean Difference – стандартизованная разность средних

SmO_2 – Skeletal Muscle Oxygen Saturation – насыщение мышечного гемоглобина кислородом

STFT – Short-Time Fourier Transform – оконное преобразование Фурье

TCN – Temporal Convolutional Network – темпоральная свёрточная сеть

TCU – Trigno Control Utility – программное обеспечение управления датчиками Delsys Trigno

THb – Total Haemoglobin – суммарный гемоглобин

VL – Vastus lateralis – латеральная широкая мышца бедра

VO_2 – Oxygen Uptake – потребление кислорода

VO_2max – Maximum Oxygen Uptake – максимальное потребление кислорода

VT1 – Ventilatory Threshold 1 – первый вентиляционный порог

VT2 – Ventilatory Threshold 2 – второй вентиляционный порог

WI – Wavelet Index – вейвлетный индекс

ОГЛАВЛЕНИЕ

Введение 18

1 Обзор литературы 22

1.1 Аэробно-анаэробный переход: физиологические механизмы 22

1.2 Электромиография как неинвазивный маркер порога при велоэргометрии 25

1.2.1 Классические признаки: RMS, MDF и ЭМГ-порог 25

1.2.2 Вейвлетный анализ ЭМГ 29

1.3 Ближняя инфракрасная спектроскопия и локальная мышечная оксигенация 33

1.4 Вариабельность сердечного ритма и DFA-α1 как онлайн-маркер первого порога 36

1.5 Кинетика лактата: задержка системного сигнала относительно локального 39

1.6 Машинное обучение и алгоритмы онлайн-детекции аэробно-анаэробного перехода 43

1.6.1 Классический ML на ручных признаках 43

1.6.2 ML для временных рядов: LSTM, TCN и вейвлетные сети 46

1.6.3 Обучение при малых датасетах и стратегии валидации 50

1.6.4 Gap: мультимодальные онлайн-системы 52

1.7 Физиологические особенности триатлонистов при велоэргометрическом тестировании 53

1.8 Заключение по обзору литературы 54

2 Материалы и методы 57

2.1 Участники исследования 57

2.2 Протокол нагрузочного тестирования 57
2.3 Аппаратный комплекс регистрации 58
2.3.1 Электромиография и инерционные измерения 58
2.3.2 Ближняя инфракрасная спектроскопия 59
2.3.3 Сердечный ритм 59
2.4 Система синхронного сбора данных Sensync 60
2.4.1 Архитектура и мотивация 60
2.4.2 Реализация 60
2.5 Предобработка сигналов 61
2.5.1 Электромиография 61
2.5.2 Мышечная оксигенация 62
2.5.3 RR-интервалы и HRV 62
2.6 Определение лактатных порогов (ground truth) 62
2.6.1 Определение LT1 62
2.6.2 Определение LT2 63
2.7 Признаковое пространство и модальности 64
2.7.1 ЭМГ-признаки (EMG) 64
2.7.2 NIRS-признаки 65
2.7.3 HRV-признаки 65
2.7.4 Признаки взаимодействия 65
2.7.5 Комбинации признаков 66
2.7.6 Варианты комбинаций 66
2.7.7 Базальные физиологические показатели 66
2.8 Модели машинного обучения 67
2.8.1 Постановка задачи 67

2.8.2 Формальная постановка 68
2.8.3 Формирование обучающей выборки 68
2.8.4 Методология широкого перебора 69
2.8.5 Схема валидации 69
2.8.6 Линейное семейство моделей 70
2.8.7 Нейросетевые семейства моделей 70
2.8.8 Выбор эпохи и агрегация оконных предсказаний 72
2.8.9 Стандартизированный аналитический этап и итоговый рейтинг 72
2.9 Метрики качества 72
2.9.1 Две дорожки оценки качества 72
2.9.2 Коэффициент детерминации R^2 74
2.9.3 Ранговая корреляция Спирмена (ρ) 74
2.9.4 Базовые предсказатели 74
2.10 Постобработка 75
2.11 Статистический анализ и интерпретация 75
2.11.1 Парные сравнения моделей: критерий Уилкоксона с поправкой Бенджамини–Хохберга 75
2.11.2 Дополнительные параметры эффекта и доверительные интервалы 76
2.11.3 Сравнения по аналитическим осям 76
2.11.4 Конформное предсказание (conformal prediction) 77
2.11.5 Интерпретация модели: анализ важности признаков (SHAP) 77
3 Результаты и обсуждения 78
3.1 Сводный рейтинг моделей 78
… 78

Заключение 79

Список использованных источников 80

Приложение 1 85

ЭМГ: временна́я область (16 признаков × 4 потока = 64) 85

ЭМГ: вариабельность амплитуды цикл-к-циклу (4 признака) 87

Кинематика педалирования (11 признаков) 87

NIRS — оконные признаки (15 признаков, Train.Red) 87

NIRS — кумулятивные признаки (3 признака) 88

HRV —вриабельность сердечного ритма (7 признаков) 88

Взаимодействия (3 признака, только EMG+NIRS+HRV) 88

Абсолютные признаки, исключаемые в варианте noabs (6 признаков) ... 89

Базальные физиологические показатели 89

Введение

Определение аэробно-анаэробного перехода является ключевой задачей спортивной физиологии и клинической медицины: первый лактатный порог (LT1) разграничивает аэробный и переходный режимы энергообеспечения, второй (LT2) соответствует максимальной устойчивой интенсивности нагрузки, выше которой наступает прогрессирующий лактоацидоз. Точное определение этих порогов позволяет персонализировать тренировочные зоны, контролировать нагрузку в режиме реального времени и проводить функциональную диагностику без дорогостоящего лабораторного оборудования.

Традиционные методы определения лактатных порогов – ступенчатый тест с забором капиллярной крови или газоаналитический метод – являются либо инвазивными, либо требуют стационарного оборудования, что существенно ограничивает их применение в полевых условиях, при регулярном мониторинге тренировочного процесса и в клинической практике. В последнее десятилетие активно развиваются неинвазивные подходы: анализ вариабельности сердечного ритма (HRV, в частности показатель DFA-α1), мышечная оксигенация методом ближней инфракрасной спектроскопии (NIRS) и поверхностная электромиография (ЭМГ). Каждый из этих методов в отдельности продемонстрировал значимую корреляцию с лактатным порогом. Вместе с тем совместное применение этих трёх сигнальных каналов в единой мультимодальной системе онлайн-предсказания в существующей литературе систематически не исследовалось, а большинство опубликованных алгоритмов работают в офлайн-режиме либо ориентированы на детекцию только одного из порогов. Таким образом, разработка метода, объединяющего ЭМГ, NIRS и HRV в единый пайплайн онлайн-предсказания LT1 и LT2 исключительно по данным носимых датчиков, представляет актуальную нерешённую задачу на стыке спортивной физиологии, обработки сигналов и машинного обучения.

Целью настоящей работы является разработка и валидация метода неинвазивного онлайн-предсказания аэробно-анаэробного перехода по данным поверхностной электромиографии и ближней инфракрасной спектроскопии работающей мышцы в условиях ступенчатого нагрузочного велоэргометрического теста. Для достижения поставленной цели решаются следующие задачи. Во-первых, разработать протокол синхронной записи данных с носимых датчиков (Delsys Trigno: ЭМГ и ИМУ мышцы vastus lateralis (дистальная и проксимальная зоны); Train.Red: мышечная оксигенация SmO_2 на vastus lateralis; Zephyr BioHarness: RR-интервалы) и сформировать размеченный датасет на гетерогенной выборке (n = 18) с различным уровнем физической подготовки и верификацией лактатных порогов LT1 и LT2 по капиллярной крови. Во-вторых, разработать алгоритм предобработки и синхронизации разночастотных физиологических сигналов, включая сегментацию ЭМГ по фазам педалирования на основе данных гироскопа, фильтрацию и нормализацию ЭМГ, сглаживание SmO_2, интерполяцию RR-интервалов и расчёт DFA-α1 в скользящем окне. В-третьих, сформировать набор признаков для онлайн-предсказания близости к лактатным порогам, включающий классические ЭМГ-характеристики (RMS, MDF, вейвлетная энергия по уровням DWT), показатели мышечной оксигенации (SmO_2, $\Delta SmO_2/\Delta t$) и вариабельности сердечного ритма (RMSSD, DFA-α1) с учётом фазовой структуры цикла педалирования. В-четвёртых, разработать ML-модель, предсказывающую в скользящем временном окне оставшееся время до наступления лактатных порогов LT1 и LT2 в режиме реального времени; систематически сопоставить базовый подход на классических моделях с ручными признаками (регуляризованная линейная регрессия, метод опорных векторов, градиентный бустинг) и расширенный подход на нейросетевых архитектурах для временных рядов (рекуррентные, темпоральные свёрточные и вейвлет-обогащённые). В-пятых, оценить точность предсказания LT1 и LT2 по носимым данным в сравнении с лактатным порогом, определённым по капиллярной крови, с использованием стратегии Leave-One-Subject-Out

(LOSO), провести анализ значимости признаков методом SHAP и сопоставить результаты с данными литературы.

Методологическую основу работы составляет системный подход к анализу физиологических сигналов: многоканальные данные с носимых датчиков рассматриваются как взаимодополняющие проекции единого физиологического процесса – перехода от аэробного к анаэробному режиму энергообеспечения. Применяемые методы включают ступенчатое велоэргометрическое тестирование с верификацией лактатных порогов по капиллярной крови (методы Dmax и mDmax); синхронную многоканальную запись поверхностной ЭМГ, данных ИМУ, мышечной оксигенации методом ближней инфракрасной спектроскопии (NIRS) и кардиоинтервалографии; цифровую обработку сигналов (полосовая фильтрация, вейвлетное преобразование, детрендированный флуктуационный анализ); машинное обучение на временных рядах физиологических сигналов; статистическую оценку с использованием LOSO-валидации и интерпретацию модели методом SHAP.

Теоретическая значимость работы состоит в систематическом исследовании информационного вклада ЭМГ, NIRS и HRV-признаков в задачу онлайн-детекции LT1 и LT2 при велоэргометрической нагрузке, а также в разработке методологии мультимодальной интеграции разночастотных физиологических сигналов для построения модели предсказания близости к лактатным порогам. Практическая значимость определяется возможностью определять LT1 и LT2 в режиме реального времени исключительно по данным носимых датчиков, без лабораторного газоаналитического оборудования и инвазивного забора крови. Разработанный метод применим для персонализации тренировочного процесса и управления нагрузкой у спортсменов на выносливость, а также может быть адаптирован для задач функциональной диагностики и контроля переносимости нагрузки в программах клинической реабилитации.

1 ОБЗОР ЛИТЕРАТУРЫ

1.1 Аэробно-анаэробный переход: физиологические механизмы

Аэробно-анаэробный переход представляет собой диапазон интенсивности нагрузки, при котором анаэробный гликолиз начинает вносить существенный вклад в энергообеспечение мышечной работы, и лактат в крови начинает накапливаться быстрее, чем может быть удалён. Концептуально различают два качественно различных переходных состояния: первый порог (VT1/LT1) и второй порог (VT2/LT2/MLSS). Первый порог соответствует первому достоверному росту концентрации лактата выше базального уровня – приблизительно 2,0–2,5 ммоль/л – и сопровождается начальными вентиляционными изменениями. Второй порог, нередко именуемый анаэробным порогом или максимальным лактатным стационарным состоянием (MLSS), соответствует интенсивности, при которой производство лактата окончательно превосходит скорость его клиренса; при фиксированном протоколе 4 ммоль/л он часто используется как его приближение [Wackerhage, Gehlert, 2022; Fiedler, Woll, 2025].

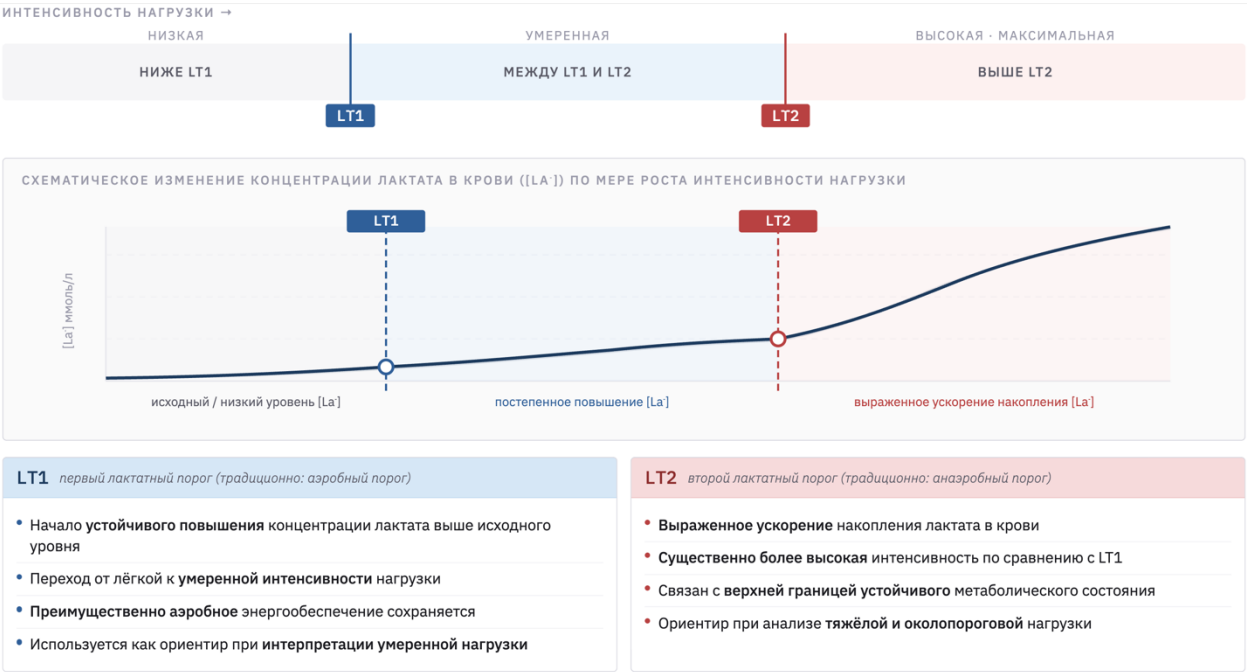

Ключевую роль в понимании лактатного порога сыграли работы по кинетике лактата. Messonnier с соавторами [Messonnier, Emhoff, 2013] в серии экспериментов с изотопными метками показали, что лактатный порог

соответствует точке, при которой скорость удаления и утилизации лактата тканями – метаболический клиренс лактата (MCR) – достигает максимума: при переходе от интенсивности LT−10% к уровню LT MCR снижается на 30%, а у тренированных спортсменов MCR при LT был на 34% выше, чем у нетренированных (62,5 против 46,5 мл·кг$^{-1}$·мин$^{-1}$, $p<0,05$). Таким образом, порог отражает не просто момент появления лактата, а точку ограничения его клиренса. Примерно 70–80% утилизируемого лактата окисляется непосредственно, а 20–30% служат субстратом для глюконеогенеза [Messonnier, Emhoff, 2013]. Транспортные белки MCT1 и MCT4, которые переносят лактат через мембрану мышечной клетки, играют роль лимитирующего звена при высокой интенсивности: семидневная тренировка увеличивает содержание MCT1 в мышечной ткани на 118%, что сопровождается повышением скорости выхода лактата из мышечного волокна в венозную кровь [Bonen, McCullagh, 1998].

Разграничение двух порогов тесно связано с физиологией рекрутирования двигательных единиц (ДЕ). При умеренной нагрузке работа поддерживается преимущественно медленными окислительными волокнами (тип I), способными к высокой скорости окислительного фосфорилирования. По мере роста нагрузки в работу постепенно вовлекаются быстрые гликолитические ДЕ (тип II), обладающие более высокой максимальной скоростью образования лактата (VLamax). Именно этот рекрутирующий сдвиг является физиологической основой первого порога: к нему лактат начинает накапливаться, поскольку быстрые волокна производят его быстрее, чем соседние медленные волокна и сердечная мышца успевают его утилизировать [Wackerhage, Gehlert, 2022; Brooks, 2023]. Количественно этот сдвиг можно описать через модель Мадера, детально рассмотренную Wackerhage и Gehlert [2022]: в ней активация гликолиза и окислительного фосфорилирования задаётся концентрацией свободного АДФ, а высокая VLamax снижает мощность на ПАНО и ухудшает результативность на длинных дистанциях.

Почему детектируются именно два порога, а не один, объясняется разными механизмами формирования буферной ёмкости и вентиляционного ответа. Первый порог (VT1/LT1) отражает начальное включение бикарбонатной буферной системы для компенсации появляющегося лактата – у молодых здоровых испытуемых VT1 наступает при 59,4% VO_2max [Lin, Huang, 2020]. Второй порог (VT2/LT2) маркирует исчерпание буферной ёмкости и начало дыхательной компенсации метаболического ацидоза; в той же популяции VT2 соответствовал 86,1% VO_2max [Lin, Huang, 2020]. При медленных рамп-протоколах тестирования лактатный порог может выявляться существенно раньше вентиляционного – Kominami и Nishijima [2015] показали, что у части испытуемых LT наступает уже при ~30% VO_2peak, опережая VT (~38% VO_2peak), что объясняется временем диффузии лактата из интерстициального пространства в капиллярную кровь. Это разграничение между биохимическим и вентиляционным порогами принципиально важно при интерпретации данных ступенчатого теста.

Первый лактатный порог (LT1) несёт практическое значение не только для спорта, но и для физиологии труда. Fasching и Rinnerhofer [2020] в исследовании 188 мужчин и 52 женщин рабочих специальностей показали, что 95,4% выполняли обычную профессиональную деятельность при интенсивности ниже LT1: именно этот порог является физиологическим верхним пределом для продолжительной тяжёлой работы длительностью до 8 часов. Превышение LT1 сопровождается ростом концентрации катехоламинов и активацией симпатической нервной системы, что ускоряет развитие утомления. Таким образом, точное определение обоих порогов критично как в контексте управления тренировочным процессом, так и при оценке функциональных возможностей человека.

Описанные различия в лимитирующих факторах имеют прямые следствия для выбора информативных неинвазивных маркеров в гетерогенной выборке. У высокотренированных спортсменов высокая митохондриальная

плотность и ёмкость окислительного фосфорилирования смещают узкое горлышко в сторону доставки кислорода к работающей мышце [Messonnier, Emhoff, 2013]: NIRS-сигнал SmO_2 непосредственно отражает момент, когда доставка перестаёт покрывать метаболический спрос, и должен давать чёткий breakpoint. У менее тренированных испытуемых первичным ограничивающим звеном остаётся митохондриальная ёмкость – скорость гликолитического синтеза пирувата превышает способность митохондрий его окислять при ещё адекватной доставке кислорода [Wackerhage, Gehlert, 2022], что может размывать NIRS-breakpoint, тогда как более раннее рекрутирование быстрых волокон типа II и соответствующий вегетативный ответ усиливают информативность ЭМГ и HRV-маркеров. Таким образом, для выборки с широким диапазоном тренированности ни одна модальность не является универсально оптимальной – гипотеза, которая может быть проверена посредством SHAP-анализа вклада признаков.

Несмотря на хорошо разработанную физиологическую концепцию двух порогов, существующие методы их определения остаются либо инвазивными (заборы крови для лактатного анализа), либо требуют специализированного газоаналитического оборудования. Определение обоих порогов – LT1 и LT2 – в реальном времени непрерывно, по локальным неинвазивным сигналам работающей мышцы, на сегодняшний день не реализовано.

1.2 Электромиография как неинвазивный маркер порога при велоэргометрии

1.2.1 Классические признаки: RMS, MDF и ЭМГ-порог

Поверхностная электромиография (*sEMG*) позволяет неинвазивно регистрировать электрическую активность скелетных мышц и тем самым косвенно отражать паттерн рекрутирования двигательных единиц, то есть последовательность и степень включения различных двигательных единиц мышцы в работу. Принципиальная возможность использования ЭМГ для определения анаэробного порога была продемонстрирована ещё в работе

Nagata и соавторов [Nagata, Moritani, 1981], в которой была обнаружена высокая корреляция между ЭМГ-порогом по интегрированной ЭМГ (IEMG-AT) и кровяным анаэробным порогом ($r=0,921$, $p<0,001$, $n=10$). В той же работе было показано, что значимое увеличение ширины частотной полосы FRQ70% (полоса на уровне 70% пиковой частоты спектра) происходит непосредственно после достижения кровяного анаэробного порога (mean diff. = 10,3 Гц, $t=2,82$, $p<0,05$), тогда как пиковая частота (PFR) не меняется значимо. При этом ЭМГ-порог по VO_2 определяется с незначительной задержкой относительно кровяного AT (mean diff. = 0,20 л/мин, $t=3,98$, $p<0,05$), хотя в 4 из 10 случаев оба порога совпадали точно.

Механизм формирования ЭМГ-порога связан с физиологией рекрутирования. При нарастании интенсивности нагрузки, когда медленные окислительные волокна типа I начинают испытывать локальное утомление в условиях нарастающего ацидоза, в работу вовлекаются быстрые двигательные единицы типа II: быстро окислительно-гликолитические (FOG) и быстро гликолитические (FG). Это приводит к двум связанным эффектам: амплитуда ЭМГ (RMS/IEMG) нелинейно возрастает за счёт увеличения числа и вклада активных мышечных волокон, а средняя (MNF) и медианная (MDF) частоты спектра смещаются вниз вследствие снижения скорости проведения потенциала действия по волокнам при накоплении лактата и падении внутримышечного pH [Nagata, Moritani, 1981]. – вследствие снижения скорости проведения потенциала действия по мышечным волокнам при накоплении лактата и падении внутримышечного pH [Nagata, Moritani, 1981]. Совместная регистрация NIRS и *sEMG* позволяет верифицировать этот механизм напрямую: Şayli и Akin [2014] при изометрических нагрузках 50% и 75% MVC обнаружили значимую отрицательную корреляцию между длительностью быстрой фазы снижения NIRS-сигнала и наклоном MNF ЭМГ, что подтверждает взаимосвязь между электрической активностью и локальной оксигенацией мышцы.

При велоэргометрии паттерны ЭМГ-активации существенно различаются для разных мышц. *Vastus lateralis* (VL) является главным разгибателем коленного сустава и обеспечивает преобладающий вклад в фазу давления на педаль (load-фаза, ~0°–180° цикла педалирования). Метод ATHHb-ЭМГ, разработанный и валидированный Поповым с соавторами [Popov, Vinogradova, 2019; Попов, Кузнецов, 2019], основан на совместном анализе нормированного сигнала ЭМГ (nEMG) и нормированного дезоксигемоглобина (nHHb) по VL. В велоэргометрическом тесте с нарастающей нагрузкой (n=40) корреляция метода с лактатным порогом LT4 составила r=0,89 (p<0,001), а коэффициент вариации при тест-ретесте – около 3%, что значительно превышает воспроизводимость традиционных ЭМГ-пороговых методов [Popov, Vinogradova, 2019]. Алгоритм использует V-slope метод (минимальная сумма квадратов остатков при двух кусочно-линейных регрессиях) и аппроксимацию nEMG полиномом 5-й степени для определения мощности на пороге.

Важным методологическим подтверждением запаздывающего характера ЭМГ-порога относительно мышечной оксигенации служит исследование Racinais с соавторами [Racinais и др., 2014], в котором на 25 велосипедистах одновременно регистрировались NIRS на VL, ЭМГ на VL, RF и BF, а также газоаналитические показатели в инкрементальном тесте. Авторы установили, что ЭМГ-порог по VL наступает уже после VT2 (89±5% от пиковой нагрузки), а на RF – при 82±14% (оба значимо позже VT2, p<0,05, d>0,6), тогда как мышечный NIRS breakpoint совпадает с VT2 (около 78–80% нагрузки). Полученный временной градиент означает, что NIRS реагирует на метаболические события второго порога раньше, чем ЭМГ способна отразить рекрутирование высокопороговых ДЕ. Этот вывод имеет прямое значение для архитектуры мультимодального предиктора: ЭМГ как сигнал по природе запаздывает, тогда как NIRS – опережающий маркер, и комбинация этих модальностей восполняет ограничения каждой по отдельности.

Разделение ЭМГ-активности по фазам педалирования открывает дополнительный аналитический потенциал. Гироскоп, интегрированный в датчик Delsys Trigno (угловая скорость оси педали), позволяет в реальном времени идентифицировать load- и rest-фазы цикла. При нарастании интенсивности изменяется относительный вклад фаз в суммарную ЭМГ-активность: растёт доля load-фазы, что отражает увеличение вербовки ДЕ в наиболее нагруженный период цикла. Этот признак, практически не исследованный в литературе как маркер порога, представляет собой потенциальный информационный канал для повышения точности ML-модели. Для модели это важно потому, что одинаковая суммарная ЭМГ-активность может соответствовать разному распределению усилия по фазам цикла, а значит фазовый признак добавляет информацию, которой нет в обычных усреднённых амплитудных метриках. Существующие же работы по ЭМГ и порогу сосредоточены преимущественно на амплитудных и спектральных характеристиках без учёта фазовой структуры педального цикла.

Среди методологических ограничений метода sEMG при велоэргометрии следует выделить несколько принципиальных. Во-первых, межэлектродные расстояния и положение электрода относительно двигательных точек и зон иннервации существенно влияют на амплитуду и форму сигнала, что затрудняет межсессионное сравнение без точного воспроизведения наложения. Во-вторых, нормализация IEMG/RMS – обязательное условие для корректного сравнения между испытуемыми: без нормировки абсолютные значения несопоставимы из-за различий в толщине подкожного жира, морфологии мышцы и импедансе кожи. В методе Попова [Popov, Vinogradova, 2019] нормировка выполняется на диапазон [EMGmax − EMGmin] по всему тесту, что исключает необходимость максимального произвольного сокращения. В-третьих, у пациентов с нейромышечными расстройствами ЭМГ-пороги значимо смещены и имеют более низкую воспроизводимость [Voet, Janssen, 2022], однако для популяции тренированных триатлонистов данное ограничение нерелевантно.

Несмотря на демонстрацию принципиальной работоспособности ЭМГ как маркера лактатного порога, существующие подходы не обеспечивают онлайн-детекцию в скользящем окне с учётом фазовой структуры педального цикла, а комбинированный анализ ЭМГ VL с синхронной NIRS на той же мышце – как основа мультимодального предиктора – в литературе не реализован.

1.2.2 Вейвлетный анализ ЭМГ

Классические признаки ЭМГ – RMS, MNF, MDF – извлекаются на основе быстрого преобразования Фурье (FFT) либо его оконных модификаций (STFT) и предполагают локальную стационарность сигнала в пределах окна анализа, то есть считают, что на коротком временном отрезке статистические свойства сигнала существенно не меняются. Однако сама природа ЭМГ при динамических нагрузках на велоэргометре противоречит этому допущению: рекрутирование двигательных единиц меняется циклически в пределах педального оборота, а интенсивность нагрузки изменяется ступенчато, что делает ЭМГ принципиально нестационарным сигналом. Graham и соавторы [Graham и др., 2015] показали, что STFT ограничен фиксированным временным разрешением порядка 500 мс, что недостаточно для разрешения быстрых частотных сдвигов при супрамаксимальных и переходных нагрузках; FFT же не сохраняет временную привязку частотного содержимого вовсе. Альтернативный класс методов – вейвлетный анализ – был разработан именно для обработки нестационарных сигналов и обеспечивает компромисс между временным и частотным разрешением, адаптивный к масштабу анализируемой особенности.

Дискретное вейвлетное преобразование (DWT) разлагает ЭМГ-сигнал на иерархию уровней декомпозиции, каждый из которых соответствует определённому поддиапазону частот. Для ЭМГ с частотой дискретизации 2000 Гц при использовании вейвлета Daubechies 6-го порядка (db6) уровни d1–d2 (~500–1000 Гц) преимущественно содержат высокочастотный шум, уровни

d3–d5 (~50–250 Гц) – основную мышечную активность, а более низкие уровни – медленные тренды и артефакты движения. На каждом уровне могут вычисляться количественные признаки: энергия (сумма квадратов вейвлет-коэффициентов), дисперсия и вейвлет-энтропия; в ML-пайплайне такие величины образуют входной вектор признаков, по которому модель оценивает состояние утомления или вероятность приближения к пороговой зоне. Wang и соавторы [Wang и др., 2018] провели сопоставление ЭМГ-индексов на VL в 30-секундном all-out велоэргометрическом тесте (n=10) и показали, что MNF, рассчитанная по вейвлет-пакетному разложению с db6, по grey relational grade – мере близости динамики признака к выбранной референсной кривой утомления – значимо превзошла классические индексы – RMS, MF и MPF на основе FFT, MDF, а также сложность Лемпеля-Зива – для оценки мышечного утомления при динамическом педалировании. Jamaluddin и соавторы [Jamaluddin и др., 2023] ввели семейство Wavelet Index (WI) признаков (WIRM1551, WIRE51 и др.), отражающих распределение энергии по шкалам и частотным диапазонам, и применили их к задаче неинвазивной идентификации затяжной мышечной усталости (prolonged fatigue) у 20 участников по 5-дневному протоколу. Классификатор Naive Bayes на наборе WI и классических признаков достиг точности 98% на *m. rectus femoris*, 97% на *m. vastus medialis* и 94% на *m. biceps femoris*. Принципиально важным для настоящей работы является то, что на *m. vastus lateralis* точность того же классификатора составила лишь 9% – на порядки ниже, чем на других мышцах квадрицепса, и изменения классических индексов (ΔFmed, ΔRMS, ΔMAV) между нормальным состоянием и состоянием prolonged fatigue были статистически незначимыми именно на VL. Этот результат свидетельствует о специфической вариабельности ЭМГ VL при длительной утомляемости и требует осторожной интерпретации вейвлетных признаков на этой мышце в контексте задачи детекции лактатного порога.

Непрерывное вейвлетное преобразование (CWT) предоставляет более гибкий, хотя и вычислительно более затратный, инструмент для разведочного

анализа ЭМГ. В отличие от DWT, где анализ выполняется только на заранее заданных уровнях масштаба, CWT обеспечивает почти непрерывное покрытие частотно-временной плоскости, формируя скалограмму – двумерную карту того, как энергия сигнала распределяется по времени и частоте, что удобно для визуализации структурных изменений сигнала. Graham и соавторы [Graham и др., 2015] применили CWT к ЭМГ-данным велоэргометрических испытаний при трёх интенсивностях – 73%, 100% и 133% VO_2peak – и обнаружили, что при 133% VO_2peak уже с первого интервала наблюдалось достоверно большее падение центральной частоты и одновременный рост площади всплеска (intensity·duration), тогда как RMS и MDF в эти моменты ещё не различали условия. CWT, тем самым, выявила режим супрамаксимальной нагрузки как качественно отличный от 100% VO_2peak там, где классические показатели регистрировали лишь количественное различие. Для практических ML-приложений DWT/вейвлет-пакеты остаются предпочтительнее CWT в силу фиксированной вычислительной стоимости и компактного представления признаков, тогда как CWT – основной инструмент разведочного анализа.

Естественное расширение вейвлетного представления – комбинирование с нелинейными признаками сигнала, поскольку ЭМГ по своей природе несёт нелинейные характеристики, отражающие непредсказуемость паттернов разряда отдельных двигательных единиц. Wang G. и соавторы [Wang G. и др., 2014] предложили использовать вейвлет-разложение совместно с корреляционной размерностью (нелинейной мерой сложности динамической системы): на 3-м уровне декомпозиции при двух каналах ЭМГ предплечья достигнута 100% точность классификации четырёх двигательных паттернов, что превзошло методы без вейвлет-предобработки и без нелинейных признаков. Принципиальное значение этого подхода для задачи онлайн-детекции порога заключается в том, что нелинейные характеристики, рассчитанные на отдельных уровнях декомпозиции, сохраняют временную привязку частотного содержимого, тогда как глобальные нелинейные индексы её утрачивают. Для ML-модели порога это

означает потенциальную возможность построения признакового пространства, в котором каждый уровень DWT представлен своим набором линейных и нелинейных характеристик.

Помимо извлечения признаков, вейвлетное преобразование применимо как метод аугментации обучающих данных. Tsinganos и соавторы [Tsinganos и др., 2020] систематически сопоставили техники аугментации ЭМГ для задачи распознавания жестов и показали, что декомпозиция сигнала на вейвлет-уровни с последующим добавлением шума на каждый уровень и реконструкцией обеспечивает прирост точности классификации до +16% на двух эталонных датасетах – существенно больше, чем простое аддитивное зашумление либо использование перекрывающихся окон. Принципиальным здесь является то, что синтетические сигналы, полученные через вейвлет-аугментацию, сохраняют физиологическую структуру оригинала: распределение энергии по полосам, форма огибающей и спектральные характеристики каждого уровня изменяются согласованно. Это делает вейвлеты универсальным инструментом, применимым как для извлечения признаков в feature engineering, так и для генерации обучающих данных при ограниченных выборках, что напрямую релевантно настоящей работе и подробно обсуждается в разделе 2.6.3.

Несмотря на демонстрированную информативность вейвлетных признаков ЭМГ при задачах классификации мышечной усталости, распознавания движений и идентификации затяжной утомляемости, их применение для онлайн-детекции аэробно-анаэробного порога при ступенчатом велоэргометрическом тесте – особенно на VL в сочетаниис NIRS и HRV – в рецензируемой литературе систематически не исследовалось. Этот разрыв имеет VL-специфический аспект: именно на этой мышце вейвлетные признаки демонстрировали наименьшую точность при идентификации длительной утомляемости [Jamaluddin и др., 2023], что

требует дополнительной валидации в физиологическом контексте задачи настоящей диссертации.

1.3 Ближняя инфракрасная спектроскопия и локальная мышечная оксигенация

Ближняя инфракрасная спектроскопия (NIRS) основана на различии спектров поглощения оксигемоглобина (O_2Hb) и дезоксигемоглобина (HHb) в ближнем инфракрасном диапазоне (700–900 нм). При непрерывном облучении ткани и регистрации отражённого сигнала NIRS позволяет оценивать текущий баланс между доставкой и утилизацией кислорода непосредственно в работающей мышце – без временных задержек, присущих системным маркерам (лактат крови, вентиляционные показатели). Показатель тканевой сатурации кислорода (SmO_2, %) отражает соотношение O_2Hb к суммарному гемоглобину (THb) в зондируемом объёме ткани и является наиболее клинически интерпретируемым выходным параметром портативных систем – Moxy Monitor и Train.Red.

Ключевой вопрос применения NIRS для детекции порога – какой именно параметр наиболее точно отражает лактатный порог. Wang и соавторы [Wang, Yoshikawa, 2006] в инкрементальном велоэргометрическом тесте (n=15) провели сравнительный анализ трёх NIRS-переменных. Точка перегиба ΔHHb была определена у всех 15 испытуемых; её корреляция с вентиляционным порогом составила r=0,99 по нагрузке и r=0,97 по VO_2 ($p<0,0001$), а с лактатным порогом – r=0,76 по нагрузке и r=0,80 по VO_2 ($p<0,05$). Точка перегиба ΔO_2Hb была определена лишь у 11 из 15 испытуемых и соответствовала значительно более высоким нагрузкам. TOI (тканевой индекс оксигенации) коррелировал с вентиляционным порогом (VT) и нормированным индексом максимального суммарного гемоглобина (nTHImax), но не был специфичным маркером лактатного порога (LT). Авторы заключили, что ΔHHb является оптимальным NIRS-параметром для

определения LT при велоэргометрии, поскольку точно отражает динамику O_2-метаболизма независимо от перфузии.

Соответствие NIRS-порога (breakpoint оксигенации) вентиляционным и лактатным порогам подтверждено рядом независимых исследований. Lin и Huang [2020] в выборке из 100 испытуемых показали, что полиномиальная регрессия 3-й степени, применённая к кривым O_2Hb и HHb, позволяет автоматически определять VT1 и VT2: пик функции O_2Hb соответствует VT1 (35,0 ± 1,0 против 35,8 ± 1,0 мл·кг$^{-1}$·мин$^{-1}$ по вентиляционному методу, $p>0,05$), а пик функции HHb – VT2 (46,2 ± 1,1 против 47,4 ± 1,0 мл·кг$^{-1}$·мин$^{-1}$, $p>0,05$). Воспроизводимость метода высокая: $r=0,94$ между сессиями, Bland–Altman в пределах 95% CI. Coquart и Mucci [2017] показали, что первая точка перегиба O_2Hb в латеральной широкой мышце бедра (*m. vastus lateralis*; O_2Hb-T) коррелирует с газообменным порогом (GET, gas exchange threshold) ($r=0,79$, $p<0,001$, $n=14$) и наступает раньше GET: NIRS отражает локальный метаболизм мышцы без вентиляционной задержки. При этом оба параметра предсказывают время до истощения при 90% Wpeak ($r=0,81$ и $r=0,72$, $p<0,01$ соответственно).

Двустороннее измерение SmO_2 повышает точность детекции порогов. Reinpõld и Rannama [2024] в выборке велосипедистов установили, что усреднённый билатеральный сигнал SmO_2 (Avr) обеспечивает лучшее соответствие с VT: смещение Pkg@BP2 относительно Pkg@VT2 составило лишь 0,03 ± 0,22 Вт/кг ($R^2=0,86$, $p>0,05$). BP1 был систематически ниже VT1 (0,12 ± 0,29 Вт/кг, $R^2=0,72$), причём у велосипедистов спринтерского типа наблюдалась тенденция к более раннему системному VT по сравнению с локальным NIRS-порогом. Авторы подчёркивают, что индивидуальная вариабельность между системными и локальными порогами остаётся высокой, что исключает их полную взаимозаменяемость на индивидуальном уровне без верификации лактатным тестом. Иными словами, даже если средние значения по группе хорошо совпадают, у конкретного спортсмена локальный

мышечный порог по NIRS может заметно не совпасть с системным порогом, определённым по дыханию или лактату. Валидация портативного NIRS-датчика van der Zwaard и соавторов [2016] на велосипедистах показала умеренную корреляцию BP с VT1 (r=0,58–0,68), что авторы объясняют крупным шагом нагрузочных ступеней (30–50 Вт) – важное методологическое замечание для дизайна ступенчатых тестов.

Среди преимуществ NIRS перед системными маркерами выделяют: непрерывность регистрации (против дискретных заборов крови), локальность сигнала (конкретная мышца, а не системный пул), и отсутствие временной задержки, связанной с транспортом лактата от мышцы к месту забора крови. В частности, Farzam и Starkweather [2018] продемонстрировали, что портативная CW-NIRS (Humon Beta) коррелирует с лабораторной системой MetaOx по SmO_2 (r=0,86, RMSE=3,4%), а Driller и Borges [2016] провели валидацию носимого датчика BSXinsight на *m. gastrocnemius* у велосипедистов: наилучшее соответствие было получено с методом Dmax (TEE=8,6 Вт, 4,4%; 95% LoA = ±17 Вт; r=0,96).

Основным методологическим ограничением NIRS при измерении на работающих мышцах является влияние толщины подкожной жировой клетчатки (ATT, adipose tissue thickness). van der Zwaard и соавторы [2016] показали, что ATT объясняет около 80% межиндивидуальной вариабельности SmO_2: при большей толщине жирового слоя регистрируемое снижение SmO_2 уменьшается, так как в зондируемый объём включается оксигенированная жировая ткань. Popov и Vinogradova [2019] указывают, что при толщине жирового слоя более 10 мм мышечный сигнал может быть существенно замаскирован. Farzam и соавторы [2018] подчёркивают, что простой порог SmO_2 недостаточен для надёжного определения LT: необходимы алгоритмы, учитывающие динамику HbO, HbR и HbT совместно. Дополнительным ограничением является низкая воспроизводимость алгоритмов детекции порога по кривой StO_2: Cayot и Robinson [2021] показали, что методы Dmax и

mDmax дают ICC=0,351 и ICC=0,385 соответственно – недопустимо низкие значения для клинического применения, хотя сами кривые StO_2 воспроизводимы (ICC=0,841–0,873). Из этого следует, что проблема заключается не в стабильности сигнала NIRS, а в неадекватности существующих алгоритмов его обработки.

Несмотря на доказанную валидность NIRS для детекции порогов, стандартные алгоритмы (Dmax, mDmax) демонстрируют неприемлемую воспроизводимость при их применении к SmO_2. Применение методов ML для автоматической и воспроизводимой детекции двух точек перегиба SmO_2 в реальном времени, в том числе в сочетании с ЭМГ-сигналом той же мышцы, остаётся нерешённой задачей.

1.4 Вариабельность сердечного ритма и DFA-α1 как онлайн-маркер первого порога

Вариабельность сердечного ритма (HRV) – показатель изменчивости последовательности RR-интервалов, отражающий состояние вегетативной нервной системы. При нарастании интенсивности физической нагрузки баланс сдвигается от парасимпатической к симпатической активности: RMSSD (квадратный корень из среднего квадрата последовательных разностей RR) нелинейно снижается, причём наиболее резкое падение совпадает с зоной VT1. Традиционные линейные метрики HRV (SDNN, SD1) имеют ограниченный динамический диапазон при нагрузке выше умеренной, что снижает их информативность в диапазоне выше первого порога. Метод детрендированного флуктуационного анализа (DFA) позволяет оценить фрактальные свойства RR-ряда через показатель краткосрочного масштабирования DFA-α1, который обладает широким динамическим диапазоном на протяжении всего инкрементального теста [Rogers, Gronwald, 2022].

Теоретическое обоснование метода DFA-α1 строится следующим образом. В покое RR-ряд демонстрирует персистентные долгосрочные

корреляции (DFA-α1 ≈ 1,0–1,2), характерные для фрактального поведения; по мере нарастания нагрузки корреляционная структура постепенно разрушается. Rogers и Gronwald [2022] обобщили накопленные к тому моменту данные: DFA-α1 = 0,75 ассоциирован с аэробным порогом (VT1) и получил обозначение «HRV-порог» (HRVT), а DFA-α1 = 0,50 соответствует анаэробному порогу (VT2/HRVT2). Практически это снижает зависимость признака от абсолютного масштаба измерений и упрощает его включение в ML-модель: DFA-α1 можно использовать как единый относительный показатель в разных протоколах и у спортсменов разного уровня, хотя индивидуальная вариабельность реакции сохраняется [Rogers, Gronwald, 2022]. Алгоритм расчёта реализован в скользящем окне (рекомендуемый диапазон 4–16 ударов) с обновлением каждые 5 секунд, что делает его применимым для мониторинга в реальном времени. Коррекция артефактов RR при уровне менее 3% не приводит к значимому смещению HRVT, что обеспечивает практическую устойчивость метода [Rogers, Gronwald, 2022].

Валидность метода DFA-α1 подтверждена в нескольких независимых исследованиях. Schaffarczyk и Gronwald [2022] в выборке женщин-велосипедисток показали хорошее совпадение между HRVT1 (DFA-α1=0,75) и VT1: статистические показатели согласованности и корреляции были высокими как для VO_2 (ICC=0,77; r=0,81), так и для ЧСС (ICC=0,87; r=0,87; p<0,001). HRVT2 (DFA-α1=0,50) соответствовал VT2 с ICC=0,84, r=0,86 (VO_2) и ICC=0,90, r=0,90 (ЧСС). Смещение по Bland–Altman для VT1 vs HRVT1 составило −1,3 мл·кг$^{-1}$·мин$^{-1}$ (LoA: −6,0 до +3,3), что приемлемо для практического применения. Важно, что данная работа впервые провела систематическую валидацию на женской популяции, ранее недостаточно изученной в контексте DFA-α1. Schaffarczyk и соавторы [Schaffarczyk, Rogers, 2022] также исследовали чувствительность DFA-α1 к тренировочному статусу у триатлонистов (n=11): после тяжёлой беговой тренировки DFA-α1 во время стандартизованной разминки при 90% VT1 значимо снижался (p=0,001, d=−1,44), тогда как нейромышечные тесты (CMJ) не выявляли значимых

изменений, что свидетельствует о том, что DFA-α1 отражает вегетативный аспект усталости.

Отдельного внимания заслуживает влияние биологического пола на кинетику DFA-α1 при нагрузке. Schaffarczyk и Gronwald [2022] показали, что у пременопаузальных женщин DFA-α1 снижается позже в ходе рамп-протокола: эстроген усиливает парасимпатический контроль сердца, вследствие чего фрактальные корреляции RR-ряда разрушаются при более высокой интенсивности. Это приводит к систематическому смещению HRVT1 и расширению пределов согласия (LoA) при сравнении с VT1 у женщин по сравнению с мужчинами. Важно, что HRVT2 у женщин демонстрирует хорошее соответствие с VT2 – авторы объясняют это тем, что второй порог отражает системную дестабилизацию, более резистентную к гормональным флуктуациям. Для настоящего исследования, включающего триатлонистов обоих полов, данный эффект является потенциальным источником систематической ошибки в DFA-α1-признаке и должен учитываться при анализе результатов модели [Schaffarczyk, Gronwald, 2022].

Принципиальные ограничения метода DFA-α1 связаны с требованиями к качеству RR-сигнала и стационарности нагрузки. Первое: метод требует достаточной длины окна для надёжного оценивания фрактального показателя – рекомендованный диапазон составляет 4–16 ударов (порядка 2 минут при ЧСС 120–160 уд/мин), что ограничивает временное разрешение при онлайн-применении. Второе: при наличии артефактов RR (>3%) необходима коррекция, а при высоком уровне шума надёжность оценок снижается. Третье: метод показывает высокую межиндивидуальную вариабельность: один и тот же прирост нагрузки может вызывать существенно разную реакцию DFA-α1 у разных спортсменов, что требует индивидуальной калибровки [Schaffarczyk, Rogers, 2022].

Накопленные количественные данные по соответствию HRV-порогов лактатным и вентиляционным были обобщены в недавнем систематическом

обзоре с мета-анализом Tanner и соавторов [Tanner и др., 2024], охватывающем 50 исследований и 1160 субъектов. Согласно результатам мета-анализа, HRVT1 не отличался значимо от LT1/VT1 (стандартизованная средняя разность SMD=0,08 при незначимом значении), а коэффициент корреляции составил r=0,85 (95% CI 0,75–0,91). Для второго порога HRVT2 vs LT2/VT2 величины оказались соизмеримыми: SMD=−0,06 (незначимо), r=0,85 (95% CI 0,80–0,89). Принципиально важным выводом является то, что характеристики субъектов, тип эргометра, начальная мощность и шаг нагрузки не влияют на точность определения HRVT – метод устойчив к вариациям протокола; HRVT2 несколько лучше определяется при коротких ступенях нагрузки. Таким образом, мета-анализ показывает, что HRV-пороги в среднем хорошо воспроизводят лактатные и вентиляционные пороги в разных протоколах нагрузки; поэтому RR-интервалы обоснованно рассматриваются как самостоятельный неинвазивный входной канал мультимодальной системы предсказания порогов.

Метод DFA-α1 валидирован как неинвазивный маркер VT1, однако его применение ограничено первым порогом и требует качественного RR-ряда без существенных артефактов. Schaffarczyk и Gronwald [2022] указывают на перспективность онлайн-расчёта DFA-α1 через носимые устройства (смарт-часы, нагрудные ремни) как следующий шаг развития метода, однако интеграция этого показателя с ЭМГ и NIRS в единый предиктивный алгоритм одновременного определения LT1 и LT2 в литературе не реализована.

1.5 Кинетика лактата: задержка системного сигнала относительно локального

Для корректной интерпретации лактатного порога, определяемого по капиллярной крови, необходимо понимать механизмы и временные характеристики транспорта лактата из работающей мышцы в системный кровоток. Bangsbo и Johansen [1993] в классическом эксперименте с

одноногим педалированием показали, что скорость выхода лактата из мышцы в кровь определяется разницей его концентраций между мышцей и кровью: чем эта разница больше, тем быстрее лактат покидает мышцу. В диапазоне внутримышечных концентраций от 0 до 45 ммоль·кг$^{-1}$ сырой массы эта зависимость была линейной, однако при высоких концентрациях транспортная система частично насыщается, и выход лактата начинает отставать от роста этого градиента. Доля медленных волокон (%ST) обратно пропорциональна градиенту лактата мышца–кровь: мышцы с большей долей медленных волокон удерживают меньший градиент при той же нагрузке. Внутримышечный pH при интенсивных нагрузках снижается до 6,73, а феморальный венозный pH – до 7,14–7,15, что само по себе влияет на транспортную кинетику [Bangsbo, Johansen, 1993].

MacLean и Bangsbo [1999] впервые применили метод микродиализа для мониторинга интерстициального лактата в *m. vastus lateralis* в реальном времени при динамической нагрузке. Было установлено, что концентрация лактата в интерстиции VL в покое составляет 2,5 ± 0,2 мМ – значительно выше, чем в артериальной (0,9 ± 0,2 мМ) и венозной (1,1 ± 0,2 мМ) плазме. При нарастании нагрузки относительное извлечение вещества микродиализным зондом из окружающей ткани (probe recovery) для лактата, возрастала с ~32% в покое до ~66% при максимальной нагрузке. Это указывало на более быстрый перенос лактата в интерстициальном пространстве сокращающейся мышцы. Изменения интерстициального лактата коррелировали с венозными, но не с артериальными концентрациями, что подтверждает: интерстициальный лактат отражает локальный метаболизм, а не системный пул [MacLean, Bangsbo, 1999]. Эти данные прямо указывают на существование концентрационной задержки: в начале ступени нагрузки капиллярный лактат (кончик пальца или мочка уха) отстаёт от реального внутримышечного значения.

Следствием описанной задержки является принципиальная зависимость определяемого лактатного порога от длительности ступеней тестового

протокола. Ji и Sommer [2021] и Wackerhage с Gehlert [2022] указывают, что ступени короче 3–4 минут не позволяют достичь квазистационарного состояния лактата: системный лактат в конце короткой ступени продолжает нарастать и не отражает равновесное состояние, характерное для данной мощности. Это методически смещает определяемый порог в сторону завышения. Иными словами, если ступень слишком короткая, кровь ещё не успевает показать полный ответ на данную мощность, и потому порог ошибочно фиксируется на более высокой нагрузке, чем та, при которой метаболический переход уже начался в мышце. Дополнительно, протокол тестирования существенно влияет и на само значение порога: разные комбинации VO_2max и *VLa*max могут давать идентичные лактатные кривые с равным LTAn, что делает стандартизацию протокола обязательным условием для межиндивидуального сравнения [Ji, Sommer, 2021]. В протоколе настоящего исследования используются ступени по 3 мин, что представляет разумный компромисс между требованиями к стационарности и практической длительностью теста для тренированных спортсменов.

Принципиально важную роль в понимании кинетики системного лактата играет объём вовлечённой мышечной массы. van Hall и Jensen-Urstad [2003] в исследовании с одновременной работой рук и ног (имитация лыжного хода) показали, что при большой вовлечённой мышечной массе скорость появления лактата в кровотоке (Ra) может достигать 184 ± 17 мкмоль·кг$^{-1}$·мин$^{-1}$, хотя артериальная концентрация остаётся низкой (<2,5 ммоль/л). Это объясняется тем, что часть работающих мышц одновременно активно поглощает лактат из крови и использует его как энергетический субстрат: около 95% поглощённого лактата окисляется непосредственно. Это означает, что при видах спорта с большой мышечной массой (лыжи, гребля) системный лактат принципиально ненадёжно отражает локальный метаболизм конкретной мышцы: часть мышц производит лактат, тогда как другая часть его потребляет через межмышечный шаттл [Brooks, 2023]. Велоэргометрия обладает в этом отношении методологическим преимуществом: нагрузка изолирована преимущественно

на мышцы нижних конечностей (VL, RF, gastrocnemius), что существенно снижает масштаб межмышечного лактатного шаттлинга и делает системный лактат более репрезентативным для локального метаболизма квадрицепса.

Неработающие мышцы вносят существенный вклад в клиренс лактата из системного кровотока. Bangsbo и Aagaard [1995] показали, что поглощение лактата неактивной мышцей пропорционально кровотоку: при двукратном увеличении перфузии поглощение удваивается, что указывает на перфузионное, а не транспортёрное ограничение в данных условиях. Транспорт лактата в неактивную мышцу котранспортируется с H^+ и вносит вклад в буферизацию системного ацидоза. При длительной нагрузке поглощение лактата неактивной мышцей снижается из-за её собственного закисления – ещё один аргумент в пользу временной нестационарности системного лактата. MCT1 играет центральную роль в этом процессе: Bonen и McCullagh [1998] установили, что семидневная тренировка увеличивает содержание MCT1 в мышце на 118%, а наклон регрессии мышца–феморальная вена возрастает на 33%, что отражает ускорение экструзии лактата и улучшение системного клиренса.

Концепция лактатного шаттла, развитая Brooks [2023], переосмысливает роль лактата как основного энергетического субстрата для аэробных тканей, а не как «отхода» анаэробного метаболизма. Лактат является связующим звеном между гликолитическими и окислительными компартментами как внутри одного волокна (внутриклеточный шаттл), так и между мышцами, а также от мышц к сердцу, мозгу и почкам (межклеточный и межорганный шаттл). Для задачи настоящей диссертации это означает, что NIRS-сигнал на *m. vastus lateralis* ближе к моменту локальных метаболических изменений в основной работающей мышце, тогда как капиллярный лактат отражает не только его продукцию, но и последующий транспорт, перераспределение и клиренс в других тканях. Поэтому временное расхождение между NIRS breakpoint и лактатной меткой следует рассматривать не только как ошибку измерения, но

и как физиологическое свойство самих сигналов. Таким образом, NIRS breakpoint на VL теоретически ближе к «правде» о мышечном метаболизме, чем капиллярный лактат, хотя на практике оба сигнала несут взаимодополняющую информацию.

Количественные данные о временной задержке между внутримышечным лактатом и капиллярным лактатом при ступенчатом велоэргометрическом тесте с шагом 30 Вт / 3 мин в литературе систематически не представлены. Это ограничивает точность разметки временных меток порога в ML-датасете и является источником неустранимой погрешности при верификации модели по лактатным меткам.

1.6 Машинное обучение и алгоритмы онлайн-детекции аэробно-анаэробного перехода

Автоматическая детекция аэробно-анаэробного перехода по физиологическим временным рядам является активно развивающейся областью, в которой методы машинного обучения постепенно вытесняют традиционные визуальные и пороговые алгоритмы. Принципиальные преимущества ML-подходов – способность улавливать нелинейные зависимости и интегрировать информацию из множества каналов – делают их особенно перспективными для задачи онлайн-детекции, где ни один отдельный физиологический сигнал не является достаточно надёжным в условиях реального времени.

1.6.1 Классический ML на ручных признаках

Среди существующих ML-подходов к классификации зон интенсивности и предсказанию порогов наиболее системный анализ был проведён Tomaszewski и Majorczyk [2024] на датасете из 183 протоколов кардиопульмонального нагрузочного тестирования (CPET) с лактатными метками. Для предсказания аэробного порога (AeT) лучшим алгоритмом оказался Random Forest (R^2=0,645, MAE=4,63 Вт, MSE=44,45, RMSE=6,67 Вт), для анаэробного порога (AnT) – LightGBM (R^2=0,803, MAE=3,44 Вт). Анализ

вклада признаков в решение модели (SHAP-анализ) показал, что наибольшее влияние на предсказание оказывают минимальный уровень лактата и ЧСС в момент максимального лактата, то есть показатели, описывающие индивидуальные особенности лактатного ответа у спортсмена. ML-модели в этой работе, однако, использовали лишь лактатные и кардиореспираторные признаки, не включая ЭМГ или NIRS.

Модельные подходы к предсказанию мощности на LT2 разрабатывались также в контексте метаболического моделирования. Fischer и Hävecker [2025] показали, что регрессионная модель на основе трёх физиологических показателей – максимального потребления кислорода (VO_2peak), доли этого максимума, используемой на уровне LT2 (%VO_2peak@LT2), и экономичности педалирования (Cc) – объясняет не менее 98% вариации мощности на LT2 у молодых велосипедистов (ICC≥0,961). При определении Cc при 90% LT2 точность достигала ICC≥0,986. Вклад VO_2peak составлял 62–67% от общего R^2, тогда как включение *VLa*max не улучшало точности предсказания. Ji и Sommer [2021] продемонстрировали, что расчётный лактатный анаэробный порог (cLTAn) через метаболическую симуляцию модели Мадера (VO_2max + *VLa*max + экономичность бега) сопоставим с mDmax (ICC=0,87) и OBLA (ICC=0,74), однако применение этих методов возможно лишь по результатам уже завершённого теста, а не в реальном времени. Здесь mDmax и OBLA выступают не онлайн-алгоритмами, а традиционными постфактум-критериями разметки порога по полной лактатной кривой; поэтому сопоставимость с ними не решает задачу детекции по ходу теста.

Алгоритмы автоматической детекции точки перегиба (*changepoint detection*) являются альтернативой полным ML-моделям в задачах, где нужно не классифицировать весь сигнал целиком, а найти момент, когда его поведение заметно меняется. В контексте физиологических данных это может быть точка, после которой показатель начинает расти, снижаться или колебаться по иному закону, чем раньше. Полиномиальная регрессия 3-й

степени, применённая Lin и Huang [2020] к NIRS-сигналам, позволяет автоматически определять VT1 (пик O_2Hb) и VT2 (пик HHb) без ручной разметки. V-slope метод двойной кусочно-линейной регрессии с минимизацией суммы квадратов остатков, применённый Поповым и соавторами [Popov, Vinogradova, 2019] к совместному сигналу nHHb–nEMG, успешно детектирует единственную точку перегиба. Для выявления двух порогов и детекции в скользящем окне требуются более гибкие подходы, например CUSUM (cumulative sum control chart), BOCPD (Bayesian online *changepoint detection*) или алгоритм *ruptures* (Python), однако применительно к многоканальным физиологическим сигналам (ЭМГ + NIRS + HRV) подобных работ в доступной литературе не представлено.

Работы с одиночными каналами демонстрируют ограниченную точность. Для NIRS: метод Dmax/mDmax по StO_2 показывает ICC<0,40 при тест-ретесте [Cayot, Robinson, 2021], тогда как полиномиальный метод по O_2Hb/HHb воспроизводим и точен [Lin, Huang, 2020]. Для ЭМГ: V-slope по nHHb–nEMG достигает r=0,89 с LT4 [Popov, Vinogradova, 2019], но не предназначен для онлайн-применения. Для HRV: DFA-α1=0,75 детектирует VT1 с ICC=0,77–0,87 [Schaffarczyk, Gronwald, 2022], однако для LT2 надёжного порогового значения не предложено. Существующие мультимодальные работы, как правило, объединяют два канала: NIRS + ЭМГ (метод ATHHb-ЭМГ Попова), NIRS + вентиляция (Coquart, Mucci, 2017) или HRV + нагрузка (Rogers, Gronwald, 2022). Системы, объединяющие все три сигнальных модальности – ЭМГ, NIRS и HRV – для одновременного предсказания обоих порогов в скользящем окне реального времени, в доступной рецензированной литературе отсутствуют.

Критический анализ применения ML в спортивной науке, проведённый Rodu и соавторами [Rodu и др., 2024], подчёркивает, что supervised ML должен дополнять, а не заменять гипотетико-дедуктивный подход: алгоритмы хорошо предсказывают численный результат, но сами по себе не объясняют, какие

физиологические механизмы за ним стоят. Поэтому без связи с предметным знанием модель может обнаружить статистическую закономерность, которую нельзя уверенно интерпретировать как реальный механизм аэробно-анаэробного перехода. Авторы рассматривают три кейс-стади и обосновывают необходимость explainable ML – SHAP-анализа, интерпретируемых деревьев, локальных surrogate-моделей – как средства снижения риска артефактных выводов. Для настоящей диссертации это служит обоснованием обязательного сочетания SHAP-анализа значимости признаков с физиологической интерпретацией результатов: ML-модель не самодостаточна, и её предсказания подлежат проверке стандартными методами и согласованию с устоявшимися механистическими представлениями о порогах.

1.6.2 ML для временных рядов: LSTM, TCN и вейвлетные сети

Классический ML на ручных признаках предполагает структурную потерю временной зависимости сигнала: операция скользящего окна агрегирует множество отсчётов в один скалярный вектор признаков Под скользящим окном здесь понимается разбиение непрерывного сигнала на короткие временные фрагменты, каждый из которых затем сводится к фиксированному набору числовых признаков., и последовательные зависимости между окнами разрушаются на этапе подачи в модель. Random Forest, XGBoost и аналогичные ансамблевые методы получают на вход разрозненные точки в признаковом пространстве и вынуждены полагаться на инженера-исследователя в части построения признаков, отражающих темпоральную динамику (например, скользящие производные, лаговые признаки, оценки наклона). Альтернативный класс моделей – нейронные сети для временных рядов (LSTM, GRU, TCN) – сохраняет последовательную структуру сигнала на уровне архитектуры и способен обучаться на временной эволюции состояния системы как таковой. Для задачи онлайн-детекции аэробно-анаэробного перехода это архитектурное преимущество принципиально: переход – событие, определяемое не моментальным

значением сигнала, а характером его эволюции на временном горизонте порядка десятков секунд.

Применимость рекуррентных архитектур к физиологическим временным рядам убедительно продемонстрирована Zeng и соавторами [Zeng и др., 2022] на крупномасштабном медицинском датасете: на выборке из 8599 пациентов на ИВЛ с 89 признаками LSTM достиг AUROC=0,828, GRU – 0,829 (статистически неотличимо), при этом обе RNN-модели превзошли Random Forest (0,820) и XGBoost. Принципиально важным архитектурным свойством, отмеченным авторами, является то, что RNN обновляет предсказание вместе с поступлением каждого нового временного шага, тогда как ансамбль на ручных признаках выдаёт оценку только в конце окна. Это свойство прямо соответствует задаче онлайн-детекции порога в скользящем окне ступенчатого теста: с каждой новой секундой модель уточняет вероятности P(LT1) и P(LT2) на основе обновлённой истории. Дополнительный вывод исследования – облегчённая RNN-модель на 26 отобранных признаках была сопоставима с полной версией на всех 89 признаках – показывает перспективность совместного применения отбора признаков и RNN-архитектур, что особенно актуально при ограниченных размерах датасета.

Прямую демонстрацию того, что глубокая нейронная сеть способна предсказывать вентиляционный порог по одному физиологическому сигналу, привели Miura и соавторы [Miura и др., 2020]. На выборке из 260 пациентов с сердечно-сосудистыми заболеваниями, проходивших CPET-тестирование, авторы обучили CNN на одноканальном ЭКГ (1000 Гц) и получили r=0,875 ($p<0{,}001$) между предсказанным и измеренным VT в тестовой когорте; смещение по Bland–Altman составило −0,05 мл·кг$^{-1}$·мин$^{-1}$ (незначимо). Корреляция выше 0,7 сохранялась во всех субгруппах по полу, возрасту и диагнозу – модель обобщалась на гетерогенную популяцию. Принципиальное значение этой работы заключается в демонстрации применимости глубокого обучения для воспроизведения экспертной газоаналитической метки порога;

ограничения – отличие популяции пациентов с ССЗ от здоровых тренированных спортсменов и одноканальная природа входа, уступающая мультимодальному стеку по информативности.

Альтернативой LSTM/GRU при предсказании метаболических переменных в реальном времени служат темпоральные свёрточные сети (TCN), основанные на каузальных свёртках с расширяющимися дилатациями. Здесь каузальные свёртки означают, что модель в каждый момент использует только текущее и прошлые значения сигнала, не заглядывая в будущее, а расширяющиеся дилатации позволяют охватывать всё более длинную историю без резкого роста числа параметров. Amelard и соавторы [Amelard и др., 2021] реализовали TCN-архитектуру для посекундного предсказания VO_2 из четырёх сигналов умной рубашки (ЧСС, резерв ЧСС, частота дыхания, минутная вентиляция) и мощности нагрузки у 22 участников на велоэргометре. Авторами было установлено, что оптимальная длина истории составляет 218 секунд, а при 187, 97 и 76 секундах отклонение модели от лучшей конфигурации не превышало 3% – TCN устойчива к выбору длины рецептивного поля. Точность модели достигла −22 мл/мин (95% CI [−262, 218]) по всем диапазонам интенсивности; классификация интенсивности (vigorous/moderate/light) на основе предсказанного VO_2 – 94,1%. Прямое сравнение показало превосходство TCN над LSTM и Random Forest. Для задачи онлайн-детекции порога TCN обладает несколькими операционными преимуществами по сравнению с LSTM: параллельное обучение (быстрее за счёт отсутствия последовательных рекуррентных шагов), управляемое рецептивное поле (длина истории задаётся явно через дилатации), стабильный инференс без проблем затухающих градиентов. Классификация интенсивности по предсказанному VO_2 непосредственно параллельна задаче настоящей работы, в которой выходом модели является вероятность нахождения в зоне ниже LT1, между LT1 и LT2 либо выше LT2.

Концептуальный мост между сигнальной обработкой и глубоким обучением представляют вейвлетные нейронные сети (wavelet CNN). В этих архитектурах первый слой реализует обучаемое вейвлет-преобразование: фильтры, инициализированные как фиксированный базис (например, db6), оптимизируются вместе с остальными параметрами сети под задачу. Тем самым, модель самостоятельно подбирает оптимальный частотный базис для конкретной классификационной или регрессионной задачи, что устраняет произвольность выбора базиса в классической DWT-предобработке. Tsinganos и соавторы [Tsinganos и др., 2020] хотя и не применяли wavelet CNN в чистом виде, использовали wavelet decomposition как технику аугментации при обучении CNN на ЭМГ и получили прирост точности до +16% – что косвенно подтверждает эффективность вейвлетных представлений в архитектурах глубокого обучения. При многоканальной записи (например, четыре канала ЭМГ Delsys Trigno на VL и четыре канала на RF) двумерная свёртка по пространству электродов и времени способна выучивать совместные пространственно-временные паттерны активации, что представляет потенциальное расширение настоящего исследования.

При ограниченном объёме выборки глубокие архитектуры (LSTM, TCN) несут более высокий риск переобучения, чем ансамблевые методы на ручных признаках; Amelard и соавторы [Amelard и др., 2021] успешно применили TCN при n=22, однако их входные данные включали метаболические сигналы (минутная вентиляция, дыхательный объём), недоступные в полевых условиях настоящего исследования. Сбалансированный выбор архитектуры, таким образом, определяется размером датасета, доступностью входных каналов и интерпретационными требованиями: для основного результата диссертации представляется обоснованным использование базовых моделей RF/XGBoost на ручных признаках с SHAP-анализом, тогда как TCN рассматривается как направление расширенного эксперимента, предполагающего возможное последующее увеличение выборки.

1.6.3 Обучение при малых датасетах и стратегии валидации

В спортивной физиологии большинство исследований ограничены 10–40 субъектами вследствие трудоёмкости протоколов нагрузочного тестирования, инвазивного характера лактатного анализа и стоимости специализированного оборудования (метаболические анализаторы, многоканальные ЭМГ-системы, NIRS). Настоящее исследование включает n=19 испытуемых, что находится в характерном для области диапазоне. При малом числе испытуемых и большом числе извлекаемых признаков возрастает риск переобучения модели на особенностях конкретной выборки; поэтому особое значение приобретают выбор архитектуры, схема валидации и допустимые способы расширения обучающего набора.

При оценке обобщающей способности модели при малых n обычная k-fold кросс-валидация приводит к утечке данных: временные сегменты одного субъекта могут одновременно оказаться в обучающей и тестовой подвыборках, что искусственно завышает оцениваемое качество. В этом случае тестовая подвыборка уже не является независимой: модель может опираться на индивидуальные особенности сигнала того же испытуемого, а не демонстрировать переносимость на нового человека. Единственный корректный метод оценки обобщаемости на новых субъектах в данном контексте – Leave-One-Subject-Out (LOSO): на каждой итерации модель обучается на n−1 субъектах и тестируется на одном оставленном. Rodu и соавторы [Rodu и др., 2024] прямо подчёркивают, что невалидированные ML-результаты в спортивной науке нередко отражают «запоминание» обучающей выборки, а не реальную предсказательную силу, и требуют осторожной интерпретации. При n=19 LOSO обеспечивает 19 независимых тестовых оценок, что достаточно для статистически интерпретируемой агрегированной метрики и для построения доверительных интервалов с использованием bootstrap или непараметрических методов.

Стратегии аугментации обучающих данных, то есть искусственного создания дополнительных вариантов уже записанных сигналов, позволяют отчасти компенсировать малый размер выборки. Tsinganos и соавторы [Tsinganos и др., 2020] систематически оценили техники аугментации ЭМГ и установили, что методы структурной модификации сигнала – плавная деформация амплитуды во времени (magnitude warping) и вейвлетное разложение (wavelet decomposition) – обеспечивают прирост точности классификации до +16% на двух эталонных датасетах, тогда как простое аддитивное зашумление и использование перекрывающихся окон дают значительно меньший выигрыш. Принципиальным методологическим ограничением является то, что аугментация выполняется в пределах одного субъекта обучающей выборки: синтетические сэмплы наследуют индивидуальные паттерны и не вносят новой межсубъектной вариабельности. Из этого следует, что аугментация не отменяет необходимости LOSO-валидации – напротив, она применима только к тренировочному фолду, тогда как тестовый фолд (оставляемый субъект) во избежание утечки сигнала всегда остаётся нетронутым.

Выбор класса модели при ограниченных данных подчиняется компромиссу между выразительностью и риском переобучения. При $n<50$ субъектов ансамблевые методы (Random Forest, XGBoost, LightGBM) в качестве основной модели обычно предпочтительнее глубоких нейронных сетей: меньшее число параметров снижает риск переобучения, а древовидная структура обеспечивает интерпретируемость через SHAP-анализ. Дополнительным преимуществом являются низкие вычислительные затраты обучения и инференса, что существенно для онлайн-применения. Tomaszewski и Majorczyk [2024] достигли $R^2=0{,}803$ для предсказания AnT с помощью LightGBM на 183 субъектах, и аналогичные результаты с RF/XGBoost на меньших выборках задокументированы в смежных работах [Tomaszewski, Majorczyk, 2024]. Параллельно Zeng и соавторы [Zeng и др., 2022] показали, что облегчённая RNN-модель на 26 отобранных признаках сопоставима с

полной версией на всех 89 признаках; это подчёркивает важность предварительного отбора информативных признаков при ограниченных данных. Rodu и соавторы [Rodu и др., 2024] рекомендуют начинать ML-исследование в спорте с интерпретируемых моделей и переходить к более сложным только при доказанной нехватке выразительной способности у базовых моделей.

Специфических рекомендаций по комбинированным стратегиям аугментации (в том числе вейвлетной) и валидации (LOSO) для задачи детекции лактатного порога по мультимодальным сигналам ЭМГ + NIRS + HRV при ограниченном объёме выборки в литературе не представлено. Настоящая работа является одной из первых, системно применяющих LOSO-валидацию совместно с вейвлетной аугментацией ЭМГ в физиологическом контексте предсказания обоих порогов аэробно-анаэробного перехода у тренированных триатлонистов.

1.6.4 Gap: мультимодальные онлайн-системы

В существующей литературе не представлено ни одной системы, одновременно объединяющей поверхностную электромиографию (ЭМГ), мышечную ближнюю инфракрасную спектроскопию (NIRS) и вариабельность сердечного ритма, представленную показателем DFA-α1, в единый алгоритм онлайн-предсказания обоих порогов – LT1 и LT2 – в скользящем окне в ходе ступенчатого нагрузочного теста. Прямым подтверждением этого разрыва служит работа Wireless Multi-Layered EMG/MMG/NIRS Sensor for Muscular Activity Evaluation [Kimoto и др., 2023], в которой описан беспроводной многослойный датчик, объединяющий ЭМГ, механомиограмму (MMG) и NIRS на одной точке *m. vastus lateralis* при велоэргометрии: авторы прямо констатируют в абстракте, что детекция анаэробного порога по комбинированным мультисенсорным данным «явно не решена» – техническая платформа существует, тогда как алгоритм онлайн-детекции порога по такого рода

мультимодальным сигналам остаётся открытой задачей. Именно это отсутствие определяет актуальность и новизну настоящей диссертационной работы.

1.7 Физиологические особенности триатлонистов при велоэргометрическом тестировании

Триатлонисты представляют собой популяцию с высокой аэробной ёмкостью, тренирующую три вида на выносливость и располагающую хорошо развитыми центральными и периферическими механизмами адаптации к нагрузке. Разнородность выборки (любители + профессионалы) обеспечивает широкий диапазон физиологических параметров, что принципиально важно для обучения ML-модели: модель должна быть инвариантна к абсолютным значениям мощности на пороге и работать с нормализованными признаками.

Согласно доменным характеристикам популяции данного исследования, для любителей-триатлонистов типичны значения VT1 в диапазоне 150–220 Вт и VT2 – 200–280 Вт при велоэргометрии, тогда как профессионалы демонстрируют VT1 220–300 Вт и VT2 290–380 Вт. Референсные нормы мощности на LT2 для популяции, разработанные Fiedler и Woll [2025] на базе репрезентативного немецкого исследования DEGS1, подтверждают выраженную зависимость порога от тренировочного статуса и пола. Метаболическая модель Fischer и Hävecker [2025] показывает, что VO_2peak вносит наибольший вклад в мощность на LT2 (62–67% R^2), что согласуется с общей физиологией: чем выше аэробная ёмкость, тем при более высокой абсолютной мощности наступает порог.

Стандартизация ступенчатых протоколов критична для воспроизводимости лактатного теста. Для тренированных спортсменов рекомендованы ступени мощностью 20–30 Вт с длительностью 3–5 минут: при более коротких ступенях не достигается квазистационарное состояние метаболизма, что смещает лактатный порог в сторону завышения [Kominami, Nishijima, 2015]. В протоколе данной диссертации используются ступени +30

Вт / 3 мин, начиная с 60 Вт, с забором лактата за 15 секунд до начала каждой новой ступени. Schaffarczyk и Rogers [2022] применяли эквивалентный протокол для DFA-α1 в популяции триатлонистов, что делает данные работы непосредственно применимыми к нашей выборке.

Выбор триатлонистов как целевой популяции методологически обоснован по нескольким причинам. Во-первых, это спортсмены с детально разработанными тренировочными зонами, для которых точное определение порогов является инструментом ежедневного управления нагрузкой. Во-вторых, периодическое тестирование на велоэргометре является стандартным компонентом их подготовки, что обеспечивает мотивацию и соответствие протоколу. В-третьих, разнородность выборки (любители + профессионалы) формирует широкий диапазон лактатных профилей, необходимый для обобщения ML-модели. В-четвёртых, велоэргометрия с изолированной нагрузкой на нижние конечности обеспечивает минимальный межмышечный лактатный шаттлинг, что повышает точность и согласованность системного лактата как метки порога.

Несмотря на физиологическую обоснованность выбора популяции, в литературе отсутствуют работы, в которых одновременная регистрация ЭМГ, NIRS и RR применялась бы для изучения неинвазивных маркеров порога именно у триатлонистов в условиях стандартного ступенчатого теста.

1.8 Заключение по обзору литературы

Проведённый обзор литературы позволяет систематизировать текущее состояние знаний по проблеме неинвазивного определения аэробно-анаэробного перехода и выявить ключевой разрыв между имеющимися методами и практической потребностью. Физиологические механизмы двух порогов (VT1/LT1 и VT2/LT2) детально изучены: они связаны с кинетикой лактата, рекрутированием двигательных единиц, кислородным балансом в мышце и вегетативными сдвигами. Каждый из рассмотренных сигнальных каналов – ЭМГ, NIRS и HRV – демонстрирует достоверную информативность

в отношении отдельных аспектов перехода: ЭМГ отражает рекрутирование быстрых ДЕ, NIRS – локальный кислородный дефицит, DFA-α1 – вегетативные сдвиги, ассоциированные с VT1; при этом HRV-пороги дополнительно валидированы крупномасштабным мета-анализом [Tanner и др., 2024], что делает их одним из наиболее обоснованных неинвазивных суррогатов лактатных и вентиляционных порогов.

Вместе с тем анализ литературы выявил несколько принципиальных ограничений существующих подходов. Первое: существующие алгоритмы детекции порога по отдельным каналам (Dmax/mDmax по StO_2, V-slope по nHHb–nEMG, пороговое значение DFA-α1=0,75) разработаны для постфактум-анализа или для одиночного канала, но не для онлайн-предсказания в скользящем окне. Второе: из рассмотренных работ ни одна не объединяет три сигнальных модальности (ЭМГ + NIRS + HRV) в единую систему – даже в работах с многослойными датчиками алгоритм мультимодальной онлайн-детекции порога остаётся, по прямому признанию авторов, нерешённой задачей [Kimoto и др., 2023]. Третье: детекция второго порога (LT2) по неинвазивным сигналам – принципиально более сложная задача, почти не решавшаяся методами ML. Четвёртое: фазовая структура педального цикла (push/pull), доступная через гироскоп датчика Delsys Trigno, не использовалась в качестве источника признаков ни в одной из найденных работ. Пятое: при характерных для области ограниченных размерах выборок комбинированные стратегии вейвлетной аугментации ЭМГ-сигнала [Tsinganos и др., 2020] и LOSO-валидации систематически не применялись в задаче детекции порогов.

Центральный *gap* данного исследования формулируется следующим образом: в мировой литературе отсутствует системная методология онлайн-предсказания обоих порогов аэробно-анаэробного перехода (LT1 и LT2) по мультимодальным неинвазивным сигналам работающей мышцы – электромиографии (включая её вейвлетные представления), ближней

инфракрасной спектроскопии и кардиальной вариабельности – в скользящем окне в ходе стандартного ступенчатого велоэргометрического теста у тренированных спортсменов на выносливость.

Настоящая диссертационная работа непосредственно закрывает этот разрыв: предлагается пайплайн, объединяющий признаки ЭМГ *m. vastus lateralis* (дистальная и проксимальная зоны; классические амплитудно-частотные индексы, вейвлетные признаки и разбивка на load- и rest-фазы по гироскопу), SmO_2 и ΔHHb по NIRS на VL, а также DFA-α1 по RR-интервалам в единую ML-модель для оценки времени до порогов LT1 и LT2 в режиме реального времени. Верификация проводится на выборке из 18 испытуемых с лактатным анализом как gold standard и breakpoint SmO_2 как вспомогательным маркером, с использованием LOSO-валидации и вейвлетной аугментации обучающего фолда. В следующем разделе подробно описываются материалы, методы сбора данных, алгоритмы предобработки и архитектура модели.

2 МАТЕРИАЛЫ И МЕТОДЫ

2.1 Участники исследования

В исследование включены 18 испытуемых (11 мужчин, 7 женщин) с различным уровнем физической подготовки – от людей, регулярно занимающихся в тренажёрных залах, до спортсменов, систематически тренирующихся в циклических видах спорта на выносливость. Критерии включения: регулярные физические тренировки объёмом не менее трёх часов в неделю, отсутствие травм опорно-двигательного аппарата в течение последних трёх месяцев, отсутствие сердечно-сосудистых противопоказаний к максимальным нагрузочным тестам. Все участники подписали форму добровольного информированного согласия. Характеристики выборки приведены в таблице 1.

Разброс времени достижения LT2 составил от 10 до 25 минут от начала основного теста, что отражает широкий диапазон аэробных возможностей участников. Гетерогенность выборки является методологическим преимуществом: ML-модель, обученная в таких условиях, вынуждена опираться на паттерны изменения сигналов, инвариантные к абсолютному уровню нагрузки, что повышает её обобщаемость на новых испытуемых.

Таблица 1. Характеристики участников исследования.

Параметр	M ± SD	Min–Max
Возраст, лет	33,1 ± 7,5	22–43
Рост, см	171,5 ± 8,8	151–183
Масса тела, кг	71,2 ± 14,8	45–104
ИМТ, кг/м²	24,0 ± 3,2	19–32
Время достижения LT2, мин	14,8 ± 4,7	10,1–25,1
Время достижения LT1, мин	8,8 ± 3,3	5,6–16,1

2.2 Протокол нагрузочного тестирования

Тестирование проводилось на велоэргометре Lode Excalibur Sport с электромагнитным управлением нагрузкой, обеспечивающим воспроизводимость мощности независимо от каденса. Использовался ступенчатый протокол с нарастающей нагрузкой: первая ступень составляла 30 Вт (1 мин) для разминки и стабилизации сигналов датчиков; начиная с 60

Вт мощность увеличивалась на 30 Вт каждые 3 мин до достижения волевого отказа испытуемого. Испытуемым давалась установка педалировать с фиксированным каденсом в диапазоне 65-80 об/мин. Критерием остановки служила невозможность поддерживать фиксированный каденс. После остановки следовал период восстановления 2–4 мин при 60-100 Вт, который также фиксировался системой сбора. Последовательность ступеней мощности в программе сбора данных соответствовала предустановленной программе велоэргометра, что обеспечивало соответствие между мощностью нагрузки и временной разметкой в файле записи.

За 15 сек до начала каждой новой ступени выполнялся забор капиллярной крови из пальца для определения концентрации лактата. Анализ проводился на портативном биохимическом анализаторе Biosen C-line с диапазоном измерения 0,5–40,0 ммоль/л и погрешностью измерения менее 2%. Результаты лактатного анализа вносились в файл HDF5 отдельным каналом по завершении теста.

2.3 Аппаратный комплекс регистрации

2.3.1 Электромиография и инерционные измерения

Поверхностная ЭМГ регистрировалась с m. vastus lateralis (VL) доминантной ноги двумя датчиками (в дистальной и проксимальной зонах мышцы) при помощи беспроводных датчиков Delsys Trigno Avanti. Каждый датчик представляет собой сдвоенный биполярный электрод с межэлектродным расстоянием 10 мм и встроенным трёхосевым акселерометром и гироскопом. Частота дискретизации ЭМГ-канала составляла 1926 Гц, гироскопического канала – 148 Гц. Датчики устанавливались по стандартным анатомическим ориентирам SENIAM: дистальный – на 2/3 расстояния от передней верхней ости подвздошной кости до верхнего края надколенника, проксимальный – на 1/3 того же расстояния, оба с наклоном в направлении волокон мышцы. Датчики фиксировались на контактные патчи, поверх накладывался фиксирующий пластырь Hartmann Omnifix. Кожа в зоне установки датчиков предварительно обрабатывалась

спиртовой салфеткой и очищалась марлевой для снижения импеданса контакта. Соединение с системой сбора данных осуществлялось через протокол TCP посредством подключения к Trigno Control Utility (TCU) – фирменному серверному приложению, транслирующему бинарный поток данных с датчиков по выделенному data-порту. Сигнал ЭМГ, поступающий от TCU, не содержит нумерации пакетов, поэтому восстановление временной оси при разрывах соединения производилось путём повторной синхронизации с внутренней шиной времени системы с последующим восстановлением временных меток по дельте от частоты дискретизации.

2.3.2 Ближняя инфракрасная спектроскопия

Мышечная оксигенация регистрировалась датчиком Train.Red PLUS, основанным на принципе непрерывной волновой ближней инфракрасной спектроскопии (cwNIRS). Датчик фиксировался над серединой брюшка m. vastus lateralis той же ноги, что и ЭМГ-датчики, при помощи штатного ремешка устройства. В ходе теста по протоколу ANT+ принимался только сигнал SmO_2 с частотой около 1–4 Гц – единственная переменная, транслируемая устройством в режиме реального времени. После завершения теста производилась выгрузка сессии из вендорского приложения Train.Red, содержащая полный набор каналов: SmO_2 (фильтрованный и нефильтрованный), O_2Hb, HHb, THb, HBDiff (O_2Hb − HHb). Временная привязка вендорской выгрузки производилась по совпадению канала SmO_2 с ANT+-рядом; после выравнивания все каналы объединялись в единый HDF5-файл вместе с ЭМГ и RR-интервалами.

2.3.3 Сердечный ритм

RR-интервалы регистрировались биосенсорным поясом Zephyr BioHarness 3 (Medtronic, США), передающим данные по Bluetooth Low Energy согласно официально опубликованному производителем протоколу пакетной передачи. Система принимала бинарные пакеты фиксированной структуры, из которых извлекались последовательности RR-интервалов в миллисекундах. Поскольку RR-интервалы представляют собой событийный ряд, а не

равноинтервальную дискретизацию, временная ось для данного канала накапливалась суммированием последовательных интервалов. При обнаружении разрыва последовательности нумерации пакетов временная ось синхронизировалась с внутренней шиной системы и продолжалась от точки восстановления.

2.4 Система синхронного сбора данных Sensync

2.4.1 Архитектура и мотивация

Для синхронной регистрации сигналов с разнородных источников разработана оригинальная программная система Sensync. Необходимость собственной разработки обусловлена отсутствием готовых решений, обеспечивающих одновременную запись разночастотных потоков (1926 Гц, 148 Гц, 3–4 Гц, событийный RR) в единый файл с общей временной осью и возможностью последующего воспроизведения и анализа в том же программном окружении.

Система прошла четыре крупные итерации разработки. На первом этапе реализовано приложение на Python с управляющим циклом трёх фаз (сбор с адаптеров, обработка, визуализация в Matplotlib). Ограниченные возможности управления привели к добавлению GUI-оболочки на Flet с сохранением Python-ядра. На третьем этапе визуализация была вынесена в отдельное React-приложение с обменом через Protocol Buffers, однако производительность такого решения оказалась недостаточной для высокочастотных потоков ЭМГ. На четвёртом этапе принято решение о полном переходе на платформу Node.js / Electron / React с отказом от управляющего цикла в пользу событийно-ориентированной (event-driven) архитектуры. Ключевым мотивом последней итерации стал опыт работы с частично потерянными и несинхронизованными данными, собранными на предыдущем оборудовании, – это показало критичность единой временной модели для корректного совмещения разночастотных каналов.

2.4.2 Реализация

Sensync реализована как модульное десктопное приложение на

платформе Electron (см. таблицу 2). Каждый источник данных инкапсулирован в изолированном плагине, выполняемом в отдельном потоке (worker_thread), что обеспечивает независимость обработки каналов и задействование нескольких процессорных ядер. Взаимодействие между плагинами осуществляется через внутреннюю событийную шину без прямых вызовов между модулями. Конфигурация набора активных плагинов и их взаимодействий задаётся профилем запуска, что позволяет переключаться между экспериментальными сценариями без изменения кода.

Таблица 2. Технологический стек sensync.

Компонент	**Технология**
Платформа	Electron (Node.js 20, TypeScript)
Пользовательский интерфейс	React 19, ECharts
Многопоточность	worker_threads (Node.js)
Формат хранения данных	HDF5 (библиотека h5wasm)
Подключение Delsys Trigno	TCP-сокет к Trigno Control Utility
Подключение Train.Red PLUS	ANT+ (библиотека ant-plus)
Подключение Zephyr BioHarness	BLE (библиотека @abandonware/noble)
Обмен с вычислительными воркерами	Protocol Buffers
Вычислительные алгоритмы (ЭМГ)	Python compute-worker

Временная модель системы опирается на внутреннюю шину сессионного времени, отсчитываемого от момента старта записи; абсолютное время начала протокола сохраняется в метаданных. Это позволяет корректно обрабатывать разрывы соединения и обеспечивает воспроизводимость временных отношений между каналами при последующем анализе.

Данные всех каналов записываются в единый файл формата HDF5: каждый источник формирует отдельный набор данных (dataset) в иерархической структуре файла и буферизирует записи независимо батчами. Формат HDF5 обеспечивает эффективное хранение разнородных временных рядов, поддерживает произвольный доступ к сегментам данных и допускает хранение метаданных непосредственно в том же файле. Данные лактата вносятся в тот же файл отдельным каналом по завершении теста.

2.5 Предобработка сигналов

2.5.1 Электромиография

Сырой ЭМГ-сигнал (1926 Гц) подвергался следующей предобработке.

Полосовая фильтрация: фильтр Баттерворта 4-го порядка, полоса пропускания 20–450 Гц. Режекторный (notch) фильтр: 50 Гц для подавления помехи промышленной сети. Вычисление огибающей: скользящее RMS в окне 250 мс. Нормализация: значения ЭМГ нормировались относительно среднего уровня на ступени 30 Вт для обеспечения межсессионной сопоставимости.

Разделение активности по фазам педалирования выполнялось на основе гироскопических данных (148 Гц): load-фаза (~0°–180° цикла) и rest-фаза (~180°–360°) определялись по пиковой угловой скорости гироскопа с использованием алгоритма детекции пиков.

2.5.2 Мышечная оксигенация

Сигналы SmO_2, HHb, HBDiff и THb из вендорской выгрузки Train.Red сглаживались скользящим средним в окне 10 сек для подавления артефактов движения. Производные $\Delta SmO_2/\Delta t$ и $\Delta HHb/\Delta t$ вычислялись как разность соседних значений соответствующего канала, делённая на временной интервал между ними. Пропущенные точки в ANT+-ряду SmO_2 (до выравнивания с вендорской выгрузкой) не интерполировались; признаки на соответствующих сегментах помечались как невалидные.

2.5.3 RR-интервалы и HRV

Перед вычислением HRV-признаков выполнялась детекция артефактов RR: интервалы, отклоняющиеся более чем на 20% от скользящей медианы в окне 5 кардиоциклов, помечались как артефакты и замещались кубической интерполяцией по соседним валидным значениям. Равноинтервальный ряд RR (с шагом 250 мс) формировался кубической интерполяцией для вычисления временны́х HRV-показателей (RMSSD, SDNN) и нелинейных показателей методами анализа Пуанкаре (SD1, SD2) и детрендированного флуктуационного анализа (DFA-α1 в окне 4–16 кардиоциклов).

2.6 Определение лактатных порогов (ground truth)

2.6.1 Определение LT1

LT1 определялся как момент первого пересечения лактатной кривой с уровнем исходный уровень + 0,4 ммоль/л, где исходный уровень – значение

лактата на первой измеренной точке (конец ступени 60 Вт). Отдельного замера в покое протокол не предусматривал; первая точка является наименьшим надёжно доступным значением лактата в сессии.

Для точного определения момента пересечения по дискретным точкам забора строилась PCHIP-интерполяция в плоскости мощность-лактат. Дискретная метка (момент забора крови на первой ступени выше порога) привязана к концу ступени и может запаздывать до 3 мин относительно реального момента пересечения порога внутри ступени. Для интерполяции выбран PCHIP, а не кубический сплайн: при редких точках (интервал 3 мин) кубический сплайн может осциллировать и давать ложные пересечения порога, тогда как PCHIP гарантирует монотонность внутри каждого интервала. Мощность в точке пересечения переводилась во время через линейную интерполяцию внутри ступени.

Целевой переменной модели служило интерполированное время LT1, выраженное как «время до LT1» – разность между временем LT1 и концом текущего скользящего окна.

2.6.2 Определение LT2

LT2 определялся методом модифицированного Dmax (ModDmax) на кубическом сплайне в плоскости мощность–лактат. Из точки первого достоверного роста лактата проводилась хорда до последней точки кривой; LT2 соответствует точке максимального перпендикулярного расстояния от кривой до этой хорды. Кубический сплайн выбран намеренно: метод Dmax является геометрическим и требует гладкой кривой с непрерывной второй производной (C^2); PCHIP гарантирует монотонность, но первая производная на стыках скачет, что искажает форму «локтя» кривой. Мощность в точке LT2 также переводилась во время через линейную интерполяцию внутри ступени. Целевой переменной модели служило время от конца скользящего окна до момента LT2 в секундах; отрицательное значение означает, что порог уже пройден.

2.7 Признаковое пространство и модальности

Признаки извлекались в скользящем окне 30 сек с шагом 5 сек. Для большинства временных моделей применялась разрежённая дискретизация — каждое шестое окно (шаг 30 с, перекрытие отсутствует) — с длиной контекста 6 или 12 мин в зависимости от архитектуры. Базовая рекуррентная модель использовала плотную нарезку: последовательность смежных окон с шагом 5 с, что соответствовало контексту порядка 75 с.

В настоящей работе используются следующие термины, которые сохраняются единообразно во всех последующих разделах:

- Модальность / набор признаков — совокупность признаков, соответствующих одному или нескольким сенсорным источникам: EMG, NIRS, HRV, EMG+NIRS, EMG+NIRS+HRV. Именно этот набор подаётся на вход модели.
- Вариант набора признаков — полный набор или вариант без абсолютных признаков. Во втором случае из входного вектора исключаются признаки, описывающие текущие средние уровни сигналов; эта ось варьирования независима от модальности.

Таким образом, сочетания «EMG+NIRS, без абсолютных признаков» и «EMG+NIRS, полный набор» соответствуют одной модальности, но двум вариантам состава признаков; сочетания «EMG+NIRS» и «HRV» представляют разные модальности независимо от выбранного варианта.

2.7.1 ЭМГ-признаки (EMG)

Признаки модальности EMG формируются из сырых сигналов поверхностной ЭМГ четырёхглавой мышцы бедра (m. vastus lateralis — дистальный и проксимальный электроды) в сочетании с кинематическими признаками педалирования. Итоговый набор содержит **~79 признаков**:

- 68 z-нормированных ЭМГ-признаков — статистики временного ряда ЭМГ (RMS, среднее, стандартное отклонение, перцентили, энтропийные и спектральные характеристики), вычисленные в пределах скользящего окна;

- 11 кинематических признаков — характеристики педального цикла: средняя каденс и её вариабельность; длительности фаз нагрузки и отдыха, их коэффициенты вариации и соотношение; трендовые показатели вариабельности за скользящее 30-секундное окно; энтропия выборки (Sample Entropy) по каждой фазе.

Z-нормировка проводилась per-subject: среднее и стандартное отклонение вычислялись по окнам первой ступени нагрузки и применялись ко всей сессии испытуемого без заглядывания вперёд (каузальность сохранена). Полный список признаков с техническими обозначениями приведён в Приложении 1.

2.7.2 NIRS-признаки

NIRS-признаки делятся на две группы. Признаки окна (15): для SmO_2, HHb, HBDiff и THb – среднее, наклон и стандартное отклонение внутри окна; для SmO_2 и HHb дополнительно производные $\Delta SmO_2/\Delta t$ и $\Delta HHb/\Delta t$; для SmO_2 – величина падения (drop) внутри окна. Накопленные признаки (3), вычисляемые от начала теста: отклонение SmO_2 от накопленного максимума, отклонение HHb от накопленного минимума, относительное падение SmO_2 от исходного базального уровня в процентах.

2.7.3 HRV-признаки

Из равноинтервального RR-ряда вычислялись временные показатели – среднее RR-интервала (mean RR), SDNN и RMSSD, отражающие общую вариабельность и короткопериодные флуктуации; нелинейные показатели анализа Пуанкаре – SD1, SD2 и их отношение SD1/SD2, характеризующие соотношение парасимпатической и симпатической составляющих; показатель детрендированного флуктуационного анализа DFA-α1 в окне 4–16 кардиоциклов, отражающий степень автокорреляции RR-ряда и используемый как маркер первого вегетативного порога.

2.7.4 Признаки взаимодействия

Эти признаки включаются только в наборе EMG+NIRS+HRV. Произведение SmO_2 и mean RR кодирует одновременное снижение мышечной

оксигенации и учащение сердечного ритма – паттерн, характерный для приближения к порогу; произведение SmO_2 и DFA-α1 отражает совместную динамику периферического метаболизма и вегетативной регуляции, оба из которых демонстрируют точку перелома вблизи LT2; отношение mean RR к текущей мощности нормирует вегетативный ответ на нагрузку, позволяя модели учитывать индивидуальную кардиальную эффективность.

2.7.5 Комбинации признаков

Тестировались пять комбинаций модальностей (см. таблицу 3). Обоснование: выявить минимально достаточный набор сенсоров, обеспечивающий точность, сопоставимую с полным мультимодальным набором.

Таблица 3. Комбинации модальностей

Набор	Состав	Число признаков
EMG	ЭМГ (z-норм.) + кинематика педалирования	~79
NIRS	Оконные + кумулятивные признаки NIRS	18
HRV	7 признаков ВСР из RR-интервалов	7
EMG+NIRS	EMG ∪ NIRS	~97
EMG+NIRS+HRV	EMG ∪ NIRS ∪ HRV ∪ взаимодействия	~107

2.7.6 Варианты комбинаций

Помимо полного набора параметров в каждой модальности анализировался вариант без признаков, представляющих абсолютные уровни сигналов в текущем окне: средних значений SmO_2, HHb, HbDiff и THb за окно, среднего RR-интервала, а также их перекрёстного признака (SmO_2 × среднее RR). Полный список технических обозначений этих признаков приведён в Приложении 1. Исходная гипотеза состояла в том, что модель, обученная исключительно на динамических признаках, не уступает модели, включающей абсолютные уровни. Подтверждение этой гипотезы имело бы практическое значение, поскольку снижало бы зависимость метода от индивидуальной базальной калибровки.

2.7.7 Базальные физиологические показатели

На калибровочной ступени нагрузки рассчитывались базальные физиологические показатели испытуемого: исходные характеристики

сердечного ритма, мышечной оксигенации и мышечной активности. В настоящей версии методики эти величины рассматриваются как вспомогательные индивидуальные характеристики и не входят в основной блок сравнения моделей, описанный в разделе 2.8.

- **Антропометрия и состав тела**: возраст, рост, масса тела, ИМТ, процент жировой массы, угол фазы биоимпеданса;
- **Базальные физиологические показатели** (калибровочная ступень 30 Вт): средняя ЧСС, RMSSD, ЭМГ-активность дистального и проксимального электродов, мышечная оксигенация SmO_2.

Эти признаки не входят в основное признаковое пространство модели предсказания и не создают утечки данных, поскольку относятся к дотестовому периоду и не содержат информации о целевой переменной.

2.8 Модели машинного обучения

2.8.1 Постановка задачи

Предсказание аэробно-анаэробного перехода формулируется как задача регрессии: по набору физиологических признаков, извлечённых из текущего скользящего окна сигналов, предсказывается оставшееся время (в секундах) до наступления соответствующего лактатного порога

В работе рассматриваются два независимых целевых показателя (таргета):

- **time_to_LT1** — оставшееся время (с) до первого лактатного порога (аэробный порог, LT1);
- **time_to_LT2** — оставшееся время (с) до второго лактатного порога (анаэробный порог, LT2).

Каждый таргет рассматривается как самостоятельная подзадача: обучение, отбор гиперпараметров и оценка качества производятся раздельно. Это обусловлено различием физиологических механизмов, определяющих LT1 и LT2, что влечёт различия в информативности модальностей признаков

и в структуре предсказательной ошибки.

2.8.2 Формальная постановка

Пусть $\boldsymbol{x}_t \in \mathbb{R}^p$ — вектор из p признаков, вычисленных по каузальному скользящему окну сигналов, завершающемуся в момент времени t. Каузальность означает, что при формировании признаков используются только отсчёты сигналов из интервала $[t - W, t]$, где W — ширина окна; заглядывание вперёд по времени исключено. Параметры нарезки окон и их шаг описаны в разделе 2.7.

Целевая переменная — оставшееся время до порога в секундах. По физиологическому смыслу эта величина монотонно убывает с ходом теста: чем позже момент t, тем меньше y(t) при условии непрерывного роста нагрузки. Это свойство учитывается при интерпретации оконных предсказаний и их последующей агрегации на уровне испытуемого.

Задача машинного обучения состоит в построении функции

$$\hat{y}_t^{(\mathrm{LT})} = f\left(\boldsymbol{x}_t;\, \hat{\theta}\right),$$

параметры которой $\hat{\theta}$ оцениваются на обучающей выборке и обобщаются на новых испытуемых. Критерий качества — средняя абсолютная ошибка (MAE, в минутах; обоснование перевода единиц — в разделе 2.9.1).

2.8.3 Формирование обучающей выборки

Для таргета LT2 в обучающую выборку включались окна с валидной разметкой времени до порога и при наличии сигналов достаточного качества во всех модальностях одновременно. Для таргета LT1 дополнительно использовался признак пригодности окна, формируемый на этапе разметки датасета.

После фильтрации датасет содержит 4 130 окон для LT1 и 3 651 окно для LT2, распределённых по 18 испытуемым.

Калибровочная ступень нагрузки (30 Вт) исключена из обучающих окон: её отсчёты используются только для вычисления базальных физиологических параметров и контроля нормировки, но не подаются в модели как целевые

обучающие примеры. Включение этой ступени в обучающий набор создало бы методологическую утечку, поскольку целевая переменная time_to_LT на ней не определена, а характеристики сигнала на 30 Вт систематически отличаются от рабочих ступеней теста.

2.8.4 Методология широкого перебора

При малом числе испытуемых (n = 18) в актуальной версии методики применялся унифицированный систематический перебор конфигураций, охватывающий три семейства моделей: линейные модели, рекуррентные сети и временные свёрточные сети. Семейство линейных моделей включает 29 классических конфигураций на основе Ridge, HuberRegressor, ElasticNet, GradientBoostingRegressor и SVR; семейство LSTM включает 16 архитектур; семейство TCN — 4 причинные архитектуры.

Для линейного семейства перебиралось полное декартово произведение двух таргетов (LT1, LT2), пяти наборов признаков (EMG, NIRS, HRV, EMG+NIRS, EMG+NIRS+HRV) и двух вариантов состава признаков (полный набор и вариант без абсолютных признаков), что даёт 580 конфигураций. Для LSTM и TCN использовалось произведение двух таргетов, четырех наборов признаков (EMG, HRV, EMG+NIRS, EMG+NIRS+HRV) и тех же двух вариантов состава признаков; модальность NIRS отдельно в нейросетевые модели не подавалась.

2.8.5 Схема валидации

В качестве единственной схемы валидации во всех экспериментах применялась стратегия Leave-One-Subject-Out (LOSO). Суть метода: на каждой итерации один испытуемый целиком выносится в тестовое множество, остальные 17 формируют обучающее множество; процедура повторяется для каждого из 18 испытуемых.

Внутреннее разбиение обучающей части LOSO-фолда на обучающую и валидационную подвыборки не использовалось: все 17 оставшихся испытуемых формировали обучающее множество, а оценка обобщающей способности выполнялась только на вынесенном тестовом субъекте. Для

линейных моделей это означает однократное обучение на каждом фолде с сохранением параметров модели и тестовых предсказаний.

Для нейросетевых моделей обучение проводилось в течение фиксированного числа эпох. Поскольку при малом объёме выборки выделение отдельной валидационной подвыборки в рамках схемы LOSO приводило бы к дополнительной потере обучающих данных, итоговый анализ выполнялся по предсказаниям, полученным на последней эпохе обучения.

2.8.6 Линейное семейство моделей

Линейное семейство реализует набор классических регрессионных моделей библиотеки scikit-learn. Для каждой комбинации «набор признаков × вариант состава признаков × таргет» перебирались конфигурации из таблицы 4; каждая конфигурация обучалась как самостоятельная модель и далее включалась в единое итоговое сравнение.

Таблица 4 Конфигурации линейного семейства

Алгоритм	**Гиперпараметры**
Ridge	$\alpha \in \{1, 10, 100, 1000\}$
HuberRegressor	$\varepsilon \in \{1{,}1; 1{,}35; 1{,}5; 2{,}0\}$
ElasticNet	$\alpha \in \{0{,}01; 0{,}1; 1{,}0\} \times$ l1_ratio $\in \{0{,}2; 0{,}5; 0{,}9\}$
GradientBoostingRegressor	n_estimators $\in \{50, 100, 200\} \times$ max_depth $\in \{2, 3\}$
SVR (ядро RBF)	$C \in \{1, 10, 100\} \times \varepsilon \in \{0{,}1; 1{,}0\}$

В отличие от ранних скриптов, в актуальном пайплайне линейные конфигурации не отбираются по отдельности внутри каждого LOSO-фолда. Все 29 конфигураций рассматриваются как независимые кандидаты, а их итоговое сравнение выполняется после агрегирования subject-level метрик и LT-point метрик на этапе анализа.

2.8.7 Нейросетевые семейства моделей

2.8.7.1 Рекуррентные сети

LSTM-семейство включает 16 архитектур трёх типов: модели без проброса состояния, модели с пробросом состояния и модели с механизмом внимания. Модели первого типа используют последовательности длиной 6 окон, модели с механизмом внимания — 12 окон, а модели с пробросом

состояния обрабатывают непрерывную запись целиком; для разных подтипов исследовались шаги дискретизации 30, 15 и 5 с.

Модели с пробросом состояния предназначены для моделирования длинного контекста без разрыва между соседними фрагментами сессии, тогда как модели с механизмом внимания усиливают вклад наиболее информативных участков последовательности при финальном предсказании. Для всех архитектур семейства LSTM исследовались два варианта входных данных: без вейвлет-преобразования и с дополнительными признаками, полученными методом непрерывного вейвлет-преобразования.

2.8.7.2 Сверточные сети

Семейство TCN включало четыре причинные архитектуры. PureTCN использовалась как базовая временная сверточная модель с дилатированными причинными свёртками. MediumTCN представляла собой её более ёмкую модификацию, рассчитанную на моделирование более сложных временных зависимостей. DwtTCN сочетала временную сверточную обработку с вейвлет-разложением входного сигнала. WaveNetTCN реализовывала схему каскадных дилатированных причинных свёрток, восходящую к архитектуре WaveNet.

2.8.7.3 Вейвлетные режимы и единая схема артефактов

Вейвлетное обогащение в актуальной методике не рассматривается как отдельное самостоятельное семейство моделей, а задаётся как режим архитектуры. Для части LSTM используется непрерывное вейвлет-преобразование, тогда как одна из TCN-архитектур реализует дискретную вейвлет-компоненту на уровне самой модели; тем самым влияние многомасштабного представления оценивается в рамках единой схемы обучения и валидации.

Каждый запуск, независимо от семейства, сохраняет стандартизированный набор артефактов: метаданные конфигурации, таблицу предсказаний, а для нейросетевых моделей также историю обучения и контрольные точки по эпохам. Это обеспечивает воспроизводимость дальнейшего анализа без повторного обучения модели.

2.8.8 Агрегация оконных предсказаний

Оконные предсказания переводятся в оценку времени порога на уровне испытуемого. Используются три правила агрегации: медианное правило, правило первого пересечения и устойчивое медианное правило. Тем самым итоговая оценка модели строится не только по качеству оконной регрессии, но и по качеству восстановления времени наступления порога у конкретного испытуемого.

2.8.9 Стандартизированный аналитический этап и итоговый рейтинг

После обучения всех конфигураций результаты обрабатываются в рамках отдельного воспроизводимого аналитического этапа. На этом этапе из таблиц предсказаний и параметров моделей формируются сводные показатели оконной ошибки, показатели ошибки определения самого порога, доверительные интервалы и итоговые сравнительные таблицы.

Такое разделение позволяет одинаково обрабатывать результаты линейных и нейросетевых моделей: этап обучения отвечает за корректную LOSO-валидацию и сохранение артефактов, тогда как аналитический этап выполняет выбор итогового состояния модели, агрегацию оконных предсказаний, статистические сравнения и построение сводного рейтинга.

2.9 Метрики качества

2.9.1 Две дорожки оценки качества

В работе используются две взаимодополняющие дорожки оценки качества, различающиеся уровнем, на котором измеряется ошибка. Первая дорожка оценивает точность регрессии по отдельным окнам сигнала; вторая дорожка оценивает точность восстановления самого момента порога на уровне испытуемого. Эти дорожки отвечают на разные исследовательские вопросы и поэтому не должны смешиваться в одном итоговом выводе.

- Оконная дорожка оценивает, насколько точно модель аппроксимирует остаточное время до порога в каждом отдельном окне. Пусть y_{ij} — истинное время до порога в j-м окне i-го

испытуемого, а $\hat{y}_{ij}$ — соответствующее предсказание модели. Тогда оконная ошибка определяется как $e_{ij}=\hat{y}_{ij}-y_{ij}$, а средняя абсолютная ошибка по испытуемому вычисляется по формуле $MAE_i=(1/n_i)\ \Sigma_j\ |e_{ij}|$. Аналогично рассчитываются $RMSE_i=[(1/n_i)\ \Sigma_j\ e_{ij}^2]^{1/2}$ и систематическое смещение $b_i=(1/n_i)\ \Sigma_j\ e_{ij}$. Эти показатели характеризуют качество регрессии как модели времени-до-события.

- Пороговая дорожка сворачивает все окна одного испытуемого в одну итоговую оценку времени наступления порога. Для каждого окна сначала восстанавливается абсолютное время порога $\hat{T}_{ij}=t^{end}_{ij}+\hat{y}_{ij}$, где t^{end}_{ij} — момент окончания окна. Далее для каждого испытуемого формируется одна итоговая оценка $\hat{T}_i$ по одному из трёх правил агрегации: медианному, правилу первого пересечения или устойчивому медианному правилу. После этого ошибка определяется уже на уровне одного момента порога: $E_i=|\hat{T}_i-T_i|$, где T_i — истинное время наступления порога. Эта дорожка отвечает на прикладной вопрос о том, насколько точно модель определяет сам момент LT у человека.

Практически это означает, что модель может демонстрировать хорошую оконную точность, но давать заметное смещение момента порога после свёртки по окнам, и наоборот. Поэтому для итогового ранжирования моделей в настоящей работе используется именно пороговая первичная метрика — средняя по субъектам ошибка медианного правила агрегации.

Единица измерения для всех временных ошибок — минуты: исходные значения в секундах конвертируются делением на 60 при расчёте сводных метрик и сравнительных таблиц.

2.9.2 Коэффициент детерминации R^2

R^2 оценивает долю объяснённой дисперсии, то есть, насколько модель лучше тривиального предсказателя — константы, равной среднему значению целевой переменной:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2},$$

В рамках LOSO $R^2 < 0$ на конкретном фолде означает, что модель предсказывает хуже тривиальной константы $\bar{y}$ — физиологические сигналы не дали полезной информации для данного испытуемого.

2.9.3 Ранговая корреляция Спирмена (ρ)

Коэффициент ранговой корреляции Спирмена вычислялся между предсказанными и истинными значениями по всем тестовым окнам. Этот показатель устойчив к монотонным нелинейным искажениям шкалы и особенно информативен для задачи «когда наступит порог»: высокий ρ означает, что модель правильно ранжирует окна по близости к порогу даже при систематическом смещении абсолютных значений.

2.9.4 Базовые предсказатели

Для оценки нижней границы сложности задачи использовались два тривиальных предсказателя:

- MeanPredictor — предсказывает константу, равную среднему значению целевой переменной по обучающему множеству фолда; не использует ни физиологические сигналы, ни временну́ю структуру теста. Служит абсолютной нижней границей: модель, не превосходящая MeanPredictor, не извлекает никакой полезной информации.
- FirstWindowPredictor — предсказывает для каждого окна значение целевой переменной, зафиксированное в первом окне сессии данного испытуемого. Поскольку время до порога монотонно убывает в ходе теста, первое окно несёт информацию о начальной

удалённости от порога даже без обращения к сигналам. Этот предсказатель проверяет более строгое условие: превзойти его означает, что физиологические сигналы добавляют информацию сверх одной лишь временно́й структуры нагрузочного теста.

Обе базовые линии воспроизводились в рамках LOSO совместно с основным экспериментом. Превышение точности модели над соответствующей базовой линией количественно характеризует вклад физиологических сигналов в предсказание.

2.10 Постобработка

В настоящей работе постобработка представляет собой преобразование последовательности оконных предсказаний в итоговую оценку времени порога на уровне испытуемого. На первом шаге для выбранного состояния модели строится последовательность абсолютных оценок времени порога

$\hat{T}_{ij}=t^{end}_{ij}+\hat{y}_{ij}$.

После чего применяются три правила агрегации: медианное, правило первого пересечения и устойчивое медианное правило. Первый вариант использует медиану всех оконных оценок, второй фиксирует первый момент перехода прогнозируемого времени до порога через нуль, третий опирается только на окна, лежащие в окрестности порога.

Такое представление позволяет отдельно анализировать точность оконной регрессии и точность восстановления момента наступления порога у испытуемого.

2.11 Статистический анализ и интерпретация

2.11.1 Парные сравнения моделей: критерий Уилкоксона с поправкой Бенджамини–Хохберга

Для сравнения двух конфигураций моделей применялся парный критерий знаковых рангов Уилкоксона (двусторонний). Тест строился на попарно согласованных по субъектам векторах метрик: для каждого испытуемого сравнивались значения одной и той же метрики, полученные двумя моделями на общем пересечении доступных субъектов.

При множественных попарных сравнениях использовалась поправка Бенджамини–Хохберга при уровне значимости α = 0,05. Коррекция выполнялась раздельно внутри каждой аналитической оси сравнения и для каждой метрики, что позволяло контролировать долю ложных открытий без избыточной потери мощности теста.

2.11.2 Дополнительные параметры эффекта и доверительные интервалы

Помимо критерия Уилкоксона, для тех же согласованных по субъектам выборок рассчитывались парный t-критерий, коэффициент d Коэна для парных различий, мера эффекта δ Клиффа, а также бутстреп-доверительные интервалы для разности средних..

2.11.3 Сравнения по аналитическим осям

Статистические сравнения в анализе строятся не для произвольных пар моделей, а по заранее заданным аналитическим осям, отражающим научные вопросы о структуре пайплайна.

- К обязательным осям относятся сравнения между семействами моделей, между наборами признаков внутри семейства, между полным набором и вариантом без абсолютных признаков внутри архитектуры, между вейвлетными и невейвлетными режимами внутри семейства, а также между задачами LT1 и LT2 для одного и того же класса модели.
- Дополнительно, при наличии соответствующих конфигураций, анализируются различия между рекуррентными моделями с пробросом и без проброса состояния, между моделями с механизмом внимания и без него, а также между различными шагами дискретизации внутри одной архитектуры.

Такая организация делает статистический слой воспроизводимым и избавляет от произвольного ручного выбора пар для сравнения: каждая ось соответствует отдельной методологической гипотезе о влиянии семейства модели, модальности или архитектурного режима.

2.11.4 Конформное предсказание (conformal prediction)

Точечное предсказание модели не даёт информации о его надёжности, поэтому в анализе дополнительно строятся предсказательные интервалы с гарантированным покрытием. В актуальной реализации используется конформное предсказание по схеме leave-one-subject-out в форме джекнайф-плюс, при которой для каждого тестового субъекта интервал строится по абсолютным ошибкам остальных субъектов той же модели.

Метод основан на предположении обменности субъектов и не требует параметрических предположений о распределении ошибок. Для малой выборки из 18 испытуемых применяется поправка на конечный размер выборки при вычислении q_hat, что особенно важно при оценке номинального уровня покрытия на уровне пороговых метрик.

По умолчанию анализируются уровни $\alpha = 0{,}2$ и $\alpha = 0{,}3$, то есть интервалы покрытия 80% и 70%. Более строгие уровни покрытия при $N = 18$ быстро вырождаются в почти тривиальные интервалы, близкие к использованию максимальной ошибки, поэтому они не рассматриваются как основной рабочий режим финального пайплайна.

2.11.5 Интерпретация модели: анализ важности признаков (SHAP)

Для интерпретации вклада отдельных признаков в предсказание времени до порога используется метод SHAP (SHapley Additive exPlanations). Для каждого окна значение SHAP разлагает предсказание модели на вклады отдельных признаков: положительный вклад соответствует сдвигу предсказания в сторону большего времени до порога, отрицательный — в сторону меньшего времени.

Важность признака оценивается как среднее абсолютное значение SHAP по всем тестовым окнам и испытуемым. Дополнительно признаки могут агрегироваться по физиологическим группам — EMG, NIRS, HRV, кинематика и взаимодействия, — что позволяет оценивать относительный вклад не только отдельных переменных, но и целых модальностей сигнала.

3 РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЯ

3.1 Сводный рейтинг моделей

…

Заключение

Дописать, после обработки

Список использованных источников

1. Nagata A., Muro M., Moritani T., Yoshida T.. Anaerobic Threshold Determination by Blood Lactate and Myoelectric Signals // Japanese Journal of Physiology. – 1981. – Т. 31. – С. 585–597.

2. Bangsbo J., Johansen L., Graham T., Saltin B.. Lactate and H+ effluxes from human skeletal muscles during intense, dynamic exercise // Journal of Physiology. – 1993. – Т. 462. – С. 115–133.

3. Bonen A., McCullagh K.J.A., Putman C.T. и др.. Short-term training increases human muscle MCT1 and femoral venous lactate in relation to muscle lactate // American Journal of Physiology – Endocrinology and Metabolism. – 1998. – Т. 274. – № 1. – С. E102–E107.

4. MacLean D.A., Bangsbo J., Saltin B.. Muscle interstitial glucose and lactate levels during dynamic exercise in humans determined by microdialysis // Journal of Applied Physiology. – 1999. – Т. 87. – № 4. – С. 1483–1490.

5. van Hall G., Jensen-Urstad M., Rosdahl H. и др.. Leg and arm lactate and substrate kinetics during exercise // American Journal of Physiology – Endocrinology and Metabolism. – 2003. – Т. 284. – № 4. – С. E193–E205. – DOI: 10.1152/ajpendo.00273.2002.

6. Wang L., Yoshikawa T., Hara T. и др.. Which common NIRS variable reflects muscle estimated lactate threshold most closely? // Applied Physiology, Nutrition, and Metabolism. – 2006. – Т. 31. – № 5. – С. 612–620. – DOI: 10.1139/H06-069.

7. Messonnier L.A., Emhoff C.-A.W., Fattor J.A. и др.. Lactate kinetics at the lactate threshold in trained and untrained men // Journal of Applied Physiology. – 2013. – Т. 114. – № 11. – С. 1593–1602. – DOI: 10.1152/japplphysiol.00043.2013.

8. Racinais S., Buchheit M., Girard O.. Breakpoints in ventilation, cerebral and muscle oxygenation, and muscle activity during an incremental cycling exercise // Frontiers in Physiology. – 2014. – Т. 5. – С. 142. – DOI: 10.3389/fphys.2014.00142.

9. Wang G., Zhang Y., Wang Y.. The Analysis of Surface EMG Signals with the Wavelet-Based Correlation Dimension Method // Computational and Mathematical Methods in Medicine. – 2014. – Т. 2014. – С. 284308. – DOI: 10.1155/2014/284308.

10. Graham R.B., Wachowiak M.P., Gurd B.J.. The Assessment of Muscular Effort, Fatigue, and Physiological Adaptation Using EMG and Wavelet Analysis // PLOS ONE. – 2015. – Т. 10. – № 8. – С. e0135069. – DOI: 10.1371/journal.pone.0135069.

11. Kominami K., Nishijima T., Okamoto T. и др.. Very Early Lactate Threshold in Healthy Young Men as Related to Oxygen Uptake Kinetics // Medicine. – 2015. – Т. 94. – № 37. – С. e1559. – DOI: 10.1097/MD.0000000000001559.

12. Driller M., Williams A., Bellinger P., Cabell A., Argus C.. Evaluating a new wearable lactate threshold sensor in recreational to highly trained cyclists // Sports Engineering. – 2016. – Т. 19. – № 3. – С. 229–235. – DOI: 10.1007/s12283-016-0198-6.

13. van der Zwaard S., Jaspers R.T., Blokland I.J. и др.. Oxygenation threshold derived from near-infrared spectroscopy: reliability and its relationship with the first ventilatory threshold // PLOS ONE. – 2016. – Т. 11. – № 9. – С. e0162914. – DOI: 10.1371/journal.pone.0162914.

14. Coquart J.B., Dufour R., Groslambert A., Mucci P.. Gas exchange threshold and muscle oxygenation inflection point during a ramp incremental exercise test // Journal of Sports Medicine and Physical Fitness. – 2017. – Т. 57. – № 5. – С. 581–588. – DOI: 10.23736/S0022-4707.16.06053-9.

15. Farzam P., Starkweather Z., Cheng X. и др.. Validation of a novel wearable, wireless technology to estimate oxygen levels and lactate threshold power in the exercising muscle // Physiological Reports. – 2018. – Т. 6. – № 7. – С. e13664. – DOI: 10.14814/phy2.13664.

16. Wang L., Liu X.. A Comparative Study of EMG Indices in Muscle Fatigue Evaluation Based on Grey Relational Analysis during All-Out Cycling Exercise //

BioMed Research International. – 2018. – Т. 2018. – С. 9341215. – DOI: 10.1155/2018/9341215.

17. Popov D.V., Vinogradova O.L.. Muscle-specific evaluation of anaerobic threshold in humans // Human Physiology. – 2019. – Т. 45. – № 2. – С. 184–189. – DOI: 10.1134/S0362119719020087.

18. Попов Д.В., Кузнецов С.С.. Валидация метода для оценки анаэробного порога в работающей мышце // Физиология человека. – 2019. – Т. 45. – № 2. – С. 70–77. – DOI: 10.1134/S0131164619020085.

19. Fasching M., Rinnerhofer S., Philipp W., Bauer R.. The First Lactate Threshold Is a Limit for Heavy Work and Corresponds to a Typical Feature in Oxygen Kinetics // Journal of Functional Morphology and Kinesiology. – 2020. – Т. 5. – № 3. – С. 66. – DOI: 10.3390/jfmk5030066.

20. Lin C.-W., Huang S.-C., Liu W.-C. и др.. Detection of Ventilatory Thresholds using Near-Infrared Spectroscopy with a Polynomial Regression Model // Saudi Journal of Biological Sciences. – 2020. – Т. 27. – № 9. – С. 2388–2394. – DOI: 10.1016/j.sjbs.2020.03.005.

21. Miura K., Seki T., Tanaka R.. Feasibility of the deep learning method for estimating the ventilatory threshold with electrocardiography data // npj Digital Medicine. – 2020. – Т. 3. – № 1. – С. 141. – DOI: 10.1038/s41746-020-00348-6.

22. Tsinganos P., Cornelis B., Cornelis J. и др.. Data Augmentation of Surface Electromyography for Hand Gesture Recognition // Sensors. – 2020. – Т. 20. – № 17. – С. 4892. – DOI: 10.3390/s20174892.

23. Amelard R., Sless T.Y., Maki K.A. и др.. Temporal convolutional networks predict dynamic oxygen uptake response from wearable sensors across exercise intensity transitions // npj Digital Medicine. – 2021. – Т. 4. – № 1. – С. 156. – DOI: 10.1038/s41746-021-00531-3.

24. Cayot T.E., Robinson S.J., Fahs C.A.. Estimating the Lactate Threshold Using Wireless Near-Infrared Spectroscopy and Threshold Detection Algorithms // International Journal of Exercise Science. – 2021. – Т. 14. – № 2. – С. 1244–1257.

25. Ji S., Sommer A., Bloch W., Wahl P.. Comparison and Performance

Validation of Calculated and Established Anaerobic Lactate Thresholds in Running // Medicina. – 2021. – Т. 57. – № 10. – С. 1117. – DOI: 10.3390/medicina57101117.

26. Rogers B., Gronwald T.. Fractal Correlation Properties of Heart Rate Variability as a Biomarker for Intensity Distribution and Training Prescription in Endurance Exercise // Frontiers in Physiology. – 2022. – Т. 13. – С. 879071. – DOI: 10.3389/fphys.2022.879071.

27. Schaffarczyk M., Rogers B., Reer R., Gronwald T.. Fractal correlation properties of HRV as a noninvasive biomarker to assess the physiological response to different exercise intensity domains in triathletes // BMC Sports Science, Medicine and Rehabilitation. – 2022. – Т. 14. – № 1. – С. 203. – DOI: 10.1186/s13102-022-00596-x.

28. Schaffarczyk M., Rogers B., Reer R., Gronwald T.. Validation of a non-linear index of heart rate variability to determine aerobic and anaerobic thresholds during incremental cycling exercise in women // European Journal of Applied Physiology. – 2023. – Т. 123. – № 2. – С. 299–309. – DOI: 10.1007/s00421-022-05050-x.

29. Voet N.B.M., Bleijenberg G., Padberg G.W. и др.. Surface Electromyography Thresholds As a Measure for Performance Fatigability During Strength and Endurance Exercise // Frontiers in Physiology. – 2022. – Т. 13. – С. 821584. – DOI: 10.3389/fphys.2022.821584.

30. Wackerhage H., Gehlert S.. Lactate Thresholds and the Simulation of Human Energy Metabolism // Frontiers in Physiology. – 2022. – Т. 13. – С. 899670. – DOI: 10.3389/fphys.2022.899670.

31. Zeng Z., Liu M., Hu X. и др.. Interpretable recurrent neural network models for dynamic prediction of the extubation failure risk in patients with invasive mechanical ventilation // BioData Mining. – 2022. – Т. 15. – № 1. – С. 25. – DOI: 10.1186/s13040-022-00309-7.

32. Brooks G.A.. What the Lactate Shuttle Means for Sports Nutrition // Nutrients. – 2023. – Т. 15. – № 9. – С. 2178. – DOI: 10.3390/nu15092178.

33. Jamaluddin A., Ahmad R.B., Ibrahim I.M. и др.. A New Approach to

Noninvasive-Prolonged Fatigue Identification Based on Surface EMG Time-Frequency Analysis // Applied Bionics and Biomechanics. – 2023. – Т. 2023. – С. 1951165. – DOI: 10.1155/2023/1951165.

34. Kimoto A., Fujiyama H., Machida M.. A Wireless Multi-Layered EMG/MMG/NIRS Sensor for Muscular Activity Evaluation // Sensors. – 2023. – Т. 23. – № 3. – С. 1539. – DOI: 10.3390/s23031539.

35. Reinpõld K., Rannama I., Port K.. Agreement between Ventilatory Thresholds and Bilaterally Measured Vastus Lateralis Muscle Oxygen Saturation in Cyclists // Sports. – 2024. – Т. 12. – № 2. – С. 40. – DOI: 10.3390/sports12020040.

36. Rodu J., Kaufman S., Peel J.L. и др.. On Leveraging Machine Learning in Sport Science in the Hypothetico-deductive Framework // Sports Medicine – Open. – 2024. – Т. 10. – № 1. – С. 124. – DOI: 10.1186/s40798-024-00788-4.

37. Tanner A.V., Nielsen B.V., Oranchuk D.J.. Agreement Between Heart Rate Variability-Derived and Ventilatory/Lactate Thresholds in Healthy Adults: A Systematic Review and Meta-Analysis // Sports Medicine – Open. – 2024. – Т. 10. – № 1. – С. 111. – DOI: 10.1186/s40798-024-00768-8.

38. Tomaszewski M., Lukanova-Jakubowska A., Majorczyk E.. From data to decision: Machine learning determination of aerobic and anaerobic thresholds in athletes // PLOS ONE. – 2024. – Т. 19. – № 8. – С. e0309427. – DOI: 10.1371/journal.pone.0309427.

39. Fiedler J., Woll A.. Reference standards for power at the lactate threshold 2 for cycle ergometry through the lens of the literature // Journal of Sports Sciences. – 2025. – DOI: 10.1080/02640414.2025.2517913.

40. Fischer J., Wolfarth B., Hävecker E.R. и др.. Modeling lactate threshold in cycling – influence of sex, maximal oxygen uptake, and body composition // European Journal of Applied Physiology. – 2025. – Т. 125. – № 6. – С. 2145–2158. – DOI: 10.1007/s00421-025-05744-y.

Приложение 1

Полный состав оконных признаков

Ниже приведено полное соответствие технических обозначений (имён колонок в датасете) и физиологического смысла для всех признаков, используемых в моделях. Обозначения: **дист.** — дистальный электрод m. vastus lateralis; **прокс.** — проксимальный; **нагр.** — фаза нагрузки (нажатие педали); **восст.** — фаза восстановления (подъём педали).

ЭМГ: временна́я область (16 признаков × 4 потока = 64)

Техническое обозначение	Поток	Физиологический смысл
`z_vl_dist_load_rms`	дист., нагр.	RMS — среднеквадратическое значение ЭМГ
`z_vl_dist_load_mav`	дист., нагр.	MAV — среднее абсолютное значение ЭМГ
`z_vl_dist_load_wl`	дист., нагр.	WL — длина волны (суммарное абс. изменение сигнала)
`z_vl_dist_load_zcr`	дист., нагр.	ZCR — частота нулевых пересечений
`z_vl_dist_load_mdf`	дист., нагр.	MDF — медианная частота спектра (Гц)
`z_vl_dist_load_mnf`	дист., нагр.	MNF — средняя (центроидная) частота спектра (Гц)
`z_vl_dist_load_p_low`	дист., нагр.	Доля мощности в полосе 20–50 Гц
`z_vl_dist_load_p_mid`	дист., нагр.	Доля мощности в полосе 50–150 Гц
`z_vl_dist_load_p_high`	дист., нагр.	Доля мощности в полосе 150–450 Гц
`z_vl_dist_load_ratio_mid_high`	дист., нагр.	Отношение p_mid / p_high
`z_vl_dist_load_e_d2`	дист., нагр.	Энергия вейвлетного субдиапазона d2 (~250–500 Гц)
`z_vl_dist_load_e_d3`	дист., нагр.	Энергия вейвлетного субдиапазона d3 (~125–250 Гц)
`z_vl_dist_load_e_d4`	дист., нагр.	Энергия вейвлетного субдиапазона d4 (~62–125 Гц)
`z_vl_dist_load_e_d5`	дист., нагр.	Энергия вейвлетного субдиапазона d5 (~31–62 Гц)
`z_vl_dist_load_wavelet_entropy`	дист., нагр.	Вейвлет-энтропия (неупорядоченность по субдиапазонам)
`z_vl_dist_load_ratio_low_high`	дист., нагр.	Отношение энергий (d4+d5) / (d2+d3)
`z_vl_dist_rest_rms`	дист., восст.	RMS ЭМГ в фазе восстановления
`z_vl_dist_rest_mav`	дист., восст.	MAV ЭМГ в фазе восстановления
`z_vl_dist_rest_wl`	дист., восст.	WL в фазе восстановления
`z_vl_dist_rest_zcr`	дист., восст.	ZCR в фазе восстановления
`z_vl_dist_rest_mdf`	дист., восст.	MDF в фазе восстановления
`z_vl_dist_rest_mnf`	дист., восст.	MNF в фазе восстановления
`z_vl_dist_rest_p_low`	дист., восст.	Доля мощности 20–50 Гц в фазе восстановления

Техническое обозначение	Поток	Физиологический смысл
z_vl_dist_rest_p_mid	дист., восст.	Доля мощности 50–150 Гц в фазе восстановления
z_vl_dist_rest_p_high	дист., восст.	Доля мощности 150–450 Гц в фазе восстановления
z_vl_dist_rest_ratio_mid_high	дист., восст.	Отношение p_mid / p_high (восст.)
z_vl_dist_rest_e_d2	дист., восст.	Энергия d2 в фазе восстановления
z_vl_dist_rest_e_d3	дист., восст.	Энергия d3 в фазе восстановления
z_vl_dist_rest_e_d4	дист., восст.	Энергия d4 в фазе восстановления
z_vl_dist_rest_e_d5	дист., восст.	Энергия d5 в фазе восстановления
z_vl_dist_rest_wavelet_entropy	дист., восст.	Вейвлет-энтропия (восст.)
z_vl_dist_rest_ratio_low_high	дист., восст.	Отношение (d4+d5)/(d2+d3) (восст.)
z_vl_prox_load_rms	прокс., нагр.	RMS ЭМГ проксимального электрода (нагр.)
z_vl_prox_load_mav	прокс., нагр.	MAV ЭМГ проксимального электрода (нагр.)
z_vl_prox_load_wl	прокс., нагр.	WL проксимального электрода (нагр.)
z_vl_prox_load_zcr	прокс., нагр.	ZCR проксимального электрода (нагр.)
z_vl_prox_load_mdf	прокс., нагр.	MDF проксимального электрода (нагр.)
z_vl_prox_load_mnf	прокс., нагр.	MNF проксимального электрода (нагр.)
z_vl_prox_load_p_low	прокс., нагр.	Доля мощности 20–50 Гц (прокс., нагр.)
z_vl_prox_load_p_mid	прокс., нагр.	Доля мощности 50–150 Гц (прокс., нагр.)
z_vl_prox_load_p_high	прокс., нагр.	Доля мощности 150–450 Гц (прокс., нагр.)
z_vl_prox_load_ratio_mid_high	прокс., нагр.	Отношение p_mid / p_high (прокс., нагр.)
z_vl_prox_load_e_d2	прокс., нагр.	Энергия d2 (прокс., нагр.)
z_vl_prox_load_e_d3	прокс., нагр.	Энергия d3 (прокс., нагр.)
z_vl_prox_load_e_d4	прокс., нагр.	Энергия d4 (прокс., нагр.)
z_vl_prox_load_e_d5	прокс., нагр.	Энергия d5 (прокс., нагр.)
z_vl_prox_load_wavelet_entropy	прокс., нагр.	Вейвлет-энтропия (прокс., нагр.)
z_vl_prox_load_ratio_low_high	прокс., нагр.	Отношение (d4+d5)/(d2+d3) (прокс., нагр.)
z_vl_prox_rest_rms	прокс., восст.	RMS ЭМГ проксимального электрода (восст.)
z_vl_prox_rest_mav	прокс., восст.	MAV ЭМГ проксимального электрода (восст.)
z_vl_prox_rest_wl	прокс., восст.	WL проксимального электрода (восст.)
z_vl_prox_rest_zcr	прокс., восст.	ZCR проксимального электрода (восст.)
z_vl_prox_rest_mdf	прокс., восст.	MDF проксимального электрода (восст.)
z_vl_prox_rest_mnf	прокс., восст.	MNF проксимального электрода (восст.)
z_vl_prox_rest_p_low	прокс., восст.	Доля мощности 20–50 Гц (прокс., восст.)
z_vl_prox_rest_p_mid	прокс., восст.	Доля мощности 50–150 Гц (прокс., восст.)
z_vl_prox_rest_p_high	прокс., восст.	Доля мощности 150–450 Гц (прокс., восст.)

Техническое обозначение	Поток	Физиологический смысл
z_vl_prox_rest_ratio_mid_high	прокс., восст.	Отношение p_mid / p_high (прокс., восст.)
z_vl_prox_rest_e_d2	прокс., восст.	Энергия d2 (прокс., восст.)
z_vl_prox_rest_e_d3	прокс., восст.	Энергия d3 (прокс., восст.)
z_vl_prox_rest_e_d4	прокс., восст.	Энергия d4 (прокс., восст.)
z_vl_prox_rest_e_d5	прокс., восст.	Энергия d5 (прокс., восст.)
z_vl_prox_rest_wavelet_entropy	прокс., восст.	Вейвлет-энтропия (прокс., восст.)
z_vl_prox_rest_ratio_low_high	прокс., восст.	Отношение (d4+d5)/(d2+d3) (прокс., восст.)

ЭМГ: вариабельность амплитуды цикл-к-циклу (4 признака)

Техническое обозначение	**Физиологический смысл**
z_vl_dist_load_rms_cv	CV амплитуды RMS по циклам — дист., нагр.
z_vl_dist_rest_rms_cv	CV амплитуды RMS по циклам — дист., восст.
z_vl_prox_load_rms_cv	CV амплитуды RMS по циклам — прокс., нагр.
z_vl_prox_rest_rms_cv	CV амплитуды RMS по циклам — прокс., восст.

Кинематика педалирования (11 признаков)

Техническое обозначение	**Физиологический смысл**
z_cadence_mean_rpm	Средняя каденс в окне (об/мин), z-норм.
z_cadence_cv	Коэффициент вариации каденса
z_load_duration_ms	Средняя длительность фазы нагрузки (мс)
z_rest_duration_ms	Средняя длительность фазы восстановления (мс)
z_load_rest_ratio	Отношение длительностей нагр./восст.
z_load_duration_cv	CV длительностей фаз нагрузки
z_rest_duration_cv	CV длительностей фаз восстановления
z_load_trend_cv_ratio_30s	Отношение CV последней трети к первой трети нагр. за 30 с
z_rest_trend_cv_ratio_30s	Отношение CV последней трети к первой трети восст. за 30 с
z_load_sampen_30s	Sample Entropy длительностей нагр. фаз за 30 с
z_rest_sampen_30s	Sample Entropy длительностей восст. фаз за 30 с

NIRS — оконные признаки (15 признаков, Train.Red)

Техническое обозначение	**Физиологический смысл**
trainred_smo2_mean	Среднее SmO_2 в окне (%)

Техническое обозначение	Физиологический смысл
trainred_smo2_drop	Снижение SmO_2 от начала окна
trainred_smo2_slope	Линейный тренд SmO_2 в окне
trainred_smo2_std	Стандартное отклонение SmO_2
trainred_dsmo2_dt	Производная SmO_2 по времени
trainred_hhb_mean	Среднее дезоксигемоглобина HHb
trainred_hhb_slope	Линейный тренд HHb в окне
trainred_hhb_std	Стандартное отклонение HHb
trainred_dhhb_dt	Производная HHb по времени
trainred_hbdiff_mean	Среднее индекса оксигенации HbDiff (= HbO_2 − HHb)
trainred_hbdiff_slope	Линейный тренд HbDiff
trainred_hbdiff_std	Стандартное отклонение HbDiff
trainred_thb_mean	Среднее общего гемоглобина THb
trainred_thb_slope	Линейный тренд THb
trainred_thb_std	Стандартное отклонение THb

NIRS — кумулятивные признаки (3 признака)

Техническое обозначение	Физиологический смысл
smo2_from_running_max	Падение SmO_2 от текущего максимума сессии
hhb_from_running_min	Подъём HHb от текущего минимума сессии
smo2_rel_drop_pct	Относительное снижение SmO_2 от базального уровня (%)

HRV —вриабельность сердечного ритма (7 признаков)

Техническое обозначение	Физиологический смысл
hrv_mean_rr_ms	Среднее RR-интервала (мс)
hrv_sdnn_ms	SDNN — стандартное отклонение RR (мс)
hrv_rmssd_ms	RMSSD (мс)
hrv_sd1_ms	SD1 по диаграмме Пуанкаре (мс)
hrv_sd2_ms	SD2 по диаграмме Пуанкаре (мс)
hrv_sd1_sd2_ratio	Отношение SD1/SD2
hrv_dfa_alpha1	DFA-α1

Взаимодействия (3 признака, только EMG+NIRS+HRV)

Техническое обозначение	Формула	Физиологический смысл
feat_smo2_x_rr	SmO_2_mean × mean_RR / 10 000	Совместный маркер оксигенации и ЧСС
feat_smo2_x_dfa	SmO_2_mean × DFA-α1	Взаимодействие оксигенации и автономной регуляции
feat_rr_per_watt	mean_RR / мощность_Вт	ЧСС, нормированная на мощность нагрузки

Абсолютные признаки, исключаемые в варианте noabs (6 признаков)

Техническое обозначение	Описание
trainred_smo2_mean	Абсолютный уровень SmO_2
trainred_hhb_mean	Абсолютный уровень HHb
trainred_hbdiff_mean	Абсолютный уровень HbDiff
trainred_thb_mean	Абсолютный уровень THb
hrv_mean_rr_ms	Абсолютный уровень ЧСС (через среднее RR)
feat_smo2_x_rr	Взаимодействие абсолютных уровней SmO_2 и ЧСС

Базальные физиологические показатели

Техническое обозначение	Физиологический смысл
age	Возраст (лет)
sex	Пол
height	Рост (см)
weight	Масса тела (кг)
bmi	Индекс массы тела
body_fat_pct	Процент жировой массы
phase_angle	Угол фазы биоимпеданса (°)
hrv_hr_baseline_bpm	ЧСС на калибровочной ступени 30 Вт (уд/мин)
hrv_rmssd_baseline_ms	RMSSD на калибровочной ступени 30 Вт (мс)
emg_vl_dist_baseline_rms	ЭМГ-RMS дистального электрода на 30 Вт
emg_vl_prox_baseline_rms	ЭМГ-RMS проксимального электрода на 30 Вт
nirs_smo2_baseline_mean	Средняя SmO_2 на калибровочной ступени 30 Вт (%)