

Автономная некоммерческая
образовательная организация высшего образования
«НАУЧНО-ТЕХНОЛОГИЧЕСКИЙ УНИВЕРСИТЕТ «СИРИУС»

Научный центр генетики и наук о жизни

направление «Вычислительная биология»

К ЗАЩИТЕ ДОПУСТИТЬ
Руководитель направления
«Вычислительная биология»
д-р биол. наук

_____ Ф.А. Колпаков
« ____ » _____ 2026 г.

**«ПРЕДСКАЗАНИЕ АЭРОБНО-АНАЭРОБНОГО ПЕРЕХОДА ПО
ЭЛЕКТРОМИОГРАММЕ И ДАННЫМ ИК-СПЕКТРОМЕТРИИ НА
РАБОТАЮЩЕЙ МЫШЦЕ»**

Магистерская диссертация по направлениям подготовки
06.04.01 «Биология», 09.04.03 «Прикладная информатика»
направленность (профиль) «Биоинформатика»

Студент гр. _____
_____ А.С. Тамразов
« ____ » _____ 2026 г.

Согласовано
Консультант

(должность, ученая степень, звание)
_____ Я.Р. Бравый
« ____ » _____ 2026 г.

Руководитель

(должность, ученая степень, звание)
_____ Д.А. Онищенко
« ____ » _____ 2026 г.

Автономная некоммерческая
образовательная организация высшего образования
«НАУЧНО-ТЕХНОЛОГИЧЕСКИЙ УНИВЕРСИТЕТ «СИРИУС»

Научный центр генетики и наук о жизни

направление «Вычислительная биология»

УТВЕРДИТЬ

Руководитель направления
«Вычислительная биология»
д-р биол. наук

_____ Ф.А. Колпаков

«___» _____ 20__ г.

ТЕХНИЧЕСКОЕ ЗАДАНИЕ

на выполнение магистерской диссертации по направлениям подготовки
06.04.01 «Биология», 09.04.03 «Прикладная информатика»
направленность (профиль) «Биоинформатика»

Тамразов Александр Сергеевич

1. Тема: «Предсказание аэробно-анаэробного перехода по электромиограмме и данным ИК-спектроскопии на работающей мышце»
2. Цель: Разработка и валидация метода неинвазивного онлайн-предсказания аэробно-анаэробного перехода по данным поверхностной электромиографии и ближней инфракрасной спектроскопии работающей мышцы в условиях ступенчатого нагрузочного велоэргометрического теста.
3. Задачи:
 - Разработать протокол синхронной записи данных с носимых датчиков (Delsys Trigno: ЭМГ и ИМУ мышцы vastus lateralis (дистальная и проксимальная зоны); Train.Red: мышечная оксигенация SmO₂ на vastus lateralis; Zephyr BioHarness: RR-интервалы).
 - Разработать алгоритм предобработки и синхронизации разночастотных физиологических сигналов, включая: сегментацию ЭМГ по фазам педалирования на основе данных гироскопа, фильтрацию и

нормализацию ЭМГ, сглаживание SmO_2 , интерполяцию RR-интервалов и расчёт DFA- α_1 в скользящем окне.

- Провести экспериментальный сбор данных согласно разработанному протоколу: выполнить ступенчатые велоэргометрические тесты с синхронной записью сигналов всех датчиков, верифицировать индивидуальные пороги LT1 и LT2 по концентрации лактата в капиллярной крови.

- Сформировать датасет для онлайн-предсказания близости к лактатным порогам, включающий классические ЭМГ-характеристики, показатели мышечной оксигенации и вариабельности сердечного ритма, с учётом фазовой структуры цикла педалирования.

- Разработать ML-модель, предсказывающую в скользящем временном окне оставшееся время до наступления лактатных порогов LT1 и LT2 в режиме реального времени; систематически сопоставить базовый подход на классических моделях с ручными признаками (регуляризованная линейная регрессия, метод опорных векторов, градиентный бустинг) и расширенный подход на нейросетевых архитектурах для временных рядов (рекуррентные, темпоральные свёрточные и вейвлет-обогащённые).

- Оценить точность предсказания LT1 и LT2 по носимым данным в сравнении с лактатным порогом, определённым по капиллярной крови, с использованием стратегии Leave-One-Subject-Out (LOSO); провести анализ значимости признаков методом SHAP, оценить вклад отдельных физиологических модальностей (ЭМГ, NIRS, BCP) и сопоставить результаты с данными литературы.

4. Рабочий график (план) выполнения магистерской диссертации:

№	Перечень заданий	Сроки выполнения
1.	Написание литературного обзора	12.02.2026 – 16.03.2026
2.	Изложение материалов и методов	17.03.2026 – 20.04.2026
3.	Представление полученных результатов	21.04.2026 – 11.05.2026

Дата выдачи: «___» _____ 20___ г.

Руководитель:

_____ Д. А. Онищенко

Задание принял к исполнению:

Студент группы М69БИ-24

_____ А.С. Тамразов

«___» _____ 20___ г.

Реферат

Диссертация изложена на 129 страницах, содержит 11 рисунков, 7 таблиц, 52 источника, 2 приложения. Цель работы – разработка и валидация метода неинвазивного онлайн-предсказания лактатных порогов LT1 и LT2 по данным поверхностной электромиографии, ближней инфракрасной спектроскопии и вариабельности сердечного ритма в ступенчатом велоэргометрическом тесте. Используются методы синхронной мультимодальной регистрации сигналов, предобработки разночастотных рядов, машинного обучения и subject-level валидации по схеме LOSO. Установлено, что пороги требуют разных сочетаний сигналов и моделей. Практическая значимость работы состоит в создании основы для систем оперативной оценки приближения к пороговым зонам нагрузки вне лабораторных условий.

Ключевые слова

ЛАКТАТНЫЙ ПОРОГ, ЭЛЕКТРОМИОГРАФИЯ, БЛИЖНЯЯ ИНФРАКРАСНАЯ СПЕКТРОСКОПИЯ, ВАРИАБЕЛЬНОСТЬ СЕРДЕЧНОГО РИТМА, НОСИМЫЕ ДАТЧИКИ, ВЕЛОЭРГОМЕТРИЧЕСКИЙ ТЕСТ, МАШИННОЕ ОБУЧЕНИЕ, ОНЛАЙН-ПРЕДСКАЗАНИЕ.

The abstract

The dissertation is presented on 129 pages and contains 11 figures, 7 tables, 52 references, and 2 appendices. The aim of the study was to develop and validate a non-invasive method for online prediction of the lactate thresholds LT1 and LT2 using surface electromyography, near-infrared spectroscopy, and heart rate variability during a graded cycle ergometer test. The study employed synchronous multimodal signal acquisition, preprocessing of multi-rate time series, machine learning methods, and subject-level validation using the LOSO scheme. It was established that the two thresholds require different combinations of signals and models. The practical significance of the work lies in providing a basis for systems for real-time assessment of approaching threshold load zones outside laboratory conditions.

Keywords

LACTATE THRESHOLD, ELECTROMYOGRAPHY, NEAR-INFRARED SPECTROSCOPY, HEART RATE VARIABILITY, WEARABLE SENSORS, CYCLE ERGOMETER TEST, MACHINE LEARNING, ONLINE PREDICTION.

Сокращения, обозначения, термины и определения

В настоящей работе применяют следующие термины и соответствующие определения:

Аэробно-анаэробный переход – диапазон интенсивности физической нагрузки, при котором анаэробный гликолиз начинает вносить существенный вклад в энергообеспечение работающих мышц, сопровождающийся нелинейным ростом концентрации лактата в крови, десатурацией мышечного гемоглобина и изменением паттерна рекрутирования двигательных единиц.

Вейвлетное преобразование – математический инструмент для анализа нестационарных сигналов, позволяющий одновременно получить информацию о частотном составе сигнала и его временной локализации; существует в дискретной (DWT) и непрерывной (CWT) формах.

Вейвлет-энтропия – мера сложности сигнала, вычисляемая как нормированная энтропия Шеннона по распределению энергии вейвлет-коэффициентов по уровням декомпозиции.

Двигательная единица (ДЕ) – мотонейрон и иннервируемые им мышечные волокна; минимальная функциональная единица нервно-мышечной системы.

DFA- $\alpha 1$ (краткосрочный показатель детрендрованного флуктуационного анализа) – безразмерный показатель, характеризующий фрактальные свойства временного ряда RR-интервалов в коротких временных масштабах (4 – 16 кардиоциклов); значение $\alpha 1 = 0,75$ эмпирически соответствует первому аэробному порогу (VT1/LT1).

Лактатный порог (LT) – интенсивность нагрузки, при которой концентрация лактата в крови начинает нелинейно возрастать относительно базального уровня покоя; различают первый (LT1, ~2 – 2,5 ммоль/л) и второй (LT2, ~4 ммоль/л) лактатные пороги.

Leave-One-Subject-Out (LOSO) – метод перекрёстной валидации, при котором на каждой итерации модель обучается на данных всех испытуемых,

кроме одного, и тестируется на оставленном; обеспечивает оценку обобщаемости модели на новых субъектах без утечки данных.

Машинное обучение (ML) – раздел искусственного интеллекта, изучающий методы построения алгоритмов, способных обучаться на данных и делать предсказания без явного программирования правил.

Мышечная оксигенация (SmO_2) – доля оксигенированного гемоглобина в суммарном гемоглобине работающей мышцы, измеряемая методом ближней инфракрасной спектроскопии (NIRS); отражает баланс между доставкой и потреблением кислорода на уровне микроциркуляции.

NIRS (ближняя инфракрасная спектроскопия) – оптический метод неинвазивного мониторинга оксигенации тканей, основанный на различии спектров поглощения оксигемоглобина (O_2Hb) и дезоксигемоглобина (HHb) в диапазоне длин волн 700 – 900 нм.

Рекрутирование двигательных единиц – последовательное вовлечение дополнительных двигательных единиц в работу по мере нарастания требуемой мышечной силы; при переходе к высокоинтенсивной нагрузке рекрутируются быстрые гликолитические волокна (тип II).

RMS (среднеквадратичная амплитуда) – показатель суммарной электрической активности мышцы, вычисляемый как корень из среднего квадрата амплитуды ЭМГ-сигнала в заданном временном окне; служит основным маркером нарастания мышечного усилия и усталости.

SHAP (SHapley Additive exPlanations) – метод интерпретации предсказаний моделей машинного обучения, основанный на теории кооперативных игр Шепли; позволяет количественно оценить вклад каждого признака в отдельное предсказание модели.

Скользящее окно – метод обработки непрерывного временного ряда путём последовательного извлечения фрагментов фиксированной длины с заданным шагом сдвига; обеспечивает вычисление признаков в режиме реального времени.

Темпоральная свёрточная сеть (TCN) – архитектура нейронной сети для обработки временных рядов, основанная на каузальных свёртках с расширяющимися дилатациями; позволяет учитывать долгосрочные зависимости в сигнале при параллельном вычислении всех временных шагов.

Электромиография (ЭМГ) – метод регистрации суммарной электрической активности скелетных мышц; поверхностная ЭМГ (sEMG) регистрирует сигнал посредством электродов, размещённых на коже над исследуемой мышцей.

В настоящей работе применяют следующие сокращения и обозначения:

АДФ – аденозиндифосфат;

ДЕ – двигательная единица;

ИК – инфракрасный (-ая, -ое);

ИМУ – инерциальный измерительный модуль;

ТЗ – техническое задание;

ЧСС – частота сердечных сокращений;

ЭМГ – электромиография; электромиограмма;

ANT+ – Adaptive Network Topology – беспроводной протокол передачи данных;

АТА – anaerobic Threshold – анаэробный порог;

АТТ – Adipose Tissue Thickness – толщина подкожной жировой клетчатки;

BLE – Bluetooth Low Energy – протокол беспроводной связи малой мощности;

CI – Confidence Interval – доверительный интервал;

CNN – Convolutional Neural Network – свёрточная нейронная сеть;

CPET – Cardiopulmonary Exercise Testing – кардиопульмональное нагрузочное тестирование;

CWT – Continuous Wavelet Transform – непрерывное вейвлетное преобразование;

DFA- α 1 – Detrended Fluctuation Analysis α -1 – краткосрочный показатель детрендированного флуктуационного анализа;

DWT – Discrete Wavelet Transform – дискретное вейвлетное преобразование;

FFT – Fast Fourier Transform – быстрое преобразование Фурье;

GET – Gas Exchange Threshold – газообменный порог;

GRU – Gated Recurrent Unit – управляемый рекуррентный блок;

HDF5 – Hierarchical Data Format version 5 – иерархический формат хранения данных;

HHb – Deoxyhaemoglobin – дезоксигемоглобин;

HRVT1 – Heart Rate Variability Threshold 1 – первый порог variability сердечного ритма;

HRVT2 – Heart Rate Variability Threshold 2 – второй порог variability сердечного ритма;

HRV – Heart Rate Variability – variability сердечного ритма;

ICC – Intraclass Correlation Coefficient – коэффициент внутриклассовой корреляции;

IEMG – Integrated Electromyography – интегрированная электромиограмма;

LOSO – Leave-One-Subject-Out – перекрёстная валидация с исключением одного испытуемого;

LSTM – Long Short-Term Memory – нейронная сеть с долгой краткосрочной памятью;

LT – Lactate Threshold – лактатный порог;

LT1 – Lactate Threshold 1 – первый лактатный порог;

LT2 – Lactate Threshold 2 – второй лактатный порог;

LT4 – Lactate Threshold at 4 mmol/L – лактатный порог при концентрации 4 ммоль/л;

MAE – Mean Absolute Error – средняя абсолютная ошибка;

MCT1 – Monocarboxylate Transporter 1 – монокарбоксилатный транспортёр 1;

MDF Median Frequency – медианная частота;

ML – Machine Learning – машинное обучение;

MLSS – Maximal Lactate Steady State – максимальное лактатное стационарное состояние;

MN – FMean Frequency – средняя частота;

NIRS – Near-Infrared Spectroscopy – ближняя инфракрасная спектроскопия;

OBLA – Onset of Blood Lactate Accumulation – начало накопления лактата в крови;

O₂Hb – Oxyhaemoglobin – оксигемоглобин;

R² – Coefficient of Determination – коэффициент детерминации;

RF – Rectus femoris – прямая мышца бедра;

RMS – Root Mean Square – среднеквадратичная амплитуда;

RNN – Recurrent Neural Network – рекуррентная нейронная сеть;

RMSE – Root Mean Square Error – среднеквадратичная ошибка;

RMSSD – Root Mean Square of Successive Differences – квадратный корень из среднеквадратичной разности последовательных RR-интервалов;

RR-интервал – интервал между последовательными зубцами R на ЭКГ;

SHAP – SHapley Additive exPlanations – метод интерпретации моделей машинного обучения на основе значений Шепли;

SMD – Standardised Mean Difference – стандартизованная разность средних;

SmO₂ – Skeletal Muscle Oxygen Saturation – насыщение мышечного гемоглобина кислородом;

STFT – Short-Time Fourier Transform – оконное преобразование Фурье;

TCN – Temporal Convolutional Network – темпоральная свёрточная сеть;

TCU – Trigno Control Utility – программное обеспечение управления датчиками Delsys Trigno;

THb – Total Haemoglobin – суммарный гемоглобин;

VL – Vastus lateralis – латеральная широкая мышца бедра;

VO₂ – Oxygen Uptake – потребление кислорода;

VO₂max – Maximum Oxygen Uptake – максимальное потребление кислорода;

VT1 – Ventilatory Threshold 1 – первый вентиляционный порог;

VT2 – Ventilatory Threshold 2 – второй вентиляционный порог;

WI – Wavelet Index – вейвлетный индекс.

Оглавление

Введение	18
1 Обзор литературы	21
1.1 Аэробно-анаэробный переход: физиологические механизмы	21
1.2 Электромиография как неинвазивный маркер порога при велоэргометрии	24
1.2.1 Классические признаки: RMS, MDF и ЭМГ-порог.....	24
1.2.2 Вейвлетный анализ ЭМГ	27
1.3 Ближняя инфракрасная спектроскопия и локальная мышечная оксигенация	31
1.4 Вариабельность сердечного ритма и DFA- $\alpha 1$ как онлайн-маркер первого порога.....	34
1.5 Кинетика лактата: задержка системного сигнала относительно локального	37
1.6 Машинное обучение и алгоритмы онлайн-детекции аэробно-анаэробного перехода.....	40
1.6.1 Классический ML на ручных признаках	41
1.6.2 ML для временных рядов: LSTM, TCN и вейвлетные сети	43
1.6.3 Обучение при малых датасетах и стратегии валидации.....	47
1.6.4 Gap: мультимодальные онлайн-системы	50
1.7 Физиологические особенности триатлонистов при велоэргометрическом тестировании	50
1.8 Заключение по обзору литературы	52
2 Материалы и методы	54
2.1 Участники исследования.....	54
2.2 Протокол нагрузочного тестирования.....	54

2.3 Аппаратный комплекс регистрации.....	55
2.3.1 Электромиография и инерционные измерения	55
2.3.2 Ближняя инфракрасная спектроскопия.....	56
2.3.3 Сердечный ритм	57
2.4 Система синхронного сбора данных Sensync	57
2.4.1 Архитектура и мотивация.....	57
2.4.2 Реализация.....	58
2.5 Предобработка сигналов	59
2.5.1 Электромиография	59
2.5.2 Мышечная оксигенация.....	59
2.5.3 RR-интервалы и HRV.....	60
2.6 Определение лактатных порогов (ground truth).....	60
2.6.1 Определение LT1.....	60
2.6.2 Определение LT2.....	61
2.6.3 Анализ чувствительности к задержке капиллярного лактата.....	61
2.7 Признаковое пространство и модальности	62
2.7.1 ЭМГ-признаки (EMG).....	63
2.7.2 NIRS-признаки.....	64
2.7.3 HRV-признаки	64
2.7.4 Признаки взаимодействия	64
2.7.5 Комбинации признаков.....	65
2.7.6 Варианты комбинаций	65
2.7.7 Базальные физиологические показатели.....	66
2.8 Модели машинного обучения	66
2.8.1 Постановка задачи.....	66

2.8.2	Формальная постановка.....	67
2.8.3	Формирование обучающей выборки.....	68
2.8.4	Методология широкого перебора.....	68
2.8.5	Схема валидации	69
2.8.6	Семейство классических моделей	70
2.8.7	Нейросетевые семейства моделей	71
2.8.8	Агрегация оконных предсказаний	72
2.8.9	Стандартизированный аналитический этап и итоговый рейтинг....	72
2.9	Метрики качества	73
2.9.1	Две дорожки оценки качества.....	73
2.9.2	Коэффициент детерминации R^2	74
2.9.3	Ранговая корреляция Спирмена (ρ)	75
2.9.4	Базовые предсказатели	75
2.10	Постобработка.....	75
2.11	Статистический анализ и интерпретация.....	76
2.11.1	Парные сравнения моделей: критерий Уилкоксона с поправкой Бенджамини–Хохберга	76
2.11.2	Дополнительные параметры эффекта и доверительные интервалы	77
2.11.3	Сравнения по аналитическим осям	77
2.11.4	Конформное предсказание (conformal prediction).....	77
3	Результаты	80
3.1	Логика экспериментальной проверки.....	80
3.2	Общая работоспособность подхода	81
3.3	Вклад модальностей	83

3.4 Сравнение семейств моделей	86
3.5 LT1 и LT2 как разные задачи предсказания.....	88
3.6 Абляция режимов формирования ЭМГ-признаков	90
3.7 Надёжность лучших моделей: исходный рейтинг против финальных кандидатных моделей.....	92
3.8 Интерпретация финальных кандидатных моделей	96
3.8.1 Классические модели: анализ вклада признаков	97
3.8.2 Нейросетевые модели: градиентная атрибуция	98
3.8.3 Сопоставление классических и нейросетевых моделей	100
3.9 Чувствительность результатов LT1 и LT2 к величине предполагаемой задержки капиллярного лактата	101
4 Обсуждение результатов.....	104
4.1 Главный методический результат	104
4.2 Почему классические и нейросетевые модели оказались сопоставимы .	104
4.3 Вклад модальностей в предсказание порогов.....	106
4.4 Режимы формирования ЭМГ-признаков и варианты предобработки.....	107
4.5 Статистическая мощность и FDR-коррекция	108
4.6 Капиллярная задержка лактата и пределы анализа чувствительности ...	108
4.7 Ограничения работы.....	109
Заключение	112
Список использованных источников.....	114
Приложение А (справочное) Полный состав оконных признаков	121
Приложение Б (справочное) Оценка неопределённости точечных предсказаний	126
Б.1 Назначение приложения	126

Б.2 Используемая процедура	126
Б.3 Полученные количественные характеристики	127
Б.4 Интерпретация: точечная ошибка и ширина интервала измеряют разное	128
Б.5 Почему интервал так широк при $N=18$	128
Б.6 Вывод.....	129

Введение

Определение аэробно-анаэробного перехода является ключевой задачей спортивной физиологии и клинической медицины: первый лактатный порог (LT1) разграничивает аэробный и переходный режимы энергообеспечения, второй (LT2) соответствует максимальной устойчивой интенсивности нагрузки, выше которой наступает прогрессирующий лактоацидоз. Точное определение этих порогов позволяет персонализировать тренировочные зоны, контролировать нагрузку в режиме реального времени и проводить функциональную диагностику без дорогостоящего лабораторного оборудования.

Традиционные методы определения лактатных порогов – ступенчатый тест с забором капиллярной крови или газоаналитический метод – являются либо инвазивными, либо требуют стационарного оборудования, что существенно ограничивает их применение в полевых условиях, при регулярном мониторинге тренировочного процесса и в клинической практике. В последнее десятилетие активно развиваются неинвазивные подходы: анализ вариабельности сердечного ритма (HRV, в частности показатель DFA- $\alpha 1$), мышечная оксигенация методом ближней инфракрасной спектроскопии (NIRS) и поверхностная электромиография (ЭМГ). Каждый из этих методов в отдельности продемонстрировал значимую корреляцию с лактатным порогом. Вместе с тем совместное применение этих трёх сигнальных каналов в единой мультимодальной системе онлайн-предсказания в существующей литературе систематически не исследовалось, а большинство опубликованных алгоритмов работают в офлайн-режиме либо ориентированы на детекцию только одного из порогов. Таким образом, разработка метода, объединяющего ЭМГ, NIRS и HRV в единый пайплайн онлайн-предсказания LT1 и LT2 исключительно по данным носимых датчиков, представляет актуальную нерешённую задачу на стыке спортивной физиологии, обработки сигналов и машинного обучения.

Целью настоящей работы является разработка и валидация метода

неинвазивного онлайн-предсказания аэробно-анаэробного перехода по данным поверхностной электромиографии и ближней инфракрасной спектроскопии работающей мышцы в условиях ступенчатого нагрузочного велоэргометрического теста. Для достижения поставленной цели решаются следующие задачи. Во-первых, разработать протокол синхронной записи данных с носимых датчиков (Delsys Trigno: ЭМГ и ИМУ мышцы vastus lateralis (дистальная и проксимальная зоны); Train.Red: мышечная оксигенация SmO₂ на vastus lateralis; Zephyr BioHarness: RR-интервалы) и сформировать размеченный датасет на гетерогенной выборке ($n = 18$) с различным уровнем физической подготовки и верификацией лактатных порогов LT1 и LT2 по капиллярной крови. Во-вторых, разработать алгоритм предобработки и синхронизации разночастотных физиологических сигналов, включая сегментацию ЭМГ по фазам педалирования на основе данных гироскопа, фильтрацию и нормализацию ЭМГ, сглаживание SmO₂, интерполяцию RR-интервалов и расчёт DFA- $\alpha 1$ в скользящем окне. В-третьих, сформировать набор признаков для онлайн-предсказания близости к лактатным порогам, включающий классические ЭМГ-характеристики (RMS, MDF, вейвлетная энергия по уровням DWT), показатели мышечной оксигенации (SmO₂, $\Delta\text{SmO}_2/\Delta t$) и вариабельности сердечного ритма (RMSSD, DFA- $\alpha 1$) с учётом фазовой структуры цикла педалирования. В-четвёртых, разработать ML-модель, предсказывающую в скользящем временном окне оставшееся время до наступления лактатных порогов LT1 и LT2 в режиме реального времени; систематически сопоставить базовый подход на классических моделях с ручными признаками (регуляризованная линейная регрессия, метод опорных векторов, градиентный бустинг) и расширенный подход на нейросетевых архитектурах для временных рядов (рекуррентные, темпоральные свёрточные и вейвлет-обогащённые). В-пятых, оценить точность предсказания LT1 и LT2 по носимым данным в сравнении с лактатным порогом, определённым по капиллярной крови, с использованием стратегии Leave-One-Subject-Out (LOSO); провести анализ значимости признаков методом SHAP, оценить

вклад отдельных физиологических модальностей (ЭМГ, NIRS, BCP) и сопоставить результаты с данными литературы.

Методологическую основу работы составляет системный подход к анализу физиологических сигналов: многоканальные данные с носимых датчиков рассматриваются как взаимодополняющие проекции единого физиологического процесса – перехода от аэробного к анаэробному режиму энергообеспечения. Применяемые методы включают ступенчатое велоэргометрическое тестирование с верификацией лактатных порогов по капиллярной крови (методы Dmax и mDmax); синхронную многоканальную запись поверхностной ЭМГ, данных ИМУ, мышечной оксигенации методом ближней инфракрасной спектроскопии (NIRS) и кардиоинтервалографии; цифровую обработку сигналов (полосовая фильтрация, вейвлетное преобразование, детрендированный флуктуационный анализ); машинное обучение на временных рядах физиологических сигналов; статистическую оценку с использованием LOSO-валидации и интерпретацию модели методом SHAP.

Теоретическая значимость работы состоит в систематическом исследовании информационного вклада ЭМГ, NIRS и HRV-признаков в задачу онлайн-детекции LT1 и LT2 при велоэргометрической нагрузке, а также в разработке методологии мультимодальной интеграции разночастотных физиологических сигналов для построения модели предсказания близости к лактатным порогам. Практическая значимость определяется возможностью определять LT1 и LT2 в режиме реального времени исключительно по данным носимых датчиков, без лабораторного газоаналитического оборудования и инвазивного забора крови. Разработанный метод применим для персонализации тренировочного процесса и управления нагрузкой у спортсменов на выносливость, а также может быть адаптирован для задач функциональной диагностики и контроля переносимости нагрузки в программах клинической реабилитации.

1 ОБЗОР ЛИТЕРАТУРЫ

1.1 Аэробно-анаэробный переход: физиологические механизмы

Аэробно-анаэробный переход представляет собой диапазон интенсивности нагрузки, при котором анаэробный гликолиз начинает вносить существенный вклад в энергообеспечение мышечной работы, и лактат в крови начинает накапливаться быстрее, чем может быть удалён. Концептуально различают два качественно различных переходных состояния: первый порог ($VT1/LT1$) и второй порог ($VT2/LT2/MLSS$). Первый порог соответствует первому достоверному росту концентрации лактата выше базального уровня – приблизительно $2,0 - 2,5$ ммоль/л – и сопровождается начальными вентиляционными изменениями. Второй порог, нередко именуемый анаэробным порогом или максимальным лактатным стационарным состоянием ($MLSS$), соответствует интенсивности, при которой производство лактата окончательно превосходит скорость его клиренса; при фиксированном протоколе 4 ммоль/л он часто используется как его приближение [1; 2].

Ключевую роль в понимании лактатного порога сыграли работы по кинетике лактата. Messonnier с соавторами [3] в серии экспериментов с изотопными метками показали, что лактатный порог соответствует точке, при которой скорость удаления и утилизации лактата тканями – метаболический клиренс лактата (MCR) – достигает максимума: при переходе от интенсивности $LT-10\%$ к уровню LT MCR снижается на 30% , а у тренированных спортсменов MCR при LT был на 34% выше, чем у нетренированных ($62,5$ против $46,5$ мл·кг⁻¹·мин⁻¹, $p < 0,05$). Таким образом, порог отражает не просто момент появления лактата, а точку ограничения его клиренса. Примерно $70 - 80\%$ утилизируемого лактата окисляется непосредственно, а $20 - 30\%$ служат субстратом для глюконеогенеза [3]. Транспортные белки $MCT1$ и $MCT4$, которые переносят лактат через мембрану мышечной клетки, играют роль лимитирующего звена при высокой интенсивности: семидневная тренировка увеличивает содержание $MCT1$ в

мышечной ткани на 118 %, что сопровождается повышением скорости выхода лактата из мышечного волокна в венозную кровь [4].

Разграничение двух порогов тесно связано с физиологией рекрутирования двигательных единиц (ДЕ). При умеренной нагрузке работа поддерживается преимущественно медленными окислительными волокнами (тип I), способными к высокой скорости окислительного фосфорилирования. По мере роста нагрузки в работу постепенно вовлекаются быстрые гликолитические ДЕ (тип II), обладающие более высокой максимальной скоростью образования лактата (VL_{max}). Именно этот рекрутирующий сдвиг является физиологической основой первого порога: к нему лактат начинает накапливаться, поскольку быстрые волокна производят его быстрее, чем соседние медленные волокна и сердечная мышца успевают его утилизировать [1; 5]. Количественно этот сдвиг можно описать через модель Мадера, детально рассмотренную Wackerhage и Gehler [1]: в ней активация гликолиза и окислительного фосфорилирования задаётся концентрацией свободного АДФ, а высокая VL_{max} снижает мощность на ПАНО и ухудшает результативность на длинных дистанциях.

Почему детектируются именно два порога, а не один, объясняется разными механизмами формирования буферной ёмкости и вентиляционного ответа. Первый порог ($VT1/LT1$) отражает начальное включение бикарбонатной буферной системы для компенсации появляющегося лактата – у молодых здоровых испытуемых $VT1$ наступает при 59,4 % VO_{2max} [6]. Второй порог ($VT2/LT2$) маркирует исчерпание буферной ёмкости и начало дыхательной компенсации метаболического ацидоза; в той же популяции $VT2$ соответствовал 86,1 % VO_{2max} [6]. При медленных рамп-протоколах тестирования лактатный порог может выявляться существенно раньше вентиляционного – Kominami и Nishijima [7] показали, что у части испытуемых LT наступает уже при ~30 % VO_{2peak} , опережая VT (~38 % VO_{2peak}), что объясняется временем диффузии лактата из интерстициального пространства в капиллярную кровь. Это разграничение между биохимическим

и вентиляционным порогами принципиально важно при интерпретации данных ступенчатого теста.

Первый лактатный порог (LT1) несёт практическое значение не только для спорта, но и для физиологии труда. Fasching и Rinnerhofer [8] в исследовании 188 мужчин и 52 женщин рабочих специальностей показали, что 95,4 % выполняли обычную профессиональную деятельность при интенсивности ниже LT1: именно этот порог является физиологическим верхним пределом для продолжительной тяжёлой работы длительностью до 8 часов. Превышение LT1 сопровождается ростом концентрации катехоламинов и активацией симпатической нервной системы, что ускоряет развитие утомления. Таким образом, точное определение обоих порогов критично как в контексте управления тренировочным процессом, так и при оценке функциональных возможностей человека.

Описанные различия в лимитирующих факторах имеют прямые следствия для выбора информативных неинвазивных маркеров в гетерогенной выборке. У высокотренированных спортсменов высокая митохондриальная плотность и ёмкость окислительного фосфорилирования смещают узкое горлышко в сторону доставки кислорода к работающей мышце [3]: NIRS-сигнал SmO_2 непосредственно отражает момент, когда доставка перестаёт покрывать метаболический спрос, и должен давать чёткий breakpoint. У менее тренированных испытуемых первичным ограничивающим звеном остаётся митохондриальная ёмкость – скорость гликолитического синтеза пирувата превышает способность митохондрий его окислять при ещё адекватной доставке кислорода [1], что может размывать NIRS-breakpoint, тогда как более раннее рекрутирование быстрых волокон типа II и соответствующий вегетативный ответ усиливают информативность ЭМГ и HRV-маркеров. Таким образом, для выборки с широким диапазоном тренированности ни одна модальность не является универсально оптимальной – гипотеза, которая может быть проверена посредством SHAP-анализа вклада признаков.

Несмотря на хорошо разработанную физиологическую концепцию двух порогов, существующие методы их определения **остаются либо инвазивными** (заборы крови для лактатного анализа), **либо требуют специализированного газоаналитического оборудования**. Определение обоих порогов – LT1 и LT2 – в реальном времени непрерывно, по локальным неинвазивным сигналам работающей мышцы, на сегодняшний день не реализовано.

1.2 Электромиография как неинвазивный маркер порога при велоэргометрии

1.2.1 Классические признаки: RMS, MDF и ЭМГ-порог

Поверхностная электромиография (*sEMG*) позволяет неинвазивно регистрировать электрическую активность скелетных мышц и тем самым косвенно отражать паттерн рекрутирования двигательных единиц, то есть последовательность и степень включения различных двигательных единиц мышцы в работу. Принципиальная возможность использования ЭМГ для определения анаэробного порога была продемонстрирована ещё в работе Nagata и соавторов [9], в которой была обнаружена высокая корреляция между ЭМГ-порогом по интегрированной ЭМГ (IEMG-AT) и кровяным анаэробным порогом ($r=0,921$, $p<0,001$, $n=10$). В той же работе было показано, что значимое увеличение ширины частотной полосы FRQ70% (полоса на уровне 70 % пиковой частоты спектра) происходит непосредственно после достижения кровяного анаэробного порога (mean diff. = 10,3 Гц, $t=2,82$, $p<0,05$), тогда как пиковая частота (PFR) не меняется значимо. При этом ЭМГ-порог по VO_2 определяется с незначительной задержкой относительно кровяного AT (mean diff. = 0,20 л/мин, $t=3,98$, $p<0,05$), хотя в 4 из 10 случаев оба порога совпадали точно.

Механизм формирования ЭМГ-порога связан с физиологией рекрутирования. При нарастании интенсивности нагрузки, когда медленные

окислительные волокна типа I начинают испытывать локальное утомление в условиях нарастающего ацидоза, в работу вовлекаются быстрые двигательные единицы типа II: быстро окислительно-гликолитические (FOG) и быстро гликолитические (FG). Это приводит к двум связанным эффектам: амплитуда ЭМГ (RMS/IEMG) нелинейно возрастает за счёт увеличения числа и вклада активных мышечных волокон, а средняя (MNF) и медианная (MDF) частоты спектра смещаются вниз вследствие снижения скорости проведения потенциала действия по волокнам при накоплении лактата и падении внутримышечного pH [9]. Совместная регистрация NIRS и *sEMG* позволяет верифицировать этот механизм напрямую: Şaylı и Akin [10] при изометрических нагрузках 50 % и 75 % MVC обнаружили значимую отрицательную корреляцию между длительностью быстрой фазы снижения NIRS-сигнала и наклоном MNF ЭМГ, что подтверждает взаимосвязь между электрической активностью и локальной оксигенацией мышцы.

При велоэргометрии паттерны ЭМГ-активации существенно различаются для разных мышц. *Vastus lateralis* (VL) является главным разгибателем коленного сустава и обеспечивает преобладающий вклад в фазу давления на педаль (load-фаза, $\sim 0^\circ$ – 180° цикла педалирования). Метод АТННб-ЭМГ, разработанный и валидированный Поповым с соавторами [11; 12], основан на совместном анализе нормированного сигнала ЭМГ (nEMG) и нормированного дезоксигемоглобина (nHHb) по VL. В велоэргометрическом тесте с нарастающей нагрузкой (n=40) корреляция метода с лактатным порогом составила $r=0,89$ ($p<0,001$), а коэффициент вариации при тест-ретесте – около 3 %, что значительно превышает воспроизводимость традиционных ЭМГ-пороговых методов [11]. Алгоритм использует V-slope метод (минимальная сумма квадратов остатков при двух кусочно-линейных регрессиях) и аппроксимацию nEMG полиномом 5-й степени для определения мощности на пороге.

Важным методологическим подтверждением запаздывающего характера ЭМГ-порога относительно мышечной оксигенации служит

исследование Racinais с соавторами [13], в котором на 25 велосипедистах одновременно регистрировались NIRS на VL, ЭМГ на VL, RF и BF, а также газоаналитические показатели в инкрементальном тесте. Авторы установили, что ЭМГ-порог по VL наступает значимо позже VT2 (89 ± 5 % от пиковой нагрузки; $p < 0,05$, $d > 0,6$), ЭМГ-порог по RF располагался около 82 ± 14 % нагрузки, тогда как мышечный NIRS breakpoint совпадает с VT2 (около 78 – 80 % нагрузки). Полученный временной градиент означает, что NIRS реагирует на метаболические события второго порога раньше, чем ЭМГ способна отразить рекрутирование высокопороговых ДЕ. Этот вывод имеет прямое значение для архитектуры мультимодального предиктора: ЭМГ как сигнал по природе запаздывает, тогда как NIRS – опережающий маркер, и комбинация этих модальностей восполняет ограничения каждой по отдельности.

Разделение ЭМГ-активности по фазам педалирования открывает дополнительный аналитический потенциал. Гироскоп, интегрированный в датчик Delsys Trigno (угловая скорость оси педали), позволяет в реальном времени идентифицировать load- и rest-фазы цикла. При нарастании интенсивности изменяется относительный вклад фаз в суммарную ЭМГ-активность: растёт доля load-фазы, что отражает увеличение вербовки ДЕ в наиболее нагруженный период цикла. Этот признак, практически не исследованный в литературе как маркер порога, представляет собой потенциальный информационный канал для повышения точности ML-модели. Для модели это важно потому, что одинаковая суммарная ЭМГ-активность может соответствовать разному распределению усилия по фазам цикла, а значит фазовый признак добавляет информацию, которой нет в обычных усреднённых амплитудных метриках. Существующие же работы по ЭМГ и порогу сосредоточены преимущественно на амплитудных и спектральных характеристиках без учёта фазовой структуры педального цикла.

Среди методологических ограничений метода sEMG при велоэргометрии следует выделить несколько принципиальных. Во-первых,

межэлектродные расстояния и положение электрода относительно двигательных точек и зон иннервации существенно влияют на амплитуду и форму сигнала, что затрудняет межсессионное сравнение без точного воспроизведения наложения. Во-вторых, нормализация IEMG/RMS – обязательное условие для корректного сравнения между испытуемыми: без нормировки абсолютные значения несопоставимы из-за различий в толщине подкожного жира, морфологии мышцы и импедансе кожи. В методе Попова [11] нормировка выполняется на диапазон [EMGmax – EMGmin] по всему тесту, что исключает необходимость максимального произвольного сокращения. В-третьих, у пациентов с нейромышечными расстройствами ЭМГ-пороги значимо смещены и имеют более низкую воспроизводимость [14], однако для популяции тренированных триатлонистов данное ограничение нерелевантно.

Несмотря на демонстрацию принципиальной работоспособности ЭМГ как маркера лактатного порога, существующие подходы не обеспечивают онлайн-детекцию в скользящем окне с учётом фазовой структуры педального цикла, а **комбинированный анализ ЭМГ VL с синхронной NIRS на той же мышце** – как основа мультимодального предиктора – в литературе не реализован.

1.2.2 Вейвлетный анализ ЭМГ

Классические признаки ЭМГ – RMS, MNF, MDF – извлекаются на основе быстрого преобразования Фурье (FFT) либо его оконных модификаций (STFT) и предполагают локальную стационарность сигнала в пределах окна анализа, то есть считают, что на коротком временном отрезке статистические свойства сигнала существенно не меняются. Однако сама природа ЭМГ при динамических нагрузках на велоэргометре противоречит этому допущению: рекрутирование двигательных единиц меняется циклически в пределах педального оборота, а интенсивность нагрузки изменяется ступенчато, что делает ЭМГ принципиально нестационарным сигналом. Graham и соавторы

[15] показали, что STFT ограничен фиксированным временным разрешением порядка 500 мс, что недостаточно для разрешения быстрых частотных сдвигов при супрамаксимальных и переходных нагрузках; FFT же не сохраняет временную привязку частотного содержимого вовсе. Альтернативный класс методов – вейвлетный анализ – был разработан именно для обработки нестационарных сигналов и обеспечивает компромисс между временным и частотным разрешением, адаптивный к масштабу анализируемой особенности.

Дискретное вейвлетное преобразование (DWT) разлагает ЭМГ-сигнал на иерархию уровней декомпозиции, каждый из которых соответствует определённому поддиапазону частот. Для ЭМГ с частотой дискретизации 2000 Гц при использовании вейвлета Daubechies 6-го порядка (db6) уровни d1–d2 – основную мышечную активность, а более низкие уровни – медленные тренды и артефакты движения. На каждом уровне могут вычисляться количественные признаки: энергия (сумма квадратов вейвлет-коэффициентов), дисперсия и вейвлет-энтропия; в ML-пайплайне такие величины образуют входной вектор признаков, по которому модель оценивает состояние утомления или вероятность приближения к пороговой зоне. Wang и соавторы [16] провели сопоставление ЭМГ-индексов на *m. vastus lateralis* в 30-секундном all-out велоэргометрическом тесте ($n=10$) и показали, что MNF, рассчитанная по вейвлет-пакетному разложению с db6, по grey relational grade – мере близости динамики признака к выбранной референсной кривой утомления – значительно превзошла классические индексы (RMS, MF, MPF, MDF, а также сложность Лемпеля–Зива) для оценки мышечного утомления при динамическом педалировании.

Jamaluddin и соавторы [17] использовали семейство Wavelet Index (WI) признаков (WIRM1551, WIRE51 и др.), отражающих распределение энергии по шкалам и частотным диапазонам, в задаче неинвазивной идентификации затяжной мышечной усталости (prolonged fatigue) у 20 участников по 5-дневному протоколу Bruce на беговой дорожке. Классификатор Naïve Bayes на

наборе WI и классических признаков достиг точности 98 % на *m. rectus femoris*, 97 % на *m. vastus medialis* и 94 % на *m. biceps femoris*, тогда как на *m. vastus lateralis* точность составила лишь 9 %, а изменения классических индексов (ΔF_{med} , ΔRMS , ΔMAV) между нормальным состоянием и состоянием затяжной мышечной усталости были статистически незначимыми. Однако этот результат не следует напрямую переносить на задачу настоящей работы, поскольку он получен в иной двигательной постановке – в беговом протоколе, а не при педалировании. Тем самым данные Jamaluddin указывают скорее на специфичный к задаче характер информативности вейвлетных признаков, чем на универсальную непригодность *m. vastus lateralis*.

Непрерывное вейвлетное преобразование (CWT) предоставляет более гибкий, хотя и вычислительно более затратный, инструмент для разведочного анализа ЭМГ. В отличие от DWT, где анализ выполняется только на заранее заданных уровнях масштаба, CWT обеспечивает почти непрерывное покрытие частотно-временной плоскости, формируя скалограмму – двумерную карту того, как энергия сигнала распределяется по времени и частоте, что удобно для визуализации структурных изменений сигнала. Graham и соавторы [15] применили CWT к ЭМГ-данным велоэргометрических испытаний при трёх интенсивностях – 73 %, 100 % и 133 % VO_{2peak} – и обнаружили, что при 133 % VO_{2peak} уже с первого интервала наблюдалось достоверно большее падение центральной частоты и одновременный рост площади всплеска ($intensity \cdot duration$), тогда как RMS и MDF в эти моменты ещё не различали условия. CWT, тем самым, выявила режим супрамаксимальной нагрузки как качественно отличный от 100 % VO_{2peak} там, где классические показатели регистрировали лишь количественное различие. Для практических ML-приложений DWT/вейвлет-пакеты остаются предпочтительнее CWT в силу фиксированной вычислительной стоимости и компактного представления признаков, тогда как CWT – основной инструмент разведочного анализа.

Естественное расширение вейвлетного представления – комбинирование с нелинейными признаками сигнала, поскольку ЭМГ по

своей природе несёт нелинейные характеристики, отражающие непредсказуемость паттернов разряда отдельных двигательных единиц. Wang G. и соавторы [18] предложили использовать вейвлет-разложение совместно с корреляционной размерностью (нелинейной мерой сложности динамической системы): на 3-м уровне декомпозиции при двух каналах ЭМГ предплечья достигнута 100 % точность классификации четырёх двигательных паттернов, что превзошло методы без вейвлет-предобработки и без нелинейных признаков. Принципиальное значение этого подхода для задачи онлайн-детекции порога заключается в том, что нелинейные характеристики, рассчитанные на отдельных уровнях декомпозиции, сохраняют временную привязку частотного содержимого, тогда как глобальные нелинейные индексы её утрачивают. Для ML-модели порога это означает потенциальную возможность построения признакового пространства, в котором каждый уровень DWT представлен своим набором линейных и нелинейных характеристик.

Помимо извлечения признаков, вейвлетное преобразование применимо как метод аугментации обучающих данных. Tsinganos и соавторы [19] систематически сопоставили техники аугментации ЭМГ для задачи распознавания жестов и показали, что декомпозиция сигнала на вейвлет-уровни с последующим добавлением шума на каждый уровень и реконструкцией обеспечивает прирост точности классификации до +16 % на двух эталонных датасетах – существенно больше, чем простое аддитивное зашумление либо использование перекрывающихся окон. Принципиальным здесь является то, что синтетические сигналы, полученные через вейвлет-аугментацию, сохраняют физиологическую структуру оригинала: распределение энергии по полосам, форма огибающей и спектральные характеристики каждого уровня изменяются согласованно. Это делает вейвлеты универсальным инструментом, применимым как для извлечения признаков в feature engineering, так и для генерации обучающих данных при

ограниченных выборках, что напрямую релевантно настоящей работе и подробно обсуждается в разделе 2.6.3.

Несмотря на демонстрированную информативность вейвлетных признаков ЭМГ при задачах классификации мышечной усталости, распознавания движений и идентификации затяжной утомляемости, их применение для онлайн-детекции аэробно-анаэробного порога при ступенчатом велоэргометрическом тесте – особенно на VL в сочетании с NIRS и HRV – в рецензируемой литературе систематически не исследовалось.

1.3 Ближняя инфракрасная спектроскопия и локальная мышечная оксигенация

Ближняя инфракрасная спектроскопия (NIRS) основана на различии спектров поглощения оксигемоглобина (O_2Hb) и дезоксигемоглобина (HHb) в ближнем инфракрасном диапазоне (700 – 900 нм) [20]. При непрерывном облучении ткани и регистрации отражённого сигнала NIRS позволяет оценивать текущий баланс между доставкой и утилизацией кислорода непосредственно в работающей мышце – без временных задержек, присущих системным маркерам (лактат крови, вентиляционные показатели). Показатель тканевой сатурации кислорода (SmO_2 , %) отражает соотношение O_2Hb к суммарному гемоглобину (THb) в зондируемом объёме ткани и является наиболее клинически интерпретируемым выходным параметром портативных систем – Moxy Monitor и Train.Red.

Ключевой вопрос применения NIRS для детекции порога – какой именно параметр наиболее точно отражает лактатный порог. Wang и соавторы [21] в инкрементальном велоэргометрическом тесте ($n=15$) провели сравнительный анализ трёх NIRS-переменных. Точка перегиба ΔHHb была определена у всех 15 испытуемых; её корреляция с вентиляционным порогом составила $r=0,99$ по нагрузке и $r=0,97$ по VO_2 ($p<0,0001$), а с лактатным порогом – $r=0,76$ по нагрузке и $r=0,80$ по VO_2 ($p<0,05$). Точка перегиба ΔO_2Hb была определена лишь у 11 из 15 испытуемых и соответствовала значительно

более высоким нагрузкам. TOI (тканевой индекс оксигенации) коррелировал с вентиляционным порогом (VT) и нормированным индексом максимального суммарного гемоглобина (nTHI_{max}), но не был специфичным маркером лактатного порога (LT). Авторы заключили, что ΔHHb является оптимальным NIRS-параметром для определения LT при велоэргометрии, поскольку точно отражает динамику O₂-метаболизма независимо от перфузии.

Соответствие NIRS-порога (breakpoint оксигенации) вентиляционным и лактатным порогам подтверждено рядом независимых исследований. Lin и Huang [6] в выборке из 100 испытуемых показали, что полиномиальная регрессия 3-й степени, применённая к кривым O₂Hb и HHb, позволяет автоматически определять VT1 и VT2: пик функции O₂Hb соответствует VT1 ($35,0 \pm 1,0$ против $35,8 \pm 1,0$ мл·кг⁻¹·мин⁻¹ по вентиляционному методу, $p > 0,05$), а пик функции HHb – VT2 ($46,2 \pm 1,1$ против $47,4 \pm 1,0$ мл·кг⁻¹·мин⁻¹, $p > 0,05$). Воспроизводимость метода высокая: $r = 0,94$ между сессиями, Bland–Altman в пределах 95 % CI. Coquart и Mucci [22] показали, что первая точка перегиба O₂Hb в латеральной широкой мышце бедра (*m. vastus lateralis*; O₂Hb-T) коррелирует с газообменным порогом (GET, gas exchange threshold) ($r = 0,79$, $p < 0,001$, $n = 14$) и наступает практически одновременно с ним (незначимая тенденция к более раннему появлению), что отражает тесную связь локального мышечного метаболизма с системным газообменом. При этом оба параметра предсказывают время до истощения при 90 % W_{peak} ($r = 0,81$ и $r = 0,72$, $p < 0,01$ соответственно).

Двустороннее измерение SmO₂ повышает точность детекции порогов. Reinröld и Rannama [23] в выборке велосипедистов установили, что усреднённый билатеральный сигнал SmO₂ (Avr) обеспечивает лучшее соответствие с VT: смещение Pkg@BP2 относительно Pkg@VT2 составило лишь $0,03 \pm 0,22$ Вт/кг ($R^2 = 0,86$, $p > 0,05$). BP1 был систематически ниже VT1 ($0,12 \pm 0,29$ Вт/кг, $R^2 = 0,72$), причём у велосипедистов спринтерского типа наблюдалась тенденция к более раннему системному VT по сравнению с локальным NIRS-порогом. Авторы подчёркивают, что индивидуальная

вариабельность между системными и локальными порогами остаётся высокой, что исключает их полную взаимозаменяемость на индивидуальном уровне без верификации лактатным тестом. Иными словами, даже если средние значения по группе хорошо совпадают, у конкретного спортсмена локальный мышечный порог по NIRS может заметно не совпасть с системным порогом, определённым по дыханию или лактату. Валидация портативного NIRS-датчика van der Zwaard и соавторов [24] на велосипедистах показала умеренную корреляцию ВР с VT1 ($r=0,58 - 0,63$), что авторы объясняют крупным шагом нагрузочных ступеней (30 – 50 Вт) – важное методологическое замечание для дизайна ступенчатых тестов.

Среди преимуществ NIRS перед системными маркерами выделяют: непрерывность регистрации (против дискретных заборов крови), локальность сигнала (конкретная мышца, а не системный пул), и отсутствие временной задержки, связанной с транспортом лактата от мышцы к месту забора крови. В частности, Farzam и Starkweather [25] продемонстрировали, что портативная CW-NIRS (Humon Beta) коррелирует с лабораторной системой MetaOx по SmO_2 ($r=0,86$, $RMSE=3,4\%$), а Driller и Borges [26] провели валидацию носимого датчика BSXinsight на *m. gastrocnemius* у велосипедистов: наилучшее соответствие было получено с методом Dmax ($TEE=8,6$ Вт, $4,4\%$; $95\% LoA = \pm 17$ Вт; $r=0,96$).

Основным методологическим ограничением NIRS при измерении на работающих мышцах является влияние толщины подкожной жировой клетчатки (ATT, adipose tissue thickness). van der Zwaard и соавторы [24] показали, что ATT объясняет около 80 % межиндивидуальной вариабельности SmO_2 : при большей толщине жирового слоя регистрируемое снижение SmO_2 уменьшается, так как в зондируемый объём включается оксигенированная жировая ткань. Porov и Vinogradova [11] указывают, что при толщине жирового слоя более 10 мм мышечный сигнал может быть существенно замаскирован. Farzam и соавторы [25] подчёркивают, что простой порог SmO_2 недостаточен для надёжного определения LT: необходимы алгоритмы,

учитывающие динамику HbO, HbR и HbT совместно. Дополнительным ограничением является низкая воспроизводимость алгоритмов детекции порога по кривой StO₂: Cayot и Robinson [27] показали, что методы Dmax и mDmax дают ICC=0,351 и ICC=0,385 соответственно – недопустимо низкие значения для клинического применения, хотя сами кривые StO₂ воспроизводимы (ICC=0,841 – 0,873). Из этого следует, что проблема заключается не в стабильности сигнала NIRS, а в неадекватности существующих алгоритмов его обработки.

Несмотря на доказанную валидность NIRS для детекции порогов, стандартные алгоритмы (Dmax, mDmax) демонстрируют неприемлемую воспроизводимость при их применении к SmO₂. **Применение методов ML для автоматической и воспроизводимой детекции двух точек перегиба SmO₂ в реальном времени**, в том числе в сочетании с ЭМГ-сигналом той же мышцы, остаётся нерешённой задачей.

1.4 Вариабельность сердечного ритма и DFA- α 1 как онлайн-маркер первого порога

Вариабельность сердечного ритма (HRV) – показатель изменчивости последовательности RR-интервалов, отражающий состояние вегетативной нервной системы. При нарастании интенсивности физической нагрузки баланс сдвигается от парасимпатической к симпатической активности: RMSSD (квадратный корень из среднего квадрата последовательных разностей RR) нелинейно снижается, причём наиболее резкое падение совпадает с зоной VT1. Традиционные линейные метрики HRV (SDNN, SD1) имеют ограниченный динамический диапазон при нагрузке выше умеренной, что снижает их информативность в диапазоне выше первого порога. Метод детрендированного флуктуационного анализа (DFA) [28] позволяет оценить фрактальные свойства RR-ряда через показатель краткосрочного масштабирования DFA- α 1, который обладает широким динамическим диапазоном на протяжении всего инкрементального теста [29].

Теоретическое обоснование метода DFA- $\alpha 1$ строится следующим образом. В покое RR-ряд демонстрирует персистентные долгосрочные корреляции (DFA- $\alpha 1 \approx 1,0 - 1,2$), характерные для фрактального поведения; по мере нарастания нагрузки корреляционная структура постепенно разрушается. Rogers и Gronwald [29] обобщили накопленные к тому моменту данные: DFA- $\alpha 1 = 0,75$ ассоциирован с аэробным порогом (VT1) и получил обозначение «HRV-порог» (HRVT), а DFA- $\alpha 1 = 0,50$ соответствует анаэробному порогу (VT2/HRVT2). Практически это снижает зависимость признака от абсолютного масштаба измерений и упрощает его включение в ML-модель: DFA- $\alpha 1$ можно использовать как единый относительный показатель в разных протоколах и у спортсменов разного уровня, хотя индивидуальная вариабельность реакции сохраняется [29]. Алгоритм расчёта реализован в скользящем окне (рекомендуемый диапазон 4 – 16 ударов) с обновлением каждые 5 секунд, что делает его применимым для мониторинга в реальном времени. Коррекция артефактов RR при уровне менее 3 % не приводит к значимому смещению HRVT, что обеспечивает практическую устойчивость метода [29].

Чувствительность метода DFA- $\alpha 1$ к функциональному состоянию подтверждена экспериментально. Schaffarczyk и соавторы [30] исследовали чувствительность DFA- $\alpha 1$ к тренировочному статусу у триатлонистов ($n=11$): после тяжёлой беговой тренировки DFA- $\alpha 1$ во время стандартизированной разминки при 90 % VT1 значимо снижался ($p=0,001$, $d=-1,44$), тогда как нейромышечные тесты (CMJ) не выявляли значимых изменений, что свидетельствует о том, что DFA- $\alpha 1$ отражает вегетативный аспект усталости.

Принципиальные ограничения метода DFA- $\alpha 1$ связаны с требованиями к качеству RR-сигнала и стационарности нагрузки. Первое: метод требует достаточной длины окна для надёжного оценивания фрактального показателя – рекомендованный диапазон составляет 4 – 16 ударов (порядка 2 минут при ЧСС 120 – 160 уд/мин), что ограничивает временное разрешение при онлайн-применении. Второе: при наличии артефактов RR ($>3\%$)

необходима коррекция, а при высоком уровне шума надёжность оценок снижается. Третье: метод показывает высокую межиндивидуальную вариабельность: один и тот же прирост нагрузки может вызывать существенно разную реакцию DFA- $\alpha 1$ у разных спортсменов, что требует индивидуальной калибровки [30].

Накопленные количественные данные по соответствию HRV-порогов лактатным и вентиляционным были обобщены в недавнем систематическом обзоре с мета-анализом Tanner и соавторов [31], охватывающем 50 исследований и 1160 субъектов. Согласно результатам мета-анализа, HRVT1 не отличался значимо от LT1/VT1 (стандартизованная средняя разность SMD=0,08 при незначимом значении), а коэффициент корреляции составил $r=0,85$ (95 % CI 0,75 – 0,91). Для второго порога HRVT2 vs LT2/VT2 величины оказались соизмеримыми: SMD=–0,06 (незначимо), $r=0,85$ (95 % CI 0,80 – 0,89). Принципиально важным выводом является то, что характеристики субъектов, тип эргометра, начальная мощность и шаг нагрузки не влияют на точность определения HRVT – метод устойчив к вариациям протокола; HRVT2 несколько лучше определяется при коротких ступенях нагрузки. Таким образом, мета-анализ показывает, что HRV-пороги в среднем хорошо воспроизводят лактатные и вентиляционные пороги в разных протоколах нагрузки; поэтому RR-интервалы обоснованно рассматриваются как самостоятельный неинвазивный входной канал мультимодальной системы предсказания порогов.

Метод DFA- $\alpha 1$ валидирован как неинвазивный маркер VT1, однако его применение ограничено первым порогом и требует качественного RR-ряда без существенных артефактов. Schaffarczyk и Gronwald [30] указывают на **перспективность онлайн-расчёта DFA- $\alpha 1$ через носимые устройства** (смарт-часы, нагрудные ремни) *как следующий шаг развития метода*, однако интеграция этого показателя с ЭМГ и NIRS в единый предиктивный алгоритм одновременного определения LT1 и LT2 в литературе не реализована.

1.5 Кинетика лактата: задержка системного сигнала относительно локального

Для корректной интерпретации лактатного порога, определяемого по капиллярной крови, необходимо понимать механизмы и временные характеристики транспорта лактата из работающей мышцы в системный кровоток. Bangsbo и Johansen [32] в классическом эксперименте с одноногим педалированием показали, что скорость выхода лактата из мышцы в кровь определяется разницей его концентраций между мышцей и кровью: чем эта разница больше, тем быстрее лактат покидает мышцу. В диапазоне внутримышечных концентраций от 0 до 45 ммоль·кг⁻¹ сырой массы эта зависимость была линейной, однако при высоких концентрациях транспортная система частично насыщается, и выход лактата начинает отставать от роста этого градиента. Доля медленных волокон (%ST) обратно пропорциональна градиенту лактата мышца–кровь: мышцы с большей долей медленных волокон удерживают меньший градиент при той же нагрузке. Внутримышечный pH при интенсивных нагрузках снижается до 6,73, а феморальный венозный pH – до 7,14–7,15, что само по себе влияет на транспортную кинетику [32].

MacLean и Bangsbo [33] впервые применили метод микродиализа для мониторинга интерстициального лактата в *m. vastus lateralis* в реальном времени при динамической нагрузке. Было установлено, что концентрация лактата в интерстиции VL в покое составляет $2,5 \pm 0,2$ mM – значительно выше, чем в артериальной ($0,9 \pm 0,2$ mM) и венозной ($1,1 \pm 0,2$ mM) плазме. При нарастании нагрузки относительное извлечение вещества микродиализным зондом из окружающей ткани (probe recovery) для лактата возрастало с ~32 % в покое до ~66 % при максимальной нагрузке. Это указывало на более быстрый перенос лактата в интерстициальном пространстве сокращающейся мышцы. Изменения интерстициального лактата коррелировали с венозными, но не с артериальными концентрациями, что подтверждает: интерстициальный лактат отражает локальный метаболизм, а

не системный пул [33]. Эти данные прямо указывают на существование концентрационной задержки: в начале ступени нагрузки капиллярный лактат (кончик пальца или мочка уха) отстаёт от реального внутримышечного значения.

Следствием описанной задержки является принципиальная зависимость определяемого лактатного порога от длительности ступеней тестового протокола. Ji и Sommer [34] и Wackerhage с Gehlert [1] указывают, что ступени короче 3 – 4 минут не позволяют достичь квазистационарного состояния лактата: системный лактат в конце короткой ступени продолжает нарастать и не отражает равновесное состояние, характерное для данной мощности. Это методически смещает определяемый порог в сторону завышения. Иными словами, если ступень слишком короткая, кровь ещё не успевает показать полный ответ на данную мощность, и потому порог ошибочно фиксируется на более высокой нагрузке, чем та, при которой метаболический переход уже начался в мышце. Дополнительно, протокол тестирования существенно влияет и на само значение порога: разные комбинации $\dot{V}O_{2\max}$ и $\dot{V}L_{\max}$ могут давать идентичные лактатные кривые с равным LT_{An} , что делает стандартизацию протокола обязательным условием для межиндивидуального сравнения [34]. В протоколе настоящего исследования используются ступени по 3 мин, что представляет разумный компромисс между требованиями к стационарности и практической длительностью теста для тренированных спортсменов.

Принципиально важную роль в понимании кинетики системного лактата играет объём вовлечённой мышечной массы. van Hall и Jensen-Urstad [35] в исследовании с одновременной работой рук и ног (имитация лыжного хода) показали, что при большой вовлечённой мышечной массе скорость появления лактата в кровотоке (R_a) может достигать 184 ± 17 $\mu\text{моль} \cdot \text{кг}^{-1} \cdot \text{мин}^{-1}$, хотя артериальная концентрация остаётся низкой ($< 2,5$ ммоль/л). Это объясняется тем, что часть работающих мышц одновременно активно поглощает лактат из крови и использует его как энергетический субстрат: около 95 %

поглощённого лактата окисляется непосредственно. Это означает, что при видах спорта с большой мышечной массой (лыжи, гребля) системный лактат принципиально ненадёжно отражает локальный метаболизм конкретной мышцы: часть мышц производит лактат, тогда как другая часть его потребляет через межмышечный шаттл [5]. Велозргометрия обладает в этом отношении методологическим преимуществом: нагрузка изолирована преимущественно на мышцы нижних конечностей (VL, RF, gastrocnemius), что существенно снижает масштаб межмышечного лактатного шаттлинга и делает системный лактат более репрезентативным для локального метаболизма квадрицепса.

Неработающие мышцы вносят существенный вклад в клиренс лактата из системного кровотока. Bangsbo и Aagaard [36] показали, что поглощение лактата неактивной мышцей пропорционально кровотоку: при двукратном увеличении перфузии поглощение удваивается, что указывает на перфузионное, а не транспортёрное ограничение в данных условиях. Транспорт лактата в неактивную мышцу котранспортируется с H^+ и вносит вклад в буферизацию системного ацидоза. При длительной нагрузке поглощение лактата неактивной мышцей снижается из-за её собственного закисления – ещё один аргумент в пользу временной нестационарности системного лактата. MCT1 играет центральную роль в этом процессе: Bonen и McCullagh [4] установили, что семидневная тренировка увеличивает содержание MCT1 в мышце на 118 %, а наклон регрессии мышца–фemorальная вена возрастает на 33 %, что отражает ускорение экстррузии лактата и улучшение системного клиренса.

Концепция лактатного шаттла, развитая Brooks [5], переосмысливает роль лактата как основного энергетического субстрата для аэробных тканей, а не как «отхода» анаэробного метаболизма. Лактат является связующим звеном между гликолитическими и окислительными компартментами как внутри одного волокна (внутриклеточный шаттл), так и между мышцами, а также от мышц к сердцу, мозгу и почкам (межклеточный и межорганный шаттл). Для задачи настоящей диссертации это означает, что NIRS-сигнал на *m. vastus*

lateralis ближе к моменту локальных метаболических изменений в основной работающей мышце, тогда как капиллярный лактат отражает не только его продукцию, но и последующий транспорт, перераспределение и клиренс в других тканях. Поэтому временное расхождение между NIRS breakpoint и лактатной меткой следует рассматривать не только как ошибку измерения, но и как физиологическое свойство самих сигналов. Таким образом, NIRS breakpoint на VL теоретически ближе к «правде» о мышечном метаболизме, чем капиллярный лактат, хотя на практике оба сигнала несут взаимодополняющую информацию.

Количественные данные о временной задержке между внутримышечным лактатом и капиллярным лактатом при ступенчатом велоэргометрическом тесте с шагом 30 Вт / 3 мин в литературе систематически не представлены. Это ограничивает точность разметки временных меток порога в ML-датасете и является источником неустранимой погрешности при верификации модели по лактатным меткам.

1.6 Машинное обучение и алгоритмы онлайн-детекции аэробно-анаэробного перехода

Автоматическая детекция аэробно-анаэробного перехода по физиологическим временным рядам является активно развивающейся областью, в которой методы машинного обучения постепенно вытесняют традиционные визуальные и пороговые алгоритмы. Принципиальные преимущества ML-подходов – способность улавливать нелинейные зависимости и интегрировать информацию из множества каналов – делают их особенно перспективными для задачи онлайн-детекции, где ни один отдельный физиологический сигнал не является достаточно надёжным в условиях реального времени.

1.6.1 Классический ML на ручных признаках

Среди существующих ML-подходов к классификации зон интенсивности и предсказанию порогов наиболее системный анализ был проведён Tomaszewski и Majorczyk [37] на датасете из 183 протоколов кардиопульмонального нагрузочного тестирования (CPET) с лактатными метками. Для предсказания аэробного порога (AeT) лучшим алгоритмом оказался Random Forest ($R^2=0,645$, $MAE=4,63$ Вт, $MSE=44,45$, $RMSE=6,67$ Вт), для анаэробного порога (AnT) – LightGBM ($R^2=0,803$, $MAE=3,44$ Вт). Анализ вклада признаков в решение модели (SHAP-анализ [38]) показал, что наибольшее влияние на предсказание оказывают минимальный уровень лактата и ЧСС в момент максимального лактата, то есть показатели, описывающие индивидуальные особенности лактатного ответа у спортсмена. ML-модели в этой работе, однако, использовали лишь лактатные и кардиореспираторные признаки, не включая ЭМГ или NIRS. Перечисленные ансамблевые алгоритмы на основе решающих деревьев – случайный лес [39], а также методы градиентного бустинга XGBoost [40] и LightGBM [41] – образуют семейство классических моделей, используемое и в настоящей работе.

Модельные подходы к предсказанию мощности на LT2 разрабатывались также в контексте метаболического моделирования. Fischer и Hävecker [42] показали, что регрессионная модель на основе трёх физиологических показателей – максимального потребления кислорода (VO_{2peak}), доли этого максимума, используемой на уровне LT2 ($\%VO_{2peak@LT2}$), и экономичности педалирования (Cc) – объясняет не менее 98 % вариации мощности на LT2 у молодых велосипедистов ($ICC \geq 0,961$). При определении Cc при 90 % LT2 точность достигала $ICC \geq 0,986$. Вклад VO_{2peak} составлял 62 – 67 % от общего R^2 , тогда как включение VL_{max} не улучшало точности предсказания. Ji и Sommer [34] продемонстрировали, что расчётный лактатный анаэробный порог ($cLTAn$) через метаболическую симуляцию модели Мадера ($VO_{2max} + VL_{max} +$ экономичность бега) сопоставим с mD_{max} ($ICC=0,87$) и OBLA

(ICC=0,74), однако применение этих методов возможно лишь по результатам уже завершённого теста, а не в реальном времени. Здесь mDmax и OBLA выступают не онлайн-алгоритмами, а традиционными постфактум-критериями разметки порога по полной лактатной кривой; поэтому сопоставимость с ними не решает задачу детекции по ходу теста.

Алгоритмы автоматической детекции точки перегиба (*changepoint detection*) являются альтернативой полным ML-моделям в задачах, где нужно не классифицировать весь сигнал целиком, а найти момент, когда его поведение заметно меняется. В контексте физиологических данных это может быть точка, после которой показатель начинает расти, снижаться или колебаться по иному закону, чем раньше. Полиномиальная регрессия 3-й степени, применённая Lin и Huang [6] к NIRS-сигналам, позволяет автоматически определять VT1 (пик O₂Hb) и VT2 (пик HHb) без ручной разметки. V-slope метод двойной кусочно-линейной регрессии с минимизацией суммы квадратов остатков, применённый Поповым и соавторами [11] к совместному сигналу nHHb–nEMG, успешно детектирует единственную точку перегиба. Для выявления двух порогов и детекции в скользящем окне требуются более гибкие подходы, например CUSUM (cumulative sum control chart), BOCPD (Bayesian online *changepoint detection*) или алгоритм *ruptures* (Python), однако применительно к многоканальным физиологическим сигналам (ЭМГ + NIRS + HRV) подобных работ в доступной литературе не представлено.

Работы с одиночными каналами демонстрируют ограниченную точность. Для NIRS: метод Dmax/mDmax по StO₂ показывает ICC<0,40 при тест-ретесте [27], тогда как полиномиальный метод по O₂Hb/HHb воспроизводим и точен [6]. Для ЭМГ: V-slope по nHHb–nEMG достигает r=0,89 с LT4 [11], но не предназначен для онлайн-применения. Для HRV: DFA- $\alpha_1=0,75$ детектирует VT1 (r≈0,85 по данным мета-анализа [31]), однако для LT2 надёжного порогового значения не предложено. Существующие мультимодальные работы, как правило, объединяют два канала: NIRS + ЭМГ

(метод АТННб-ЭМГ Попова), NIRS + вентиляция (Coquart, Mucci, 2017) или HRV + нагрузка (Rogers, Gronwald, 2022). Системы, объединяющие все три сигнальных модальности – ЭМГ, NIRS и HRV – для одновременного предсказания обоих порогов в скользящем окне реального времени, в доступной рецензированной литературе отсутствуют.

Критический анализ применения ML в спортивной науке, проведённый Rodu и соавторами [43], подчёркивает, что supervised ML должен дополнять, а не заменять гипотетико-дедуктивный подход: алгоритмы хорошо предсказывают численный результат, но сами по себе не объясняют, какие физиологические механизмы за ним стоят. Поэтому без связи с предметным знанием модель может обнаружить статистическую закономерность, которую нельзя уверенно интерпретировать как реальный механизм аэробно-анаэробного перехода. Авторы рассматривают три кейс-стади и обосновывают необходимость explainable ML – SHAP-анализа, интерпретируемых деревьев, локальных surrogate-моделей – как средства снижения риска артефактных выводов. Для настоящей диссертации это служит обоснованием обязательного сочетания SHAP-анализа значимости признаков с физиологической интерпретацией результатов: ML-модель не самодостаточна, и её предсказания подлежат проверке стандартными методами и согласованию с устоявшимися механистическими представлениями о порогах.

1.6.2 ML для временных рядов: LSTM, TCN и вейвлетные сети

Классический ML на ручных признаках предполагает структурную потерю временной зависимости сигнала: операция скользящего окна агрегирует множество отсчётов в один скалярный вектор признаков (под скользящим окном здесь понимается разбиение непрерывного сигнала на короткие временные фрагменты, каждый из которых затем сводится к фиксированному набору числовых признаков), и последовательные зависимости между окнами разрушаются на этапе подачи в модель. Random Forest, XGBoost и аналогичные ансамблевые методы получают на вход

разрозненные точки в признаковом пространстве и вынуждены полагаться на инженера-исследователя в части построения признаков, отражающих темпоральную динамику (например, скользящие производные, лаговые признаки, оценки наклона). Альтернативный класс моделей – нейронные сети для временных рядов: рекуррентные сети с долгой краткосрочной памятью (LSTM) [44], GRU и темпоральные свёрточные сети (TCN) – сохраняет последовательную структуру сигнала на уровне архитектуры и способен обучаться на временной эволюции состояния системы как таковой. Для задачи онлайн-детекции аэробно-анаэробного перехода это архитектурное преимущество принципиально: переход – событие, определяемое не моментальным значением сигнала, а характером его эволюции на временном горизонте порядка десятков секунд.

Применимость рекуррентных архитектур к физиологическим временным рядам убедительно продемонстрирована Zeng и соавторами [45] на крупномасштабном медицинском датасете: на выборке из 8599 пациентов на ИВЛ с 89 признаками LSTM достиг AUROC=0,828, GRU – 0,829 (статистически неотличимо), при этом из нетемпоральных моделей сопоставимую с RNN точность показали лишь Random Forest (0,820) и XGBoost (0,823), уступая им, однако, в качестве калибровки. Принципиально важным архитектурным свойством, отмеченным авторами, является то, что RNN обновляет предсказание вместе с поступлением каждого нового временного шага, тогда как ансамбль на ручных признаках выдаёт оценку только в конце окна. Это свойство прямо соответствует задаче онлайн-детекции порога в скользящем окне ступенчатого теста: с каждой новой секундой модель уточняет оценку оставшегося времени до порогов LT1 и LT2 на основе обновлённой истории. Дополнительный вывод исследования – облегчённая RNN-модель на 26 отобранных признаках была сопоставима с полной версией на всех 89 признаках – показывает перспективность совместного применения отбора признаков и RNN-архитектур, что особенно актуально при ограниченных размерах датасета.

Прямую демонстрацию того, что глубокая нейронная сеть способна предсказывать вентиляционный порог по одному физиологическому сигналу, привели Miura и соавторы [46]. На выборке из 260 пациентов с сердечно-сосудистыми заболеваниями, проходивших СРЕТ-тестирование, авторы обучили гибридную нейросеть (одномерные свёртки в сочетании с LSTM) на одноканальном ЭКГ (1000 Гц) и получили $r=0,875$ ($p<0,001$) между предсказанным и измеренным VT в тестовой когорте; смещение по Bland–Altman составило $-0,05 \text{ мл} \cdot \text{кг}^{-1} \cdot \text{мин}^{-1}$ (незначимо). Корреляция выше 0,7 сохранялась во всех субгруппах по полу, возрасту и диагнозу – модель обобщалась на гетерогенную популяцию. Принципиальное значение этой работы заключается в демонстрации применимости глубокого обучения для воспроизведения экспертной газоаналитической метки порога; ограничения – отличие популяции пациентов с ССЗ от здоровых тренированных спортсменов и одноканальная природа входа, уступающая мультимодальному стеку по информативности.

Альтернативой LSTM/GRU при предсказании метаболических переменных в реальном времени служат темпоральные свёрточные сети (TCN) [47], основанные на каузальных свёртках с расширяющимися дилатациями. Здесь каузальные свёртки означают, что модель в каждый момент использует только текущее и прошлые значения сигнала, не заглядывая в будущее, а расширяющиеся дилатации позволяют охватывать всё более длинную историю без резкого роста числа параметров. Amelard и соавторы [48] реализовали TCN-архитектуру для посекундного предсказания VO_2 из четырёх сигналов умной рубашки (ЧСС, резерв ЧСС, частота дыхания, минутная вентиляция) и мощности нагрузки у 22 участников на велоэргометре. Авторами было установлено, что оптимальная длина истории составляет 218 секунд, а при 187, 97 и 76 секундах отклонение модели от лучшей конфигурации не превышало 3 % – TCN устойчива к выбору длины рецептивного поля. Точность модели достигла -22 мл/мин (95 % CI $[-262, 218]$) по всем диапазонам интенсивности; классификация интенсивности

(vigorous/moderate/light) на основе предсказанного VO_2 – 94,1 %. Прямое сравнение показало превосходство TCN над LSTM и Random Forest. Для задачи онлайн-детекции порога TCN обладает несколькими операционными преимуществами по сравнению с LSTM: параллельное обучение (быстрее за счёт отсутствия последовательных рекуррентных шагов), управляемое рецептивное поле (длина истории задаётся явно через дилатации), стабильный инференс без проблем затухающих градиентов. Посекундное предсказание непрерывной метаболической величины (VO_2) темпоральной свёрточной сетью непосредственно параллельно задаче настоящей работы, в которой выходом модели является оценка оставшегося времени до достижения порогов LT1 и LT2.

Концептуальный мост между сигнальной обработкой и глубоким обучением представляют вейвлетные нейронные сети (wavelet CNN). В этих архитектурах первый слой реализует обучаемое вейвлет-преобразование: фильтры, инициализированные как фиксированный базис (например, db6), оптимизируются вместе с остальными параметрами сети под задачу. Тем самым, модель самостоятельно подбирает оптимальный частотный базис для конкретной классификационной или регрессионной задачи, что устраняет произвольность выбора базиса в классической DWT-предобработке. Tsinganos и соавторы [19] хотя и не применяли wavelet CNN в чистом виде, использовали wavelet decomposition как технику аугментации при обучении CNN на ЭМГ и получили прирост точности до +16 % – что косвенно подтверждает эффективность вейвлетных представлений в архитектурах глубокого обучения. При многоканальной записи (например, четыре канала ЭМГ Delsys Trigno на VL и четыре канала на RF) двумерная свёртка по пространству электродов и времени способна выучивать совместные пространственно-временные паттерны активации, что представляет потенциальное расширение настоящего исследования. Нейросетевые модели, в отличие от древовидных, не обладают встроенной мерой важности признаков, поэтому для их интерпретации применяется аксиоматический метод градиентной атрибуции

Integrated Gradients [49], распределяющий вклад каждого входа вдоль траектории от опорного состояния к наблюдаемому.

При ограниченном объёме выборки глубокие архитектуры (LSTM, TCN) несут более высокий риск переобучения, чем ансамблевые методы на ручных признаках; Amelard и соавторы [48] успешно применили TCN при $n=22$, однако их входные данные включали метаболические сигналы (минутная вентиляция, дыхательный объём), недоступные в полевых условиях настоящего исследования. Сбалансированный выбор архитектуры, таким образом, определяется размером датасета, доступностью входных каналов и интерпретационными требованиями: для основного результата диссертации представляется обоснованным использование базовых моделей RF/XGBoost на ручных признаках с SHAP-анализом, тогда как TCN рассматривается как направление расширенного эксперимента, предполагающего возможное последующее увеличение выборки.

1.6.3 Обучение при малых датасетах и стратегии валидации

В спортивной физиологии большинство исследований ограничены 10 – 40 субъектами вследствие трудоёмкости протоколов нагрузочного тестирования, инвазивного характера лактатного анализа и стоимости специализированного оборудования (метаболические анализаторы, многоканальные ЭМГ-системы, NIRS). Настоящее исследование включает $n=18$ испытуемых, что находится в характерном для области диапазоне. При малом числе испытуемых и большом числе извлекаемых признаков возрастает риск переобучения модели на особенностях конкретной выборки; поэтому особое значение приобретают выбор архитектуры, схема валидации и допустимые способы расширения обучающего набора.

При оценке обобщающей способности модели при малых n обычная k -fold кросс-валидация приводит к утечке данных: временные сегменты одного субъекта могут одновременно оказаться в обучающей и тестовой подвыборках, что искусственно завышает оцениваемое качество. В этом

случае тестовая подвыборка уже не является независимой: модель может опираться на индивидуальные особенности сигнала того же испытуемого, а не демонстрировать переносимость на нового человека. Единственный корректный метод оценки обобщаемости на новых субъектах в данном контексте – Leave-One-Subject-Out (LOSO): на каждой итерации модель обучается на $n-1$ субъектах и тестируется на одном оставленном. Rodu и соавторы [43] прямо подчёркивают, что невалидированные ML-результаты в спортивной науке нередко отражают «запоминание» обучающей выборки, а не реальную предсказательную силу, и требуют осторожной интерпретации. При $n=18$ LOSO обеспечивает 18 независимых тестовых оценок, что достаточно для статистически интерпретируемой агрегированной метрики и для построения доверительных интервалов с использованием bootstrap или непараметрических методов. При множественных попарных сравнениях конфигураций моделей контроль доли ложных открытий обеспечивается процедурой Бенджамини–Хохберга [50], которая менее консервативна, чем поправка Бонферрони, сохраняя при этом контроль над FDR. Для оценки неопределённости точечных предсказаний без априорных допущений о распределении ошибки используется конформное предсказание [51], формирующее интервалы с гарантированным покрытием на конечной выборке.

Стратегии аугментации обучающих данных, то есть искусственного создания дополнительных вариантов уже записанных сигналов, позволяют отчасти компенсировать малый размер выборки. Tsinganos и соавторы [19] систематически оценили техники аугментации ЭМГ и установили, что методы структурной модификации сигнала – плавная деформация амплитуды во времени (magnitude warping) и вейвлетное разложение (wavelet decomposition) – обеспечивают прирост точности классификации до +16 % на двух эталонных датасетах, тогда как простое аддитивное зашумление и использование перекрывающихся окон дают значительно меньший выигрыш. Принципиальным методологическим ограничением является то, что

аугментация выполняется в пределах одного субъекта обучающей выборки: синтетические сэмплы наследуют индивидуальные паттерны и не вносят новой межсубъектной вариабельности. Из этого следует, что аугментация не отменяет необходимости LOSO-валидации – напротив, она применима только к тренировочному фолду, тогда как тестовый фолд (оставляемый субъект) во избежание утечки сигнала всегда остаётся нетронутым.

Выбор класса модели при ограниченных данных подчиняется компромиссу между выразительностью и риском переобучения. При $n < 50$ субъектов ансамблевые методы (Random Forest, XGBoost, LightGBM) в качестве основной модели обычно предпочтительнее глубоких нейронных сетей: меньшее число параметров снижает риск переобучения, а древовидная структура обеспечивает интерпретируемость через SHAP-анализ. Дополнительным преимуществом являются низкие вычислительные затраты обучения и инференса, что существенно для онлайн-применения. Tomaszewski и Majorczyk [37] достигли $R^2=0,803$ для предсказания AnT с помощью LightGBM на 183 субъектах, и аналогичные результаты с RF/XGBoost на меньших выборках задокументированы в смежных работах [37]. Параллельно Zeng и соавторы [45] показали, что облегчённая RNN-модель на 26 отобранных признаках сопоставима с полной версией на всех 89 признаках; это подчёркивает важность предварительного отбора информативных признаков при ограниченных данных. Rodu и соавторы [43] рекомендуют начинать ML-исследование в спорте с интерпретируемых моделей и переходить к более сложным только при доказанной нехватке выразительной способности у базовых моделей.

Специфических рекомендаций по комбинированным стратегиям аугментации (в том числе вейвлетной) и валидации (LOSO) для задачи детекции лактатного порога по мультимодальным сигналам ЭМГ + NIRS + HRV при ограниченном объёме выборки в литературе не представлено. Настоящая работа является одной из первых, системно применяющих LOSO-

валидацию совместно с вейвлетной аугментацией ЭМГ в физиологическом контексте предсказания обоих порогов аэробно-анаэробного перехода.

1.6.4 Gap: мультимодальные онлайн-системы

В существующей литературе не представлено ни одной системы, одновременно объединяющей поверхностную электромиографию (ЭМГ), мышечную ближнюю инфракрасную спектроскопию (NIRS) и вариабельность сердечного ритма, представленную показателем DFA- $\alpha 1$, в единый алгоритм онлайн-предсказания обоих порогов – LT1 и LT2 – в скользящем окне в ходе ступенчатого нагрузочного теста. Прямым подтверждением этого разрыва служит работа Wireless Multi-Layered EMG/MMG/NIRS Sensor for Muscular Activity Evaluation [52], в которой описан беспроводной многослойный датчик, объединяющий ЭМГ, механомиограмму (MMG) и NIRS на одной точке *m. vastus lateralis* при велоэргометрии: авторы прямо констатируют в абстракте, что детекция анаэробного порога по комбинированным мультисенсорным данным «явно не решена» – техническая платформа существует, тогда как алгоритм онлайн-детекции порога по такого рода мультимодальным сигналам остаётся открытой задачей. Именно это отсутствие определяет актуальность и новизну настоящей диссертационной работы.

1.7 Физиологические особенности триатлонистов при велоэргометрическом тестировании

Триатлонисты представляют собой популяцию с высокой аэробной ёмкостью, тренирующую три вида на выносливость и располагающую хорошо развитыми центральными и периферическими механизмами адаптации к нагрузке. Разнородность выборки (любители + профессионалы) обеспечивает широкий диапазон физиологических параметров, что принципиально важно для обучения ML-модели: модель должна быть инвариантна к абсолютным значениям мощности на пороге и работать с нормализованными признаками.

Согласно доменным характеристикам популяции данного исследования, для любителей-триатлонистов типичны значения $VT1$ в диапазоне 150 – 220 Вт и $VT2$ – 200 – 280 Вт при велоэргометрии, тогда как профессионалы демонстрируют $VT1$ 220 – 300 Вт и $VT2$ 290 – 380 Вт. Референсные нормы мощности на LT2 для популяции, разработанные Fiedler и Woll [2] на базе репрезентативного немецкого исследования DEGS1, подтверждают выраженную зависимость порога от тренировочного статуса и пола. Метаболическая модель Fischer и Hävecker [42] показывает, что VO_{2peak} вносит наибольший вклад в мощность на LT2 (62 – 67 % R^2), что согласуется с общей физиологией: чем выше аэробная ёмкость, тем при более высокой абсолютной мощности наступает порог.

Стандартизация ступенчатых протоколов критична для воспроизводимости лактатного теста. Для тренированных спортсменов рекомендованы ступени мощностью 20 – 30 Вт с длительностью 3 – 5 минут: при более коротких ступенях не достигается квазистационарное состояние метаболизма, что смещает лактатный порог в сторону завышения [7]. В протоколе данной диссертации используются ступени +30 Вт / 3 мин, начиная с 60 Вт, с забором лактата за 15 секунд до начала каждой новой ступени. Schaffarczyk и Rogers [30] применяли эквивалентный протокол для DFA- $\alpha1$ в популяции триатлонистов, что делает данные работы непосредственно применимыми к нашей выборке.

Выбор триатлонистов как целевой популяции методологически обоснован по нескольким причинам. Во-первых, это спортсмены с детально разработанными тренировочными зонами, для которых точное определение порогов является инструментом ежедневного управления нагрузкой. Во-вторых, периодическое тестирование на велоэргометре является стандартным компонентом их подготовки, что обеспечивает мотивацию и соответствие протоколу. В-третьих, разнородность выборки (любители + профессионалы) формирует широкий диапазон лактатных профилей, необходимый для обобщения ML-модели. В-четвёртых, велоэргометрия с изолированной

нагрузкой на нижние конечности обеспечивает минимальный межмышечный лактатный шаттлинг, что повышает точность и согласованность системного лактата как метки порога.

1.8 Заключение по обзору литературы

Проведённый обзор литературы позволяет систематизировать текущее состояние знаний по проблеме неинвазивного определения аэробно-анаэробного перехода и выявить ключевой разрыв между имеющимися методами и практической потребностью. Физиологические механизмы двух порогов ($VT1/LT1$ и $VT2/LT2$) детально изучены: они связаны с кинетикой лактата, рекрутированием двигательных единиц, кислородным балансом в мышце и вегетативными сдвигами. Каждый из рассмотренных сигнальных каналов – ЭМГ, NIRS и HRV – демонстрирует достоверную информативность в отношении отдельных аспектов перехода: ЭМГ отражает рекрутирование быстрых ДЕ, NIRS – локальный кислородный дефицит, DFA- $\alpha1$ – вегетативные сдвиги, ассоциированные с $VT1$; при этом HRV-пороги дополнительно валидированы крупномасштабным мета-анализом [31], что делает их одним из наиболее обоснованных неинвазивных суррогатов лактатных и вентиляционных порогов.

Вместе с тем анализ литературы выявил несколько принципиальных ограничений существующих подходов. Первое: существующие алгоритмы детекции порога по отдельным каналам (D_{max}/mD_{max} по StO_2 , V-slope по $nNhb-nEMG$, пороговое значение DFA- $\alpha1=0,75$) разработаны для постфактум-анализа или для одиночного канала, но не для онлайн-предсказания в скользящем окне. Второе: из рассмотренных работ ни одна не объединяет три сигнальных модальности (ЭМГ + NIRS + HRV) в единую систему – даже в работах с многослойными датчиками алгоритм мультимодальной онлайн-детекции порога остаётся, по прямому признанию авторов, нерешённой задачей [52]. Третье: детекция второго порога ($LT2$) по неинвазивным сигналам – принципиально более сложная задача, почти не

решавшаяся методами ML. Четвёртое: фазовая структура педального цикла (push/pull), доступная через гироскоп датчика Delsys Trigno, не использовалась в качестве источника признаков ни в одной из найденных работ. Пятое: при характерных для области ограниченных размеров выборок комбинированные стратегии вейвлетной аугментации ЭМГ-сигнала [19] и LOSO-валидации систематически не применялись в задаче детекции порогов.

Центральный *gap* данного исследования формулируется следующим образом: в мировой литературе отсутствует системная методология онлайн-предсказания обоих порогов аэробно-анаэробного перехода (LT1 и LT2) по мультимодальным неинвазивным сигналам работающей мышцы – электромиографии (включая её вейвлетные представления), ближней инфракрасной спектроскопии и кардиальной вариабельности – в скользящем окне в ходе стандартного ступенчатого велоэргометрического теста у тренированных спортсменов на выносливость.

Настоящая диссертационная работа непосредственно закрывает этот разрыв: предлагается пайплайн, объединяющий признаки ЭМГ *m. vastus lateralis* (дистальная и проксимальная зоны; классические амплитудно-частотные индексы, вейвлетные признаки и разбивка на load- и rest-фазы по гироскопу), SmO₂ и ΔHHb по NIRS на VL, а также DFA-α1 по RR-интервалам в единую ML-модель для оценки времени до порогов LT1 и LT2 в режиме реального времени. Верификация проводится на выборке из 18 испытуемых с лактатным анализом как gold standard и breakpoint SmO₂ как вспомогательным маркером, с использованием LOSO-валидации и вейвлетной аугментации обучающего фолда. В следующем разделе подробно описываются материалы, методы сбора данных, алгоритмы предобработки и архитектура модели.

2 МАТЕРИАЛЫ И МЕТОДЫ

2.1 Участники исследования

В исследование включены 18 испытуемых (11 мужчин, 7 женщин) с различным уровнем физической подготовки – от людей, регулярно занимающихся в тренажёрных залах, до спортсменов, систематически тренирующихся в циклических видах спорта на выносливость. Критерии включения: регулярные физические тренировки объёмом не менее трёх часов в неделю, отсутствие травм опорно-двигательного аппарата в течение последних трёх месяцев, отсутствие сердечно-сосудистых противопоказаний к максимальным нагрузочным тестам. Все участники подписали форму добровольного информированного согласия. Характеристики выборки приведены в таблице 2.1.

Разброс времени достижения LT2 составил от 10 до 25 минут от начала основного теста, что отражает широкий диапазон аэробных возможностей участников. Гетерогенность выборки является методологическим преимуществом: ML-модель, обученная в таких условиях, вынуждена опираться на паттерны изменения сигналов, инвариантные к абсолютному уровню нагрузки, что повышает её обобщаемость на новых испытуемых.

Таблица 2.1 – Характеристики участников исследования

Параметр	$M \pm SD$	Min–Max
Возраст, лет	$33,1 \pm 7,5$	22 – 43
Рост, см	$171,5 \pm 8,8$	151 – 183
Масса тела, кг	$71,2 \pm 14,8$	45 – 104
ИМТ, кг/м ²	$24,0 \pm 3,2$	19 – 32
Время достижения LT2, мин	$14,8 \pm 4,7$	10,1 – 25,1
Время достижения LT1, мин	$8,8 \pm 3,3$	5,6 – 16,1

2.2 Протокол нагрузочного тестирования

Тестирование проводилось на велоэргометре Lode Excalibur Sport с электромагнитным управлением нагрузкой, обеспечивающим воспроизводимость мощности независимо от каденса. Использовался

ступенчатый протокол с нарастающей нагрузкой: первая ступень составляла 30 Вт (1 мин) для разминки и стабилизации сигналов датчиков; начиная с 60 Вт мощность увеличивалась на 30 Вт каждые 3 мин до достижения волевого отказа испытуемого. Испытуемым давалась установка педалировать с фиксированным каденсом в диапазоне 65 – 80 об/мин. Критерием остановки служила невозможность поддерживать фиксированный каденс. После остановки следовал период восстановления 2 – 4 мин при 60 – 100 Вт, который также фиксировался системой сбора. Последовательность ступеней мощности в программе сбора данных соответствовала предустановленной программе велоэргометра, что обеспечивало соответствие между мощностью нагрузки и временной разметкой в файле записи.

За 15 сек до начала каждой новой ступени выполнялся забор капиллярной крови из пальца для определения концентрации лактата. Анализ проводился на портативном биохимическом анализаторе Biosen C-line с диапазоном измерения 0,5 – 40,0 ммоль/л и погрешностью измерения менее 2 %. Результаты лактатного анализа вносились в файл HDF5 отдельным каналом по завершении теста.

2.3 Аппаратный комплекс регистрации

2.3.1 Электромиография и инерционные измерения

Поверхностная ЭМГ регистрировалась с *m. vastus lateralis* (VL) доминантной ноги двумя датчиками (в дистальной и проксимальной зонах мышцы) при помощи беспроводных датчиков Delsys Trigno Avanti. Каждый датчик представляет собой сдвоенный биполярный электрод с межэлектродным расстоянием 10 мм и встроенным трёхосевым акселерометром и гироскопом. Частота дискретизации ЭМГ-канала составляла 1926 Гц, гироскопического канала – 148 Гц. Датчики устанавливались по стандартным анатомическим ориентирам SENIAM: дистальный – на 2/3 расстояния от передней верхней ости подвздошной кости

до верхнего края надколенника, проксимальный – на 1/3 того же расстояния, оба с наклоном в направлении волокон мышцы. Датчики фиксировались на контактные патчи, поверх накладывался фиксирующий пластырь Hartmann Omnifix. Кожа в зоне установки датчиков предварительно обрабатывалась спиртовой салфеткой и очищалась марлевой для снижения импеданса контакта. Соединение с системой сбора данных осуществлялось через протокол TCP посредством подключения к Trigno Control Utility (TCU) – фирменному серверному приложению, транслирующему бинарный поток данных с датчиков по выделенному data-порту. Сигнал ЭМГ, поступающий от TCU, не содержит нумерации пакетов, поэтому восстановление временной оси при разрывах соединения производилось путём повторной синхронизации с внутренней шиной времени системы с последующим восстановлением временных меток по дельте от частоты дискретизации.

2.3.2 Ближняя инфракрасная спектроскопия

Мышечная оксигенация регистрировалась датчиком Train.Red PLUS, основанным на принципе непрерывной волновой ближней инфракрасной спектроскопии (cwNIRS). Датчик фиксировался над серединой брюшка m. vastus lateralis той же ноги, что и ЭМГ-датчики, при помощи штатного ремешка устройства. В ходе теста по протоколу ANT+ принимался только сигнал SmO_2 с частотой около 1–4 Гц – единственная переменная, транслируемая устройством в режиме реального времени. После завершения теста производилась выгрузка сессии из вендорского приложения Train.Red, содержащая полный набор каналов: SmO_2 (фильтрованный и нефильтранный), O_2Hb , HHb , THb , HBDiff ($\text{O}_2\text{Hb} - \text{HHb}$). Временная привязка вендорской выгрузки производилась по совпадению канала SmO_2 с ANT+-рядом; после выравнивания все каналы объединялись в единый HDF5-файл вместе с ЭМГ и RR-интервалами.

2.3.3 Сердечный ритм

RR-интервалы регистрировались биосенсорным поясом Zephyr BioHarness 3 (Medtronic, США), передающим данные по Bluetooth Low Energy согласно официально опубликованному производителем протоколу пакетной передачи. Система принимала бинарные пакеты фиксированной структуры, из которых извлекались последовательности RR-интервалов в миллисекундах. Поскольку RR-интервалы представляют собой событийный ряд, а не равноинтервальную дискретизацию, временная ось для данного канала накапливалась суммированием последовательных интервалов. При обнаружении разрыва последовательности нумерации пакетов временная ось синхронизировалась с внутренней шиной системы и продолжалась от точки восстановления.

2.4 Система синхронного сбора данных Sensync

2.4.1 Архитектура и мотивация

Для синхронной регистрации сигналов с разнородных источников разработана оригинальная программная система Sensync. Необходимость собственной разработки обусловлена отсутствием готовых решений, обеспечивающих одновременную запись разночастотных потоков (1926 Гц, 148 Гц, 3 – 4 Гц, событийный RR) в единый файл с общей временной осью и возможностью последующего воспроизведения и анализа в том же программном окружении.

Система прошла четыре крупные итерации разработки. На первом этапе реализовано приложение на Python с управляющим циклом трёх фаз (сбор с адаптеров, обработка, визуализация в Matplotlib). Ограниченные возможности управления привели к добавлению GUI-оболочки на Flet с сохранением Python-ядра. На третьем этапе визуализация была вынесена в отдельное React-приложение с обменом через Protocol Buffers, однако производительность такого решения оказалась недостаточной для высокочастотных потоков ЭМГ.

На четвёртом этапе принято решение о полном переходе на платформу Node.js / Electron / React с отказом от управляющего цикла в пользу событийно-ориентированной (event-driven) архитектуры. Ключевым мотивом последней итерации стал опыт работы с частично потерянными и несинхронизованными данными, собранными на предыдущем оборудовании, – это показало критичность единой временной модели для корректного совмещения разночастотных каналов.

2.4.2 Реализация

Sensync реализована как модульное десктопное приложение на платформе Electron (см. таблицу 2.2). Каждый источник данных инкапсулирован в изолированном плагине, выполняемом в отдельном потоке (`worker_thread`), что обеспечивает независимость обработки каналов и задействование нескольких процессорных ядер. Взаимодействие между плагинами осуществляется через внутреннюю событийную шину без прямых вызовов между модулями. Конфигурация набора активных плагинов и их взаимодействий задаётся профилем запуска, что позволяет переключаться между экспериментальными сценариями без изменения кода.

Таблица 2.2 – Технологический стек sensync

Компонент	Технология
Платформа	Electron (Node.js 20, TypeScript)
Пользовательский интерфейс	React 19, ECharts
Многопоточность	<code>worker_threads</code> (Node.js)
Формат хранения данных	HDF5 (библиотека <code>h5wasm</code>)
Подключение Delsys Trigno	TCP-сокеты к Trigno Control Utility
Подключение Train.Red PLUS	ANT+ (библиотека <code>ant-plus</code>)
Подключение Zephyr BioHarness	BLE (библиотека <code>@abandonware/noble</code>)
Обмен с вычислительными воркерами	Protocol Buffers
Вычислительные алгоритмы (ЭМГ)	Python <code>compute-worker</code>

Временная модель системы опирается на внутреннюю шину сессионного времени, отсчитываемого от момента старта записи; абсолютное время начала протокола сохраняется в метаданных. Это позволяет корректно обрабатывать разрывы соединения и обеспечивает воспроизводимость временных отношений между каналами при последующем анализе.

Данные всех каналов записываются в единый файл формата HDF5: каждый источник формирует отдельный набор данных (dataset) в иерархической структуре файла и буферизирует записи независимо батчами. Формат HDF5 обеспечивает эффективное хранение разнородных временных рядов, поддерживает произвольный доступ к сегментам данных и допускает хранение метаданных непосредственно в том же файле. Данные лактата вносятся в тот же файл отдельным каналом по завершении теста.

2.5 Предобработка сигналов

2.5.1 Электромиография

Сырой ЭМГ-сигнал (1926 Гц) подвергался следующей предобработке. Полосовая фильтрация: фильтр Баттерворта 4-го порядка, полоса пропускания 20 – 450 Гц. Режекторный (notch) фильтр: 50 Гц для подавления помехи промышленной сети. Вычисление огибающей: скользящее RMS в окне 250 мс. Нормализация: значения ЭМГ нормировались относительно среднего уровня на ступени 30 Вт для обеспечения межсессионной сопоставимости.

Разделение активности по фазам педалирования выполнялось на основе гироскопических данных (148 Гц): load-фаза ($\sim 0^\circ$ – 180° цикла) и rest-фаза ($\sim 180^\circ$ – 360°) определялись по пиковой угловой скорости гироскопа с использованием алгоритма детекции пиков.

2.5.2 Мышечная оксигенация

Сигналы SmO₂, HHb, HBDiff и THb из вендорской выгрузки Train.Red сглаживались скользящим средним в окне 10 сек для подавления артефактов движения. Производные $\Delta\text{SmO}_2/\Delta t$ и $\Delta\text{HHb}/\Delta t$ вычислялись как разность соседних значений соответствующего канала, делённая на временной интервал между ними. Пропущенные точки в ANT+-ряду SmO₂ (до выравнивания с вендорской выгрузкой) не интерполировались; признаки на соответствующих сегментах помечались как невалидные.

2.5.3 RR-интервалы и HRV

Перед вычислением HRV-признаков выполнялась детекция артефактов RR: интервалы, отклоняющиеся более чем на 20 % от скользящей медианы в окне 5 кардиоциклов, помечались как артефакты и замещались кубической интерполяцией по соседним валидным значениям. Равноинтервальный ряд RR (с шагом 250 мс) формировался кубической интерполяцией для вычисления временных HRV-показателей (RMSSD, SDNN) и нелинейных показателей методами анализа Пуанкаре (SD1, SD2) и детрендрованного флуктуационного анализа (DFA- $\alpha 1$ в окне 4 – 16 кардиоциклов).

2.6 Определение лактатных порогов (ground truth)

2.6.1 Определение LT1

LT1 определялся как момент первого пересечения лактатной кривой с уровнем исходный уровень + 0,4 ммоль/л, где исходный уровень – значение лактата на первой измеренной точке (конец ступени 60 Вт). Отдельного замера в покое протокол не предусматривал; первая точка является наименьшим надёжно доступным значением лактата в сессии.

Для точного определения момента пересечения по дискретным точкам забора строилась РСНП-интерполяция в плоскости мощность-лактат. Дискретная метка (момент забора крови на первой ступени выше порога) привязана к концу ступени и может запаздывать до 3 мин относительно реального момента пересечения порога внутри ступени. Для интерполяции выбран РСНП, а не кубический сплайн: при редких точках (интервал 3 мин) кубический сплайн может осциллировать и давать ложные пересечения порога, тогда как РСНП гарантирует монотонность внутри каждого интервала. Мощность в точке пересечения переводилась во время через линейную интерполяцию внутри ступени.

Целевой переменной модели служило интерполированное время LT1, выраженное как «время до LT1» – разность между временем LT1 и концом текущего скользящего окна.

2.6.2 Определение LT2

LT2 определялся методом модифицированного Dmax (ModDmax) на кубическом сплайне в плоскости мощность–лактат. Из точки первого достоверного роста лактата проводилась хорда до последней точки кривой; LT2 соответствует точке максимального перпендикулярного расстояния от кривой до этой хорды. Кубический сплайн выбран намеренно: метод Dmax является геометрическим и требует гладкой кривой с непрерывной второй производной (C^2); РСНП гарантирует монотонность, но первая производная на стыках скачет, что искажает форму «локтя» кривой. Мощность в точке LT2 также переводилась во время через линейную интерполяцию внутри ступени.

Целевой переменной модели служило время от конца скользящего окна до момента LT2 в секундах; отрицательное значение означает, что порог уже пройден.

2.6.3 Анализ чувствительности к задержке капиллярного лактата

Описанные выше моменты LT1 и LT2 локализуются по капиллярному лактату. Концентрация лактата в капиллярной крови отстаёт от концентрации во внутримышечной среде на физиологически значимую величину, точное значение которой зависит от индивидуальных характеристик испытуемого и в протоколе настоящего исследования не регистрировалось. Количественная коррекция такой задержки в работе не применяется.

Вместо этого проводится анализ чувствительности основных результатов к выбору величины предполагаемой задержки. Для LT2 рассматривается дискретная сетка сдвигов целевой переменной $\Delta \in \{45, 90, 135, 180\}$ с, охватывающая четверть, половину, три четверти и полную

длительность ступени нагрузочного протокола (180 с). При высокой интенсивности, соответствующей LT2, градиент мышца-кровь максимален, транспортёры МСТ1/МСТ4 работают в режиме частичного насыщения, и капиллярный сигнал объективно отстаёт от внутримышечного на величины указанного порядка; выбранный диапазон сетки охватывает физиологически правдоподобные значения такой задержки в отсутствие прямых количественных данных для ступенчатого велоэргометрического теста.

Для LT1 аналогичный анализ выполняется в усечённом виде ($\Delta \in \{45, 90\}$ с) и используется как отрицательный контроль. При низкой интенсивности градиент мышца-кровь мал и нестабилен между испытуемыми, величина задержки сопоставима с межиндивидуальной вариабельностью самого порога, и любая её содержательная коррекция была бы методологически некорректна. Включение LT1 в анализ чувствительности преследует не цель индивидуально скорректировать LT1, а цель противопоставить его поведение поведению LT2 на той же сетке.

Конкретная процедура отбора моделей, для которых проводится дополнительное обучение со сдвинутой целевой переменной, и общее число таких обучений описаны в разделе 2.8.4. Развёрнутое обоснование выбранной постановки – включая требования к индивидуальной коррекции, причины отказа от непрерывной формульной поправки и пределы применимости анализа чувствительности к временному сдвигу таргета в форме глобального сдвига – приведено в разделе обсуждения (ограничения метода).

2.7 Признаковое пространство и модальности

Признаки извлекались в скользящем окне 30 сек с шагом 5 сек. Для большинства временных моделей применялась разрежённая дискретизация – каждое шестое окно (шаг 30 с, перекрытие отсутствует) – с длиной контекста 6 или 12 мин в зависимости от архитектуры. Базовая рекуррентная модель использовала плотную нарезку: последовательность смежных окон с шагом 5 с, что соответствовало контексту порядка 75 с.

В настоящей работе используются следующие термины, которые сохраняются единообразно во всех последующих разделах:

- **Модальность / набор признаков** – совокупность признаков, соответствующих одному или нескольким сенсорным источникам: EMG, NIRS, HRV, EMG+NIRS, EMG+NIRS+HRV. Именно этот набор подаётся на вход модели.
- **Вариант набора признаков** – полный набор или вариант без абсолютных признаков. Во втором случае из входного вектора исключаются признаки, описывающие текущие средние уровни сигналов; эта ось варьирования независима от модальности.

Таким образом, сочетания «EMG+NIRS, без абсолютных признаков» и «EMG+NIRS, полный набор» соответствуют одной модальности, но двум вариантам состава признаков; сочетания «EMG+NIRS» и «HRV» представляют разные модальности независимо от выбранного варианта.

2.7.1 ЭМГ-признаки (EMG)

Признаки модальности EMG формируются из сырых сигналов поверхностной ЭМГ четырёхглавой мышцы бедра (m. vastus lateralis – дистальный и проксимальный электроды) в сочетании с кинематическими признаками педалирования. Итоговый набор содержит **~79 признаков**:

- 68 z-нормированных ЭМГ-признаков – статистики временного ряда ЭМГ (RMS, среднее, стандартное отклонение, перцентили, энтропийные и спектральные характеристики), вычисленные в пределах скользящего окна;
- 11 кинематических признаков – характеристики педального цикла: средняя каденс и её вариабельность; длительности фаз нагрузки и отдыха, их коэффициенты вариации и соотношение; трендовые показатели вариабельности за скользящее 30-секундное окно; энтропия выборки (Sample Entropy) по каждой фазе.

Z-нормировка проводилась per-subject: среднее и стандартное отклонение вычислялись по окнам первой ступени нагрузки и применялись ко всей сессии испытуемого без заглядывания вперёд (каузальность сохранена). Полный список признаков с техническими обозначениями приведён в приложении А.

2.7.2 NIRS-признаки

NIRS-признаки делятся на две группы. Признаки окна (15): для SmO₂, HHb, HBDiff и THb – среднее, наклон и стандартное отклонение внутри окна; для SmO₂ и HHb дополнительно производные $\Delta\text{SmO}_2/\Delta t$ и $\Delta\text{HHb}/\Delta t$; для SmO₂ – величина падения (drop) внутри окна. Накопленные признаки (3), вычисляемые от начала теста: отклонение SmO₂ от накопленного максимума, отклонение HHb от накопленного минимума, относительное падение SmO₂ от исходного базального уровня в процентах.

2.7.3 HRV-признаки

Из равноинтервального RR-ряда вычислялись временные показатели – среднее RR-интервала (mean RR), SDNN и RMSSD, отражающие общую вариабельность и короткопериодные флуктуации; нелинейные показатели анализа Пуанкаре – SD1, SD2 и их отношение SD1/SD2, характеризующие соотношение парасимпатической и симпатической составляющих; показатель детрендериванного флуктуационного анализа DFA- α_1 , вычисляемый по каузальному trailing-контексту 120 с шагом обновления 5 с. При расчёте DFA- α_1 диапазон 4 – 16 кардиоциклов использовался как набор масштабов анализа, а не как длина сегмента RR-ряда.

2.7.4 Признаки взаимодействия

Эти признаки включаются только в наборе EMG+NIRS+HRV. Произведение SmO₂ и mean RR кодирует одновременное снижение мышечной

оксигенации и учащение сердечного ритма – паттерн, характерный для приближения к порогу; произведение SmO_2 и $DFA-\alpha_1$ отражает совместную динамику периферического метаболизма и вегетативной регуляции, оба из которых демонстрируют точку перелома вблизи LT2; отношение $mean\ RR$ к текущей мощности нормирует вегетативный ответ на нагрузку, позволяя модели учитывать индивидуальную кардиальную эффективность.

2.7.5 Комбинации признаков

Тестировались пять комбинаций модальностей (см. таблицу 2.3). Обоснование: выявить минимально достаточный набор сенсоров, обеспечивающий точность, сопоставимую с полным мультимодальным набором.

Таблица 2.3 – Комбинации модальностей

Набор	Состав	Число признаков
EMG	ЭМГ (z-норм.) + кинематика педалирования	~79
NIRS	Оконные + кумулятивные признаки NIRS	18
HRV	7 признаков BCP из RR-интервалов	7
EMG+NIRS	EMG $\cup$ NIRS	~97
EMG+NIRS+HRV	EMG $\cup$ NIRS $\cup$ HRV $\cup$ взаимодействия	~107

2.7.6 Варианты комбинаций

Помимо полного набора параметров в каждой модальности анализировался вариант без признаков, представляющих абсолютные уровни сигналов в текущем окне: средних значений SmO_2 , HHb , $HbDiff$ и THb за окно, среднего RR-интервала, а также их перекрёстного признака ($SmO_2 \times$ среднее RR). Полный список технических обозначений этих признаков приведён в приложении А. Исходная гипотеза состояла в том, что модель, обученная исключительно на динамических признаках, не уступает модели, включающей абсолютные уровни. Подтверждение этой гипотезы имело бы практическое значение, поскольку снижало бы зависимость метода от индивидуальной базальной калибровки.

2.7.7 Базальные физиологические показатели

На калибровочной ступени нагрузки рассчитывались базальные физиологические показатели испытуемого: исходные характеристики сердечного ритма, мышечной оксигенации и мышечной активности. В настоящей версии методики эти величины рассматриваются как вспомогательные индивидуальные характеристики и не входят в основной блок сравнения моделей, описанный в разделе 2.8.

- **Антропометрия и состав тела:** возраст, рост, масса тела, ИМТ, процент жировой массы, угол фазы биоимпеданса;
- **Базальные физиологические показатели** (калибровочная ступень 30 Вт): средняя ЧСС, RMSSD, ЭМГ-активность дистального и проксимального электродов, мышечная оксигенация SmO_2 .

Эти признаки не входят в основное признаковое пространство модели предсказания и не создают утечки данных, поскольку относятся к дотестовому периоду и не содержат информации о целевой переменной.

2.8 Модели машинного обучения

2.8.1 Постановка задачи

Предсказание аэробно-анаэробного перехода формулируется как задача регрессии: по набору физиологических признаков, извлечённых из текущего скользящего окна сигналов, предсказывается оставшееся время (в секундах) до наступления соответствующего лактатного порога

В работе рассматриваются два независимых целевых показателя (таргета):

- **time_to_LT1** – оставшееся время (с) до первого лактатного порога (аэробный порог, LT1);

- **time_to_LT2** – оставшееся время (с) до второго лактатного порога (анаэробный порог, LT2).

Каждый таргет рассматривается как самостоятельная подзадача: обучение, отбор гиперпараметров и оценка качества производятся отдельно. Это обусловлено различием физиологических механизмов, определяющих LT1 и LT2, что влечёт различия в информативности модальностей признаков и в структуре предсказательной ошибки.

2.8.2 Формальная постановка

Пусть $\mathbf{x}_t \in \mathbb{R}^p$ – вектор из p признаков, вычисленных по каузальному скользящему окну сигналов, завершающемуся в момент времени t . Каузальность означает, что при формировании признаков используются только отсчёты сигналов из интервала $[t - W, t]$, где W – ширина окна; заглядывание вперёд по времени исключено. Параметры нарезки окон и их шаг описаны в разделе 2.7. Полный состав оконных признаков по всем модальностям приведён в приложении А.

Целевая переменная – оставшееся время до порога в секундах. По физиологическому смыслу эта величина монотонно убывает с ходом теста: чем позже момент t , тем меньше $y(t)$ при условии непрерывного роста нагрузки. Это свойство учитывается при интерпретации оконных предсказаний и их последующей агрегации на уровне испытуемого.

Задача машинного обучения состоит в построении функции:

$$\hat{y}_t^{(LT)} = f(\mathbf{x}_t; \hat{\theta}),$$

где $\hat{y}_t^{(LT)}$ – прогнозируемое время до наступления порога LT; $\mathbf{x}_t$ – вектор признаков, вычисленных по каузальному окну, завершающемуся в момент t ; θ – параметры модели, оцениваемые на обучающей выборке.

Функция обобщается на новых испытуемых. Критерий качества – средняя абсолютная ошибка (MAE, в минутах; обоснование перевода единиц – в разделе 2.9.1).

2.8.3 Формирование обучающей выборки

Для таргета LT2 в обучающую выборку включались окна с валидной разметкой времени до порога и при наличии сигналов достаточного качества во всех модальностях одновременно. Для таргета LT1 дополнительно использовался признак пригодности окна, формируемый на этапе разметки датасета.

После фильтрации датасет содержит 4 130 окон для LT1 и 3 651 окно для LT2, распределённых по 18 испытуемым.

Калибровочная ступень нагрузки (30 Вт) исключена из обучающих окон: её отсчёты используются только для вычисления базальных физиологических параметров и контроля нормировки, но не подаются в модели как целевые обучающие примеры. Включение этой ступени в обучающий набор создало бы методологическую утечку, поскольку целевая переменная `time_to_LT` на ней не определена, а характеристики сигнала на 30 Вт систематически отличаются от рабочих ступеней теста.

2.8.4 Методология широкого перебора

При малом числе испытуемых ($n = 18$) в актуальной версии методики применялся унифицированный систематический перебор конфигураций, охватывающий три семейства моделей: семейство классических моделей, рекуррентные сети и временные свёрточные сети. Семейство классических моделей (технический префикс `Lin` в пайплайне) включает 29 конфигураций на основе Ridge, HuberRegressor, ElasticNet, GradientBoostingRegressor и SVR; семейство LSTM включает 16 архитектур; семейство TCN – 4 причинные архитектуры.

Для семейства классических моделей базовый перебор образует полное

декартово произведение двух таргетов (LT1, LT2), пяти наборов признаков (EMG, NIRS, HRV, EMG+NIRS, EMG+NIRS+HRV) и двух вариантов состава признаков (полный набор и вариант без абсолютных признаков), что даёт 580 базовых конфигураций. Дополнительно для наборов признаков, содержащих EMG-компоненту, исследовались три режима формирования ЭМГ-признаков:

- фазо-разделённый режим, при котором признаки вычислялись отдельно для фаз нагрузки и восстановления;
- цикловой режим, при котором признаки вычислялись по объединённым участкам нагрузки и восстановления в пределах детектированного цикла педалирования;
- полнооконый режим, при котором признаки вычислялись по всем ЭМГ-отсчётам скользящего окна без фазового разделения.

Для LSTM и TCN использовалось произведение двух таргетов, трех наборов признаков (EMG, EMG+NIRS, EMG+NIRS+HRV) и тех же двух вариантов состава признаков; модальность NIRS отдельно в нейросетевые модели не подавалась.

Дополнительно к описанному выше перебору проводился целевой анализ чувствительности конечного набора отобранных моделей с использованием сетки сдвигов целевой переменной (см. раздел 2.6.3). Выбирались по два лучших представителя на каждое семейство – классическое, LSTM, TCN – отдельно для LT1 и LT2 по основной метрике рейтинга на baseline-конфигурации. Каждая из 12 отобранных моделей обучалась дополнительно на четырёх сдвигах для LT2 ($\Delta \in \{45, 90, 135, 180\}$ с) и двух сдвигах для LT1 ($\Delta \in \{45, 90\}$ с) на той же схеме валидации LOSO; это даёт $24 + 12 = 36$ дополнительных обучений сверх базового перебора.

2.8.5 Схема валидации

В качестве единственной схемы валидации во всех экспериментах применялась стратегия Leave-One-Subject-Out (LOSO). Суть метода: на каждой итерации один испытуемый целиком выносится в тестовое множество,

остальные 17 формируют обучающее множество; процедура повторяется для каждого из 18 испытуемых.

Внутреннее разбиение обучающей части LOSO-фолда на обучающую и валидационную подвыборки не использовалось: все 17 оставшихся испытуемых формировали обучающее множество, а оценка обобщающей способности выполнялась только на вынесенном тестовом субъекте. Для линейных моделей это означает однократное обучение на каждом фолде с сохранением параметров модели и тестовых предсказаний.

Для нейросетевых моделей обучение проводилось в течение фиксированного числа эпох. Поскольку при малом объёме выборки выделение отдельной валидационной подвыборки в рамках схемы LOSO приводило бы к дополнительной потере обучающих данных, итоговый анализ выполнялся по предсказаниям, полученным на последней эпохе обучения.

2.8.6 Семейство классических моделей

Семейство классических моделей реализует набор регрессионных моделей библиотеки scikit-learn. Несмотря на исторический префикс Lin в именах конфигураций, семейство не ограничивается линейными методами: помимо Ridge, HuberRegressor и ElasticNet, в него входят GradientBoostingRegressor и SVR. Для каждой комбинации «набор признаков × вариант состава признаков × таргет» перебирались конфигурации из таблицы 2.4; каждая конфигурация обучалась как самостоятельная модель и далее включалась в единое итоговое сравнение. Для EMG-содержащих наборов дополнительно исследовались три режима формирования ЭМГ-признаков: фазо-разделённый, цикловой и полнооконный.

Таблица 2.4 – Конфигурации семейства классических моделей

Алгоритм	Гиперпараметры
Ridge	$\alpha \in \{1, 10, 100, 1000\}$
HuberRegressor	$\varepsilon \in \{1, 1; 1, 35; 1, 5; 2, 0\}$
ElasticNet	$\alpha \in \{0, 01; 0, 1; 1, 0\} \times 11$ ratio $\in \{0, 2; 0, 5; 0, 9\}$
GradientBoostingRegressor	n_estimators $\in \{50, 100, 200\} \times$ max_depth $\in \{2, 3\}$
SVR (ядро RBF)	C $\in \{1, 10, 100\} \times \varepsilon \in \{0, 1; 1, 0\}$

В отличие от ранних скриптов, в актуальном пайплайне конфигурации семейства классических моделей не отбираются по отдельности внутри каждого LOSO-фолда. Все 29 базовых конфигураций рассматриваются как независимые кандидаты, а в EMG-содержащих постановках к ним дополнительно добавляются варианты `phase_split`. Итоговое сравнение выполняется после агрегирования subject-level метрик и LT-point метрик на этапе анализа.

2.8.7 Нейросетевые семейства моделей

Рекуррентные сети. LSTM-семейство включает 16 архитектур трёх типов: модели без проброса состояния, модели с пробросом состояния и модели с механизмом внимания. Модели первого типа используют последовательности длиной 6 окон, модели с механизмом внимания – 12 окон, а модели с пробросом состояния обрабатывают непрерывную запись целиком; для разных подтипов исследовались шаги дискретизации 30, 15 и 5 с.

Модели с пробросом состояния предназначены для моделирования длинного контекста без разрыва между соседними фрагментами сессии, тогда как модели с механизмом внимания усиливают вклад наиболее информативных участков последовательности при финальном предсказании. Для всех архитектур семейства LSTM исследовались два варианта входных данных: без вейвлет-преобразования и с дополнительными признаками, полученными методом непрерывного вейвлет-преобразования.

Свёрточные сети. Семейство TCN включало четыре причинные архитектуры. PureTCN использовалась как базовая временная сверточная модель с дилатированными причинными свёртками. MediumTCN представляла собой её более ёмкую модификацию, рассчитанную на моделирование более сложных временных зависимостей. DwtTCN сочетала временную сверточную обработку с вейвлет-разложением входного сигнала. WaveNetTCN реализовывала схему каскадных дилатированных причинных

свёрток, восходящую к архитектуре WaveNet.

Вейвлетные режимы. Вейвлетное обогащение в актуальной методике не рассматривается как отдельное самостоятельное семейство моделей, а задаётся как режим архитектуры. Для части LSTM используется непрерывное вейвлет-преобразование, тогда как одна из TCN-архитектур реализует дискретную вейвлет-компоненту на уровне самой модели; тем самым влияние многомасштабного представления оценивается в рамках единой схемы обучения и валидации.

Каждый запуск, независимо от семейства, сохраняет стандартизированный набор артефактов: метаданные конфигурации, таблицу предсказаний, а для нейросетевых моделей также историю обучения и контрольные точки по эпохам. Это обеспечивает воспроизводимость дальнейшего анализа без повторного обучения модели.

2.8.8 Агрегация оконных предсказаний

Оконные предсказания переводятся в оценку времени порога на уровне испытуемого. Используются три правила агрегации: медианное правило, правило первого пересечения и устойчивое медианное правило. Тем самым итоговая оценка модели строится не только по качеству оконной регрессии, но и по качеству восстановления времени наступления порога у конкретного испытуемого.

2.8.9 Стандартизированный аналитический этап и итоговый рейтинг

После обучения всех конфигураций результаты обрабатываются в рамках отдельного воспроизводимого аналитического этапа. На этом этапе из таблиц предсказаний и параметров моделей формируются subject-level метрики оконной регрессии, показатели ошибки определения самого порога, доверительные интервалы, таблицы парных статистических сравнений и стандартизированные рейтинги моделей.

Такое разделение позволяет одинаково обрабатывать результаты

семейства классических моделей и нейросетевых моделей: этап обучения отвечает за корректную LOSO-валидацию и сохранение артефактов, тогда как аналитический этап выполняет выбор итогового состояния модели, агрегацию оконных предсказаний, статистические сравнения и построение двух уровней итогового отбора. Первый уровень представляет собой raw-рейтинг по первичной пороговой метрике LT. Второй уровень представляет собой фильтрованный shortlist моделей, который формируется после проверки адекватности траектории и пересечения верхних квантилей по LT-качеству и качеству восстановления траектории; именно этот shortlist используется для последующей интерпретации и анализа объяснимости моделей.

2.9 Метрики качества

2.9.1 Две дорожки оценки качества

В работе используются две взаимодополняющие дорожки оценки качества, различающиеся уровнем, на котором измеряется ошибка. Первая дорожка оценивает точность регрессии по отдельным окнам сигнала; вторая дорожка оценивает точность восстановления самого момента порога на уровне испытуемого. Эти дорожки отвечают на разные исследовательские вопросы и поэтому не должны смешиваться в одном итоговом выводе.

- Оконная дорожка оценивает, насколько точно модель аппроксимирует остаточное время до порога в каждом отдельном окне. Пусть y_{ij} – истинное время до порога в j -м окне i -го испытуемого, а $\hat{y}_{ij}$ – соответствующее предсказание модели. Тогда оконная ошибка определяется как $e_{ij} = \hat{y}_{ij} - y_{ij}$, а средняя абсолютная ошибка по испытуемому вычисляется по формуле $MAE_i = \frac{1}{n_i} \sum_j |e_{ij}|$. Аналогично рассчитываются $RMSE_i = \sqrt{\frac{1}{n_i} \sum_j e_{ij}^2}$ и систематическое смещение $b_i = \frac{1}{n_i} \sum_j e_{ij}$. Эти показатели характеризуют качество регрессии как модели времени-до-события.

- Пороговая дорожка сворачивает все окна одного испытуемого в одну итоговую оценку времени наступления порога. Для каждого окна сначала восстанавливается абсолютное время порога $\hat{T}_{ij} = t_{ij}^{end} + \hat{y}_{ij}$, где t_{ij}^{end} – момент окончания окна. Далее для каждого испытуемого формируется одна итоговая оценка $\hat{T}_i$ по одному из трёх правил агрегации: медианному, правилу первого пересечения или устойчивому медианному правилу. После этого ошибка определяется уже на уровне одного момента порога: $E_i = |\hat{T}_i - T_i|$, где T_i – истинное время наступления порога. Эта дорожка отвечает на прикладной вопрос о том, насколько точно модель определяет сам момент LT у человека.

Практически это означает, что модель может демонстрировать хорошую оконную точность, но давать заметное смещение момента порога после свёртки по окнам, и наоборот. Поэтому для итогового ранжирования моделей в настоящей работе используется именно пороговая первичная метрика – средняя по субъектам ошибка медианного правила агрегации.

Единица измерения для всех временных ошибок – минуты: исходные значения в секундах конвертируются делением на 60 при расчёте сводных метрик и сравнительных таблиц.

2.9.2 Коэффициент детерминации R^2

R^2 оценивает долю объяснённой дисперсии, то есть, насколько модель лучше тривиального предсказателя – константы, равной среднему значению целевой переменной:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2},$$

где y_i – истинное время до порога для i -го наблюдения;
 $\hat{y}_i$ – предсказанное моделью значение;
 $\bar{y}$ – среднее истинных значений по выборке.

В рамках LOSO $R^2 < 0$ на конкретном фолде означает, что модель предсказывает хуже тривиальной константы $\bar{y}$ – физиологические сигналы не дали полезной информации для данного испытуемого.

2.9.3 Ранговая корреляция Спирмена (ρ)

Коэффициент ранговой корреляции Спирмена вычислялся между предсказанными и истинными значениями по всем тестовым окнам. Этот показатель устойчив к монотонным нелинейным искажениям шкалы и особенно информативен для задачи «когда наступит порог»: высокий ρ означает, что модель правильно ранжирует окна по близости к порогу даже при систематическом смещении абсолютных значений.

2.9.4 Базовые предсказатели

Для оценки нижней границы сложности задачи использовался тривиальный предсказатель MeanPredictor, который выдаёт константу, равную среднему значению целевой переменной по обучающему множеству фолда, и не использует ни физиологические сигналы, ни временную структуру теста. Такой baseline задаёт минимальный ориентир качества: модель, не превосходящая MeanPredictor, не извлекает полезной информации из доступных данных.

Базовая линия воспроизводилась в рамках LOSO совместно с основным экспериментом. Превышение её точности рассматривается как необходимое, но не достаточное условие содержательной полезности модели.

2.10 Постобработка

В настоящей работе постобработка представляет собой преобразование последовательности оконных предсказаний в итоговую оценку времени порога на уровне испытуемого. На первом шаге для выбранного состояния модели строится последовательность абсолютных оценок времени порога:

$$\hat{T}_{ij} = t_{ij}^{end} + \hat{y}_{ij}$$

где $\hat{T}_{ij}$ – оценка абсолютного времени наступления порога для окна j испытуемого i ;

t_{ij}^{end} – момент окончания окна;

$\hat{y}_{ij}$ – предсказанное остаточное время до порога.

После чего применяются три правила агрегации: медианное, правило первого пересечения и устойчивое медианное правило. Первый вариант использует медиану всех оконных оценок, второй фиксирует первый момент перехода прогнозируемого времени до порога через нуль, третий опирается только на окна, лежащие в окрестности порога.

Такое представление позволяет отдельно анализировать точность оконной регрессии и точность восстановления момента наступления порога у испытуемого.

2.11 Статистический анализ и интерпретация

2.11.1 Парные сравнения моделей: критерий Уилкоксона с поправкой Бенджамини–Хохберга

Для сравнения двух конфигураций моделей применялся парный критерий знаковых рангов Уилкоксона (двусторонний). Тест строился на попарно согласованных по субъектам векторах метрик: для каждого испытуемого сравнивались значения одной и той же метрики, полученные двумя моделями на общем пересечении доступных субъектов.

При множественных попарных сравнениях использовалась поправка Бенджамини–Хохберга при уровне значимости $\alpha = 0,05$. Коррекция выполнялась отдельно внутри каждой аналитической оси сравнения и для каждой метрики, что позволяло контролировать долю ложных открытий без избыточной потери мощности теста.

2.11.2 Дополнительные параметры эффекта и доверительные интервалы

Помимо критерия Уилкоксона, для тех же согласованных по субъектам выборок рассчитывались парный t -критерий, коэффициент d Коэна для парных различий, мера эффекта δ Клиффа, а также бутстреп-доверительные интервалы для разности средних.

2.11.3 Сравнения по аналитическим осям

Статистические сравнения в анализе строятся не для произвольных пар моделей, а по заранее заданным аналитическим осям, отражающим научные вопросы о структуре пайплайна.

- К обязательным осям относятся сравнения между семействами моделей, между наборами признаков внутри семейства, между полным набором и вариантом без абсолютных признаков внутри архитектуры, между вейвлетными и невейвлетными режимами внутри семейства, между различными режимами формирования ЭМГ-признаков внутри одной архитектуры, а также между задачами LT1 и LT2 для одного и того же класса модели.
- Дополнительно, при наличии соответствующих конфигураций, анализируются различия между рекуррентными моделями с пробросом и без проброса состояния, между моделями с механизмом внимания и без него, а также между различными шагами дискретизации внутри одной архитектуры.

Такая организация делает статистический слой воспроизводимым и избавляет от произвольного ручного выбора пар для сравнения: каждая ось соответствует отдельной методологической гипотезе о влиянии семейства модели, модальности или архитектурного режима.

2.11.4 Конформное предсказание (conformal prediction)

Точечное предсказание модели не даёт информации о его надёжности,

поэтому в анализе дополнительно строятся предсказательные интервалы с гарантированным покрытием. В актуальной реализации используется конформное предсказание по схеме leave-one-subject-out в форме джекнайф-плюс, при которой для каждого тестового субъекта интервал строится по абсолютным ошибкам остальных субъектов той же модели. Подробная оценка неопределённости точечных предсказаний вынесена в приложение Б.

Метод основан на предположении обменности субъектов и не требует параметрических предположений о распределении ошибок. Для малой выборки из 18 испытуемых применяется поправка на конечный размер выборки при вычислении $\hat{q}$, что особенно важно при оценке номинального уровня покрытия на уровне пороговых метрик.

По умолчанию анализируются уровни $\alpha = 0,2$ и $\alpha = 0,3$, то есть интервалы покрытия 80 % и 70 %. Более строгие уровни покрытия при $N = 18$ быстро вырождаются в почти тривиальные интервалы, близкие к использованию максимальной ошибки, поэтому они не рассматриваются как основной рабочий режим финального пайплайна.

2.11.5 Интерпретация модели: анализ важности признаков (SHAP)

Для интерпретации вклада отдельных признаков в предсказание времени до порога используется метод SHAP (SHapley Additive exPlanations). SHAP-анализ применяется только к автоматически отобраннным finalist-моделям семейства классических моделей (Lin) отдельно для задач LT1 и LT2. Отбор выполняется после фильтра адекватности траектории и пересечения верхних квантилей по LT-качеству и качеству восстановления траектории. Объектом объяснения является оконный регрессионный выход модели: для каждого окна значение SHAP разлагает предсказание на вклады отдельных признаков, где положительный вклад соответствует сдвигу предсказания в сторону большего времени до порога, а отрицательный – в сторону меньшего времени.

Агрегация SHAP проводится на нескольких уровнях. Базовый уровень составляет пооконное объяснение, после чего значения агрегируются

отдельно для каждого испытуемого, что позволяет анализировать межсубъектную устойчивость структуры вкладов. Далее строятся сводки на уровне модели и физиологических групп признаков (EMG, NIRS, HRV, кинематика и взаимодействия). Важность признака оценивается как среднее абсолютное значение SHAP, а важность модальности – как суммарный вклад признаков, принадлежащих данной группе. Такая схема делает интерпретацию согласованной с итоговым отбором моделей: объясняются не произвольные победители по одной метрике, а конфигурации, которые одновременно демонстрируют приемлемую точность определения порога и адекватность реконструируемой траектории.

3 РЕЗУЛЬТАТЫ

3.1 Логика экспериментальной проверки

Глава результатов построена не как перечисление вычислительных модулей, а как последовательная проверка исследовательских вопросов работы. В центре внимания находятся четыре связанные задачи: принципиальная осуществимость онлайн-предсказания лактатных порогов по данным носимых датчиков, роль отдельных модальностей и их комбинаций, различие между задачами LT1 и LT2, а также устойчивость и интерпретируемость лучших моделей.

Сравнение семейств моделей в настоящей главе относится к фактически достигнутой точности и устойчивости в постановке кросс-валидации с поочерёдным исключением одного испытуемого. При этом глубина последующего анализа намеренно несимметрична. Для всех семейств рассматривается достижимое качество предсказания, однако углублённая интерпретация выполняется только для тех групп моделей, для которых она методологически наиболее надёжна: для финальных кандидатных моделей классического семейства и для отдельно отобранных финальных конфигураций нейросетевых архитектур.

Такое сужение объясняется не априорным предположением о превосходстве одного семейства над другим, а сочетанием трёх факторов. Во-первых, выборка из 18 испытуемых ограничивает подтверждающую силу статистических выводов и делает нейросетевые модели более чувствительными к нестабильности между запусками. Во-вторых, классические модели опираются на явные оконные признаки, что позволяет интерпретировать их на уровне физиологических дескрипторов и модальностей. В-третьих, для нейросетевых моделей интерпретация носит характер сопоставления нескольких методов анализа вклада признаков на уровне модальностей и временной структуры, а не самостоятельной шкалы ранжирования.

Статистический слой результатов также требует отдельной оговорки. После поправки на множественные сравнения ни одно из парных сравнений в текущем анализе не достигает формального порога значимости. В условиях данной выборки это следует трактовать прежде всего как ограничение мощности тестов, а не как доказательство отсутствия направленных различий между подходами. Поэтому в последующих подразделах акцент делается не на дихотомии «значимо или незначимо», а на согласованности направления эффекта, величине сдвига, ранговом положении моделей, множестве доверенных кандидатных моделей и содержательной физиологической интерпретации.

Наконец, все результаты получены в едином стандартизованном вычислительном контуре, включающем подготовку датасета, унифицированные раннеры обучения, массовый запуск конфигураций и общий аналитический слой для агрегации метрик, сравнений и интерпретации. Для классических моделей, где это применимо, использовались фиксированные гиперпараметры и детерминированные источники псевдослучайности; для нейросетевых моделей фиксировались базовые генераторы случайности, хотя побитовая воспроизводимость весов не гарантировалась. Вследствие этого последующие подразделы следует читать как результаты единой воспроизводимой экспериментальной системы, а не как набор разрозненных частных запусков.

3.2 Общая работоспособность подхода

Первый вопрос главы результатов состоит в том, демонстрируют ли построенные модели принципиальную работоспособность самой постановки задачи, то есть возможность неинвазивного онлайн-предсказания приближения к LT1 и LT2 по данным носимых датчиков. Полученные результаты позволяют ответить на этот вопрос положительно. В постановке кросс-валидации с поочерёдным исключением одного испытуемого как классические, так и нейросетевые модели достигают нетривиальной точности,

что подтверждает информативность используемых сигналов и реализуемость самого подхода.

На уровне исходного рейтинга моделей лучшие значения медианной ошибки определения порога составили порядка 119 с для LT1 и 104 с для LT2. Уже на этом этапе видно, что среди верхних позиций присутствуют как модели классического семейства, так и нейросетевые конфигурации, то есть задача не сводится к успеху одного-единственного класса алгоритмов. Важнее, однако, другое: ошибки такого масштаба существенно меньше типичной продолжительности 3-минутной ступени нагрузочного протокола и потому подтверждают практическую осмысленность самой идеи пошагового онлайн-мониторинга приближения к порогу.

Вместе с тем данный подраздел сознательно опирается на исходный рейтинг только как на демонстрацию достижимого качества, а не как на окончательный выбор лучших моделей. Одной метрики ошибки по времени до порога недостаточно для интерпретации надёжности модели: даже при хорошем среднем качестве локализации порога возможны выраженный систематический сдвиг прогноза, тяжёлый хвост грубых ошибок или неудовлетворительное восстановление общей формы траектории. Поэтому уже на уровне общей работоспособности результаты следует читать многомерно – через сочетание ошибки локализации порога, систематического смещения, доли грубых промахов и устойчивости траекторных метрик.

Для этой цели в дальнейших подразделах используется рабочий порог грубой ошибки 120 с. Он не рассматривается как физиологическая константа, а задаёт практически осмысленный уровень серьёзного промаха в условиях ступенчатого протокола, где одна ступень длится 180 с. Ошибка такого порядка означает смещение прогноза на существенную часть соседней ступени и потому интерпретируется как потеря прикладной точности локализации порога. Более строгий вариант проверки чувствительности с порогом 90 с в текущей выборке приводил к исчезновению множества финальных кандидатных моделей при сохранении того же правила отбора,

поэтому основной анализ далее сохраняет порог 120 с как компромисс между строгостью критерия и устойчивостью отбора.

Таким образом, ответ на базовый вопрос этого подраздела является положительным: сам подход к онлайн-предсказанию приближения к лактатным порогам по данным носимых датчиков работоспособен. Однако из этого ещё не следует, что верхние строки исходного рейтинга автоматически соответствуют наиболее надёжным и физиологически интерпретируемым моделям. Именно поэтому логика более строгого итогового отбора будет рассмотрена отдельно в разделе 3.7.

Таблица 3.1 – Лучшая конфигурация каждого семейства по задаче LT1

Место в общем рейтинге	Семейство	ЭМГ-признаки	Ошибка LT, с	Смещение LT, с	Доля грубых ошибок	Медиана R^2
1	Классическое	По полному окну	119	23	0.45	0.78
21	LSTM	По фазам цикла	131	-13	0.49	0.82
88	TCN	По фазам цикла	150	9	0.66	0.59

В таблице 3.1 все модели из топа обучались на датасете без абсолютных признаков, а также на полном наборе модальностей

Таблица 3.2 – Лучшая конфигурация каждого семейства по задаче LT2

Место в общем рейтинге	Семейство	Модальности	Ошибка LT, с	Смещение LT, с	Доля грубых ошибок	Медиана R^2
1	TCN	EMG+NIRS+HRV	104	20	0.53	0.61
2	Классическое	HRV	108	39	0.50	0.65
3	LSTM	EMG+NIRS+HRV	109	-2	0.52	0.71

В таблице 3.2 все модели из топа обучались на датасете с абсолютными значениями признаков, а также с эмг признаками по фазам цикла.

3.3 Вклад модальностей

Следующий вопрос касается роли отдельных модальностей и их комбинаций. В рамках настоящей работы сравнивались одномодальные и мультимодальные постановки, прежде всего варианты на основе ЭМГ,

ЭМГ+NIRS и ЭМГ+NIRS+HRV. При этом данный подраздел следует читать в фиксированной аналитической рамке: речь идёт прежде всего о сравнении модальностей при стандартном фазо-разделённом режиме формирования ЭМГ-признаков. Влияние альтернативных режимов формирования ЭМГ-признаков рассматривается отдельно в разделе 3.6, чтобы не смешивать эффект модальности с эффектом способа агрегирования сигнала.

Для LT1 наблюдается достаточно согласованная картина: расширение одномодальной постановки до мультимодальной в большинстве случаев улучшает качество предсказания. Если сравнивать попарно совпадающие по архитектуре конфигурации, то вариант EMG+NIRS+HRV оказывается лучше чисто ЭМГ-постановки в 183 из 212 сопоставимых случаев (86,3 %), а медианный выигрыш по ошибке локализации порога составляет 34,7 с. При сравнении EMG+NIRS с EMG+NIRS+HRV улучшение наблюдается уже в 91 из 96 сопоставимых конфигураций (94,8 %), с медианным выигрышем 24,0 с. После поправки на множественные сравнения эти различия не сохраняют формальной значимости, однако направление эффекта оказывается исключительно устойчивым. Особенно заметно это при переходе от ЭМГ и ЭМГ+NIRS к конфигурации ЭМГ+NIRS+HRV. Такой выигрыш прослеживается как в классическом семействе, так и в рекуррентных и сверточных нейросетевых моделях. Иными словами, для первого порога объединение нескольких носимых каналов чаще оказывается полезнее, чем попытка опереться на один источник информации.

Для LT2 картина становится менее однозначной по интерпретации, но не по самому направлению эффекта. Если сравнивать совпадающие по архитектуре конфигурации, то вариант EMG+NIRS+HRV оказывается лучше чисто ЭМГ-постановки в 208 из 212 случаев (98,1 %), а его преимущество над конфигурацией EMG+NIRS наблюдается в 94 из 96 случаев (97,9 %). Медианный выигрыш при этих переходах составляет 54,0 и 44,1 с соответственно. При этом внутри классического семейства HRV-only конфигурации на LT2 оказываются лучше мультимодальных вариантов в 36

из 58 сопоставимых случаев (62,1 %), а медианное преимущество HRV составляет 12,6 с. Поэтому мультимодальность в целом остаётся полезной, однако выигрыш оказывается более зависимым от семейства модели и от конкретной конфигурации признаков. В одних случаях добавление NIRS к ЭМГ даёт лишь умеренный эффект или почти не меняет качество, тогда как в других случаях заметнее проявляется вклад HRV-компоненты. Это важно подчеркнуть отдельно: обнаруженная роль HRV не означает пересмотра исходной цели исследования, акцентированной на ЭМГ и NIRS, а описывает эмпирически выявленную особенность части моделей, прежде всего в задаче LT2.

Таким образом, ответ на вопрос о модальностях не сводится к простой формуле «чем больше датчиков, тем лучше». Для LT1 наиболее убедительным выглядит преимущество расширенных мультимодальных постановок. Для LT2 зависимость сложнее: выигрыш мультимодальности сохраняется, но распределяется неравномерно, а информативность HRV-компоненты становится более заметной, чем в задаче LT1. В дальнейших подразделах это различие будет рассматриваться как один из аргументов в пользу того, что LT1 и LT2 являются родственными, но не тождественными задачами (рисунок 3.1).




Рисунок 3.1 – Направление эффекта расширения модального состава для LT1 и LT2 в разных семействах моделей

3.4 Сравнение семейств моделей

После анализа модальностей естественным следующим шагом является сопоставление самих семейств моделей. Для настоящей работы этот вопрос принципиален, поскольку она сочетает два разных подхода к решению задачи: классические модели на основе явных оконных признаков и нейросетевые архитектуры, извлекающие временные закономерности непосредственно из последовательностей окон. При этом сравнение семейств в данной главе относится не к их гипотетическому максимальному потенциалу, а к реально достигнутому качеству в текущем экспериментальном дизайне.

Полученные результаты не позволяют говорить о существовании одного универсально доминирующего семейства. На уровне LT1 средняя ошибка локализации порога составляет 186,8 с для классического семейства, 188,4 с для LSTM и 195,8 с для TCN. Таким образом, весь разрыв между лучшим и худшим средним значением составляет около 9 с, что существенно меньше внутрисемейного разброса моделей (стандартное отклонение 23 – 41 с). Для LT2 картина также не сводится к победе одного класса моделей: средние значения составляют 172,3 с для классических моделей, 167,8 с для LSTM и 167,3 с для TCN, то есть межсемейный разрыв сокращается примерно до 5 с при внутрисемейном разбросе 25 – 47 с. Локальные преимущества отдельных конфигураций наблюдаются, однако на уровне всего семейства они не превращаются в безусловное превосходство.

Такой результат важен сам по себе. Он показывает, что в рамках данной выборки и данной схемы валидации классические модели с ручными признаками остаются конкурентоспособными по отношению к нейросетям и не могут рассматриваться лишь как слабая техническая базовая линия сравнения. Более того, на LT1 средняя ошибка классического семейства практически совпадает с LSTM, а на LT2 различие между тремя семьями укладывается в считанные секунды. Одновременно отсутствие универсального преимущества нейросетей не следует трактовать как доказательство их принципиальной слабости: скорее, речь идёт о том, что в

текущих условиях более сложная архитектура сама по себе ещё не гарантирует лучшего результата.

Внутри нейросетевых семейств дополнительно проявляется вторичная архитектурная ось – временная конфигурация модели. Длина последовательности, шаг дискретизации и, для части TCN-конфигураций, использование вейвлетного представления влияют на доступный модели временной контекст и, следовательно, на итоговое качество. Однако этот сюжет имеет подчинённый статус по сравнению с вопросами модальности, различия LT1 и LT2 и устойчивости финальных моделей. Поэтому далее временная конфигурация будет упоминаться как важный архитектурный фактор, но не как самостоятельный центральный результат главы.

Таким образом, ответ на вопрос о семействах моделей оказывается сдержанным. В данной работе нейросетевые модели не вытесняют классические решения, а сосуществуют с ними как альтернативный класс подходов со своими сильными и слабыми сторонами. Для дальнейшего анализа это означает, что итоговые выводы следует строить не вокруг поиска «лучшего семейства вообще», а вокруг сочетания задачи, модальности, режима признаков и устойчивости конкретных моделей (рисунок 3.2).




Рисунок 3.2 – Распределение ошибки локализации порога по семействам моделей отдельно для LT1 и LT2

3.5 LT1 и LT2 как разные задачи предсказания


Один из центральных вопросов всей работы состоит в том, можно ли рассматривать LT1 и LT2 как одну и ту же задачу с разными метками или же для них требуются разные модельные решения. Полученные результаты поддерживают вторую интерпретацию. Хотя оба порога относятся к одной физиологической оси нарастающей нагрузки, их предсказание опирается на неодинаковую структуру сигналов и приводит к различающимся конфигурациям лидирующих моделей.

Первый аргумент в пользу такого вывода даёт сравнение составов лучших и наиболее надёжных моделей. В итоговый набор финальных кандидатных моделей для LT1 вошли четыре классические мультимодальные конфигурации EMG+NIRS+HRV, тогда как для LT2 – только две модели, из которых одна опирается исключительно на HRV, а другая использует полный мультимодальный набор. Уже на уровне модальностей видно, что для LT1 более естественным ядром остаются решения, в которых ведущую роль играют ЭМГ и NIRS, тогда как для LT2 заметнее возрастает роль HRV-компоненты. Это различие проявляется не только в итоговых интерпретациях моделей, но и в распределении успешных конфигураций внутри семейства классических моделей и нейросетевых архитектур.

Второй аргумент связан с сопоставлением одних и тех же модельных конфигураций между двумя задачами. Если бы LT1 и LT2 фактически совпадали как задачи предсказания, можно было бы ожидать близкого профиля ошибок у одних и тех же моделей. Однако парные сравнения показывают, что для многих конфигураций величина ошибки заметно меняется при переходе от одного порога к другому, а типичный сдвиг не сводится к исчезающе малому. Если суммировать такие сопоставления по семействам, то медианный абсолютный сдвиг средней ошибки между LT1 и LT2 составляет около 23,5 с для классических моделей, 18,2 с для LSTM и 20,0 с для TCN. Особенно выражено это для временных сверточных и части

рекуррентных архитектур, где различия между задачами уверенно достигают десятков секунд.

Третий аргумент даёт сопоставление рангов моделей между задачами. По всему пулу конфигураций ранговая корреляция между LT1 и LT2 остаётся положительной, то есть успешные решения для одного порога нередко оказываются неплохими и для другого. Однако эта связь далека от полной эквивалентности: для всего пула моделей коэффициент Спирмена составляет около 0,57, внутри классического семейства – 0,58, а внутри семейства LSTM снижается до 0,40. Более высокая оценка для TCN (0,76) получена лишь на 18 сопоставимых конфигурациях и потому требует осторожной интерпретации. Напротив, внутри классического семейства согласованность рангов выше, что указывает не на тождество задач, а скорее на более стабильное поведение ручных признаков при переходе от LT1 к LT2 (рисунок 3.3).



Таким образом, LT1 и LT2 следует рассматривать как родственные, но не тождественные задачи предсказания. Они связаны общей физиологической логикой нагрузочного теста, однако различаются по тому, какие модальности и какие архитектурные решения оказываются наиболее полезными. Для дальнейшей интерпретации это означает, что обобщать результаты одного порога на другой без отдельной проверки нельзя: каждое семейство моделей и каждая комбинация модальностей должны оцениваться по LT1 и LT2 раздельно.

3.6 Абляция режимов формирования ЭМГ-признаков

Отдельный вопрос касается того, влияет ли способ формирования ЭМГ-признаков на качество классических моделей. В данном подразделе сравниваются три режима: фазо-разделённый, цикловой и полнооконный. При интерпретации важно не смешивать этот сюжет ни с разделом 3.3 о модальностях, ни с разделом 3.4 о временной конфигурации моделей. Если в разделе 3.3 основной интерес представляло сравнение различных наборов сигналов, а в разделе 3.4 – длины последовательности и шага анализа, то здесь рассматривается именно то, как меняется результат при переходе от раздельного учёта фаз цикла к более целостному использованию ЭМГ-сигнала внутри окна.

Для LT1 картина выглядит достаточно определённой в одном важном отношении: в верхней части рейтинга доминируют интегральные режимы формирования ЭМГ-признаков, то есть полнооконный и цикловой, тогда как фазо-разделённый режим практически исчезает из числа лучших конфигураций. Между полнооконным и цикловым вариантами нет столь же однозначного превосходства: по составу иллюстративного среза из 30 лучших классических EMG-содержащих моделей они представлены почти поровну, хотя полнооконный режим несколько чаще встречается у самой вершины рейтинга. Это позволяет сделать более осторожный вывод: для первого порога модели чаще выигрывают тогда, когда опираются не на жёсткое разделение

нагрузки и восстановления, а на более целостное представление динамики ЭМГ в пределах цикла или всего окна наблюдения.

Для LT2 ситуация иная. В том же иллюстративном срезе верхней части рейтинга одновременно присутствуют фазо-разделённые, цикловые и полнооконные конфигурации, причём различия между ними оказываются существенно менее однозначными. На этом основании нельзя утверждать, что один режим формирования ЭМГ-признаков универсально предпочтителен для второго порога. Скорее, для LT2 эффект режима оказывается ограниченно переносимым и сильнее зависит от того, с какими модальностями и с какой конкретной модельной конфигурацией он сочетается.

Тем самым абляция по режимам формирования ЭМГ-признаков усиливает один из главных выводов главы: LT1 и LT2 нельзя рассматривать как полностью одинаковые задачи. Для LT1 отказ от жёсткого фазового разделения ЭМГ выглядит практически полезным направлением. Для LT2 тот же шаг уже не даёт столь же устойчивого выигрыша и требует более осторожной интерпретации. Поэтому в дальнейших обсуждениях для LT1 имеет смысл рассматривать прежде всего интегральные режимы формирования ЭМГ-признаков, тогда как для LT2 выбор между ними требует более осторожной и контекстной интерпретации (рисунок 3.4).




Рисунок 3.4 – Состав иллюстративного среза из 30 лучших классических EMG-содержащих моделей по режимам формирования ЭМГ-признаков отдельно для LT1 и LT2

3.7 Надёжность лучших моделей: исходный рейтинг против финальных кандидатных моделей

До этого момента результаты главы описывались преимущественно через исходный рейтинг по ошибке локализации порога. Такой рейтинг необходим для прозрачного сравнения моделей, однако он не отвечает на вопрос о том, каким конфигурациям можно доверять как финальным кандидатам. Хорошее среднее значение ошибки по времени до порога ещё не гарантирует, что модель адекватно восстанавливает траекторию у типичного испытуемого, не даёт систематического смещения и не проваливается на существенной части выборки.

По этой причине в работе использовался дополнительный этап отбора, отделяющий исходных победителей по одной LT-метрике от множества финальных кандидатных моделей. Этот этап задавался не постфактум под конкретных лидеров, а как набор минимальных требований к физиологически осмысленной и практически пригодной траектории. В явном виде использовались пороги $r2_median \geq 0$, доля грубых ошибок $\leq 0,50$, а для LT2 дополнительно – покрытия области пересечения и стабилизации не ниже 0,80. В качестве одного из таких требований использовалась медиана R^2 , а не только среднее значение этого показателя: при выборке из 18 испытуемых медиана меньше зависит от одного-двух тяжёлых выбросов и позволяет проверить, не оказывается ли траектория хуже константного предиктора хотя бы для типичного участника. Ограничение на долю грубых ошибок задавалось как требование не проваливаться более чем в половине случаев. Более строгий вариант проверки чувствительности с порогом 90 с при тех же правилах отбора приводил к исчезновению множества финальных кандидатных моделей, поэтому в основном анализе был сохранён рабочий порог 120 с как

более реалистичный компромисс между строгостью критерия и устойчивостью отбора (рисунок 3.5).

Для второго порога к этим ограничениям добавлялись требования к покрытию области пересечения и стабилизации траектории. Их смысл состоял не в достижении формальной стопроцентной полноты, а в том, чтобы подавляющее большинство индивидуальных траекторий вообще доходило до интерпретируемой области, в которой локализация LT2 имеет физиологический смысл. В практическом виде это фиксировалось порогами $\text{zero_crossing_coverage} \geq 0,80$ и $\text{stable_window_coverage} \geq 0,80$. Значения этих порогов также следует рассматривать как рабочие критерии допустимости, а не как универсальные константы. Отдельно необходимо оговорить и область применения общего отбора: в объединённом варианте он использовался для классического семейства, поскольку здесь модели строятся на общей системе ручных признаков и допускают единообразную последующую интерпретацию. Для нейросетевых семейств те же ограничения применялись отдельно внутри каждой семьи, чтобы не смешивать вопрос надёжности с различиями между самими классами моделей.

Практический результат такого подхода состоит в том, что исходные лидеры и финальные кандидатные модели совпадают лишь частично. Для LT1 лучшая классическая конфигурация из таблицы 3.1 – ElasticNet($\alpha=0,01$; $l1_ratio=0,5$) с полнооконными ЭМГ-признаками – сохраняется и после дополнительной фильтрации. Для LT2 ситуация иная: лучшая классическая конфигурация из таблицы 3.2 – ElasticNet($\alpha=1,0$; $l1_ratio=0,2$) на HRV-признаках – в итоговый набор уже не входит. После дополнительного отбора для второго порога остаются более устойчивые модели ElasticNet($\alpha=0,1$; $l1_ratio=0,2$) на HRV и GradientBoostingRegressor($\text{max_depth}=3$; $\text{n_estimators}=50$) в мультимодальной постановке EMG+NIRS+HRV. Нейросетевые лидеры из таблиц 3.1 – 3.2 в данное множество не включались по определению, поскольку этот этап отбора был ограничен классическим семейством. Это ещё раз подчёркивает разницу между двумя задачами: если

для LT1 хороший результат по основной метрике чаще сочетается с приемлемым качеством траектории, то для LT2 противоречие между точностью локализации порога и устойчивостью формы кривой проявляется сильнее.

Таким образом, дополнительный отбор не заменяет исходный рейтинг, а уточняет его смысл. Исходный рейтинг показывает, какие модели лучше минимизируют ошибку определения порога. Множество финальных кандидатных моделей (таблица 3.3), напротив, выделяет те конфигурации, которые одновременно сохраняют приемлемую точность, устойчивость и интерпретируемость. Именно поэтому дальнейший анализ признаков и модальностей в работе опирается не на весь верх исходного рейтинга, а на этот более узкий и методологически защищённый набор моделей.

Таблица 3.3 – Финальные кандидатные модели классического семейства для LT1 и LT2

Порог	Модель	Модальности	ЭМГ-признаки	Ошибка LT, с	Доля грубых ошибок	Медiana R^2
LT1	ElasticNet($\alpha=0,01$; $l1_ratio=0,5$)	EMG+NIRS+HRV	По полному окну	119,4	0,449	0,776
LT1	ElasticNet($\alpha=0,01$; $l1_ratio=0,2$)	EMG+NIRS+HRV	По полному окну	121,5	0,466	0,729
LT1	Ridge($\alpha=10$)	EMG+NIRS+HRV	По полному окну	122,5	0,464	0,803
LT1	ElasticNet($\alpha=0,1$; $l1_ratio=0,9$)	EMG+NIRS+HRV	По полному окну	122,7	0,472	0,721
LT2	ElasticNet($\alpha=0,1$; $l1_ratio=0,2$)	HRV	Не используется	111,7	0,451	0,774
LT2	GradientBoostingRegressor($max_depth=3$; $n_estimators=50$)	EMG+NIRS+HRV	По полному окну	113,1	0,461	0,809




Рисунок 3.5 – Число классических моделей на последовательных этапах дополнительного отбора отдельно для LT1 и LT2




Рисунок 3.6 – Индивидуальные траектории истинного и предсказанного времени до LT1 для лучшей модели; в данном случае исходный лидер и финальная кандидатная модель совпадают, поэтому на каждом подграфике показана одна предсказанная траектория




Рисунок 3.7 – Индивидуальные траектории истинного и предсказанного времени до LT2 для исходного лидера и финальной кандидатной модели; различие между кривыми показывает, почему минимальная ошибка локализации порога не всегда совпадает с наиболее надёжной траекторией

Следует отметить, что отдельные панели на рисунках 3.6 – 3.7 отражают не только свойства модели, но и ограничения качества исходных данных. В частности, более шумная траектория у S007 на LT1 согласуется с повышенной зашумлённостью кардиорегуляторного канала, а укороченная траектория у S018 на LT2 обусловлена исключением части окон на этапе контроля качества.

3.8 Интерпретация финальных кандидатных моделей

После отбора финальных кандидатных моделей возникает следующий вопрос: какие именно сигналы и признаки лежат в основе полученных прогнозов. В данном подразделе эта задача решается отдельно для классических и нейросетевых моделей. Для классического семейства использовался анализ вкладов признаков методом SHAP, а для нейросетевых моделей – градиентная атрибуция с сопоставлением нескольких методов. Такой отдельный подход важен, поскольку сами модели имеют различную внутреннюю структуру и извлекают информацию из входных данных по-разному.

3.8.1 Классические модели: анализ вклада признаков

Для классического семейства интерпретация проводилась только на множестве финальных кандидатных моделей и прежде всего на уровне отдельных испытуемых. Это позволяет оценивать не только среднюю картину, но и её устойчивость между субъектами. Для LT1 набор финальных моделей оказался достаточно однородным: все они относятся к мультимодальной конфигурации с ЭМГ, NIRS и HRV, а основной вклад в прогноз вносит блок ЭМГ-признаков. В среднем по финальному набору около 63 % суммарного |SHAP| приходится на ЭМГ и ещё около 21 % – на NIRS, тогда как доля HRV составляет лишь около 5 %. На втором месте по важности устойчиво находится NIRS, тогда как вклад HRV и составных признаков оказывается заметно меньше. Такой результат хорошо согласуется с общей логикой первого порога: в его окрестности модель прежде всего использует локальные мышечные и оксигенационные изменения, а дополнительные признаки играют скорее поддерживающую роль.

Для LT2 картина менее однородна. В число финальных кандидатных моделей вошли как HRV-ориентированная конфигурация, так и мультимодальная модель, в которой одновременно присутствуют ЭМГ, NIRS и HRV. Поэтому здесь нельзя формулировать универсальный физиологический вывод о доминировании какой-либо одной модальности. Корректнее говорить, что в рамках текущего набора наиболее надёжных моделей для второго порога заметно усиливается роль кардиорегуляторных и составных признаков. Если исключить HRV-ориентированную модель и рассматривать только лучшую мультимодальную конфигурацию LT2, то около 39 % суммарного |SHAP| приходится на HRV, 28 % – на составные признаки, 21 % – на NIRS и лишь 12 % – на ЭМГ. Следовательно, различие между LT1 и LT2 проявляется не только в составе лучших моделей, но и в структуре наиболее информативных признаков.

При этом SHAP в данной работе следует трактовать как интерпретацию уже обученных финальных кандидатных моделей, а не как доказательство

причинной роли соответствующих сигналов. Сильной стороной этого слоя анализа является именно межсубъектная устойчивость: важен не только средний вклад признака по всей выборке, но и то, повторяется ли его значимость у разных испытуемых (рисунок 3.8).




Рисунок 3.8 – Средний вклад модальностей в классических финальных кандидатных моделях по данным SHAP отдельно для LT1 и LT2

3.8.2 Нейросетевые модели: градиентная атрибуция

Для нейросетевых семейств интерпретация проводилась отдельно внутри каждого семейства. Для LT1 в качестве наиболее надёжной рекуррентной модели рассматривалась конфигурация LSTMRegressor с длиной последовательности 6 и шагом 15 с, а для LT2 – конфигурация DwtTCN с длиной последовательности 30 и шагом 5 с. Здесь анализ вкладов имеет дополнительное измерение: помимо модальностей и отдельных признаков приходится учитывать ещё и распределение важности по временной оси.

Для LSTM-модели, соответствующей LT1, два градиентных метода дают практически совпадающую картину: на ЭМГ приходится 55,4 % суммарного вклада по Integrated Gradients и 54,6 % по GradientShap, на NIRS – 25,0 и 25,4 % соответственно, тогда как доля HRV не превышает 7,6 %, а составных признаков – 6,5 %. Метод маскирования даёт более сглаженный

профиль: доля ЭМГ снижается до 36,5 %, тогда как HRV и составные признаки возрастают до 15,3 и 14,2 % соответственно. На уровне отдельных признаков при этом в верхних позициях оказываются главным образом NIRS- и составные признаки, что означает не слабость ЭМГ-блока, а более распределённый характер его вклада: важность ЭМГ размазывается по множеству нормализованных каналов, тогда как некоторые признаки NIRS и составные признаки формируют более выраженные локальные пики. По временной оси модель опирается не только на последнее окно, а на краткую предысторию сигнала, что подтверждает использование накопленного временного контекста, а не только самой свежей информации.

Для TCN-модели, соответствующей LT2, картина сложнее. Градиентные методы снова показывают доминирующую роль ЭМГ на уровне модальностей: по Integrated Gradients и GradientShap на ЭМГ приходится 52,0 и 52,2 % суммарного вклада, на NIRS – 23,6 и 23,3 %, на HRV – 9,3 и 9,2 %, а на составные признаки – около 7 %. Однако при маскировании модальных блоков доля ЭМГ снижается до 28,6 %, тогда как вклад HRV возрастает до 16,9 %, а составных признаков – до 25,2 %. Уже на уровне отдельных признаков наибольший вклад вносят показатели HRV и составные признаки. Это хорошо согласуется с более сложной структурой LT2, которая уже проявлялась и в классическом семействе. Дополнительная особенность TCN-модели состоит в том, что по временной оси возникает выраженный чередующийся рисунок с шагом порядка 15 секунд. Его нельзя трактовать как самостоятельный физиологический ритм: он отражает архитектурную многошкальную обработку сигнала и, следовательно, ограничивает временное разрешение самой интерпретации.

Сопоставление нескольких методов атрибуции здесь имеет разный смысл. Близость результатов Integrated Gradients и GradientShap следует рассматривать как внутреннюю проверку численной устойчивости, поскольку оба метода родственны по конструкции. Отдельную независимую проверку даёт только маскирование модальных блоков. При этом различия между

подходами оказываются количественно существенными: для LSTM доля ЭМГ снижается с примерно 55 % по градиентным методам до 36 % при маскировании, а для TCN – с 52 % до 29 %, тогда как вклад составных признаков в TCN возрастает с 7 % до 25 %. В то же время и этот метод не является нейтральным арбитром важности: при коррелированных и частично избыточных входах, особенно между NIRS, HRV и составными признаками, отключение одного блока может частично компенсироваться другими. Поэтому расхождения между градиентными методами и маскированием нужно трактовать как метод-зависимую чувствительность анализа, а не как однозначное доказательство истинной важности соответствующей модальности (рисунок 3.9).




Рисунок 3.9 – Распределение вклада модальностей в нейросетевых финальных моделях для трёх методов атрибуции

3.8.3 Сопоставление классических и нейросетевых моделей

Если сопоставлять результаты анализа вкладов между классическими и нейросетевыми моделями на уровне модальностей, то для LT1 согласованность оказывается достаточно высокой. И в классических финальных моделях, и в наиболее надёжной LSTM-конфигурации доминирует

ЭМГ-блок, тогда как NIRS занимает вторую позицию. Это позволяет считать вывод о ведущей роли локальных мышечных признаков для первого порога достаточно устойчивым к выбору класса модели.

Для LT2 такое согласование выражено слабее. Здесь между SHAP и градиентной атрибуцией совпадает скорее общий сюжет: по сравнению с LT1 возрастает роль кардиорегуляторных и составных признаков. Однако точное ранжирование модальностей уже зависит от семейства модели. Это следует трактовать не как противоречие, а как дополнительный признак большей сложности второго порога: разные классы моделей извлекают из одних и тех же сигналов не полностью совпадающую информацию. Следовательно, кросс-семейное сопоставление для LT2 позволяет подтвердить не жёсткую идентичность интерпретации, а лишь согласованное направление сдвига по сравнению с LT1.

Таким образом, интерпретационный анализ усиливает один из главных выводов главы. Для LT1 наиболее устойчивый результат связан с доминирующей ролью ЭМГ при поддерживающем вкладе NIRS. Для LT2 структура признаков оказывается более неоднородной: вклад ЭМГ сохраняется, но заметно возрастает значение кардиорегуляторных и составных характеристик, а согласованность между различными классами моделей становится слабее. Это ещё раз подтверждает, что LT1 и LT2 следует рассматривать как две родственные, но не тождественные задачи предсказания.

3.9 Чувствительность результатов LT1 и LT2 к величине предполагаемой задержки капиллярного лактата

Для проверки устойчивости основного результата к выбору величины физиологической задержки капиллярного лактата относительно внутримышечного был выполнен анализ чувствительности к временному сдвигу таргета по схеме, описанной в разделах 2.6.3 и 2.8.4. Для каждой целевой переменной и каждого семейства моделей отбиралось по две лучших

модели; в классическом семействе отбор включал топ-ElasticNet (контрольная линейная конфигурация) и топ-SVR (нелинейный классический представитель). Результаты приведены на рисунках 3.10 и 3.11.




Рисунок 3.10 – MAE LT1 (в секундах) при сдвиге целевой переменной на Δ




Рисунок 3.11 – MAE LT2 (в секундах) при сдвиге целевой переменной на Δ

Зависимость MAE от величины сдвига оказалась практически плоской для всех представленных моделей как для LT2, так и для LT1. Для классических моделей колебания MAE при изменении Δ от нуля до полной длительности ступени протокола (180 с) совпадают с нулём в пределах вычислительной точности; это поведение является ожидаемым по построению, поскольку функции потерь этих моделей зависят только от остатков и инвариантны к константному сдвигу целевой переменной. Для нейросетевых моделей относительный размах MAE по сетке сдвигов в большинстве случаев также не превышает 3 – 5 %, за двумя исключениями на LT2: модель *stateful LSTM* демонстрирует относительный размах 15.8 % (19.7 с) с устойчивым ростом MAE при $\Delta \geq 135$ с, что объясняется переносом скрытого состояния между чанками последовательности субъекта и связанным с этим нарушением шкало-инвариантности стандартизации таргета; модель *TCN(DWT)* демонстрирует относительный размах 13.7 % (15.8 с), причём при ненулевых сдвигах MAE улучшается на ~16 секунд, что может отражать дополнительную сходимость свёрточно-вейвлетной архитектуры к локальным паттернам сигнала вблизи сдвинутой границы порога. На LT1 размах MAE для всех нейросетевых моделей не превышает 2.8 %.

Содержательная интерпретация наблюдаемого плато, включая обсуждение того, какие именно эффекты способна обнаружить выбранная постановка эксперимента, приведена в разделе 4.6.

4 ОБСУЖДЕНИЕ РЕЗУЛЬТАТОВ

4.1 Главный методический результат

Главный практический результат настоящей работы состоит в том, что неинвазивное предсказание LT1 и LT2 по данным носимых датчиков оказалось достижимым. Для лучших конфигураций ошибка локализации порога составила порядка двух минут для LT1 и менее двух минут для LT2, то есть оставалась меньше длительности одной ступени в используемом велоэргометрическом протоколе. Это означает, что модель не просто улавливает общую тенденцию, а способна различать соседние зоны нагрузки на масштабе, практически значимом для самого теста.

В то же время этот результат не следует переоценивать. Ошибка такого масштаба ещё не позволяет рассматривать предложенный подход как инструмент прецизионного индивидуального назначения тренировочных интенсивностей. Однако она уже делает его практически интересным для задач оперативной оценки приближения к пороговой зоне, грубого разделения тренировочных диапазонов и построения обратной связи в условиях, где инвазивный лактатный контроль или полноценная лабораторная диагностика недоступны. Иными словами, работа показывает не то, что задача уже решена во всей полноте, а то, что она решается с точностью, уже представляющей практический интерес для применения вне лабораторных условий.

4.2 Почему классические и нейросетевые модели оказались сопоставимы

Один из наиболее показательных результатов работы состоит в том, что лучшие классические и нейросетевые модели оказались очень близки по качеству. Такая близость легко провоцирует две слишком прямолинейные интерпретации: либо что классические модели в данной задаче лучше, либо что нейросетевые подходы здесь оказываются избыточными. Ни один из этих выводов не был бы корректным. Более корректно говорить о том, что в условиях настоящей задачи преимущество более сложного представления

сигнала оказалось частично нивелировано сочетанием малого объёма выборки и сильного ручного признакового пространства.

В классическом семействе на вход модели подавались уже физиологически осмысленные признаки: амплитудно-частотные ЭМГ-показатели, характеристики мышечной оксигенации, признаки вариабельности сердечного ритма, а также составные дескрипторы, связывающие локальные и системные компоненты ответа. Тем самым значительная часть структурирования сигнала выполнялась ещё до этапа обучения, и линейные либо слабо нелинейные модели работали уже не с сырым рядом, а с достаточно информативным представлением. Нейросетевые модели в этой работе также обучались в той же признаковой постановке, а не на сырых мультимодальных рядах, поэтому их возможное преимущество, связанное с самостоятельным извлечением скрытых представлений из менее обработанного сигнала, здесь заведомо не могло проявиться в полной мере. Такой выбор был сознательным: при $N = 18$ переход к менее агрегированным входам резко повышал бы риск переобучения, потребовал бы отдельной схемы объединения разночастотных сигналов и затруднил бы интерпретацию результатов. Поэтому сравнение семейств проводилось в общей признаковой постановке, а вопрос о возможном выигрыше от более сырых входов для нейросетей оставлен на следующий этап исследования. При этом, нейросетевые архитектуры показали сопоставимый уровень качества и, особенно для LT2, дали конкурентоспособные решения с иной структурой использования модальностей и временного контекста.

Следовательно, содержательный вывод состоит не в том, что одно семейство моделей оказалось лучше другого, а в том, что в рамках данной выборки и данной постановки хорошие результаты достигаются разными типами моделей, если они получают физиологически информативное представление сигнала. Для настоящей работы это означает, что ключевым фактором оказался не класс архитектуры сам по себе, а удачное сочетание

признакового описания, модальности и устойчивости модели на уровне отдельных испытуемых.

4.3 Вклад модальностей в предсказание порогов

Сопоставление модальностей показывает, что задача предсказания порогов не сводится к поиску одного универсально лучшего сигнала. Для LT1 наиболее устойчивый выигрыш даёт мультимодальная постановка: объединение ЭМГ, NIRS и HRV улучшает качество предсказания по сравнению с более простыми вариантами в большинстве сопоставимых конфигураций. Это хорошо согласуется с физиологией первого порога, где переход формируется постепенной перестройкой локального мышечного ответа, оксигенации и вегетативной регуляции, а потому выигрыш даёт именно сочетание нескольких частично независимых индикаторов.

Для LT2 картина сложнее. В среднем мультимодальные конфигурации также остаются сильными, особенно в нейросетевых моделях, однако в классическом семействе лучший результат был получен конфигурацией, которая использовала только вариабельность сердечного ритма. Этот факт не означает, что локальные мышечные сигналы не нужны; скорее он показывает, что для второго порога системные признаки в ряде случаев оказываются ближе к целевой метке, задаваемой по капиллярной крови. Иными словами, для LT2 системный компонент может играть более самостоятельную роль, чем для LT1.

Отдельно следует отметить, что мышечная оксигенация в настоящей работе редко выступали как самостоятельный лидер, но это не делает его бесполезной модальностью. Более корректно рассматривать его как локальный дополнительный источник информации, который в сочетании с другими сигналами сочетания проявляет себя сильнее, чем в изолированном виде. Тем самым различие между LT1 и LT2 проявляется и на уровне модальностей: для первого порога наиболее естественна мультимодальная

интеграция, тогда как для второго структура вклада оказывается менее симметричной и допускает особенно сильную роль HRV.

4.4 Режимы формирования ЭМГ-признаков и варианты предобработки

Результаты абляции по режимам формирования ЭМГ-признаков показывают, что для LT1 и LT2 важен не только набор модальностей, но и способ представления сигнала внутри окна. Для LT1 в верхней части рейтинга доминируют интегральные режимы, в которых ЭМГ описывается на уровне полного цикла или всего окна наблюдения, тогда как фазо-разделённый вариант практически исчезает из числа лучших конфигураций. Это хорошо согласуется с физиологией первого порога: на данном этапе нагрузка нарастает относительно плавно, и для модели оказывается полезнее накопительное описание изменений мышечной активности, чем жёсткое разбиение сигнала на отдельные фазы цикла.

Для LT2 картина менее однозначна. В числе лучших конфигураций здесь одновременно сохраняются фазо-разделённые, цикловые и полнооконные варианты, а выигрыш одного режима над другим уже не выглядит устойчивым. Такая асимметрия дополнительно поддерживает главный вывод главы результатов: LT1 и LT2 не следует рассматривать как одну и ту же задачу с разными метками. Если для LT1 более целостное описание ЭМГ действительно оказывается полезным, то для LT2 сохраняет значение контраст между отдельными фазами цикла, и поэтому преимущество интегральных режимов уже не является универсальным.

При этом данный результат не следует смешивать с вопросом о временной конфигурации нейросетевых моделей: в настоящем подразделе обсуждается способ формирования ЭМГ-признаков внутри окна, а не длина наблюдаемой последовательности и шаг анализа. Таким образом, полезность интегрального описания ЭМГ для LT1 не означает автоматически, что для той же задачи оптимальной окажется и более длинная временная память модели.

4.5 Статистическая мощность и FDR-коррекция

Отдельного обсуждения требует тот факт, что после поправки на множественные сравнения ни одно из парных сопоставлений не достигло формального порога значимости. Сам по себе этот результат не означает, что сравниваемые модели эквивалентны. В настоящей работе он прежде всего отражает ситуацию, в которой лучшие конфигурации оказываются очень близки друг к другу по качеству, а межсубъектная вариативность остаётся высокой относительно наблюдаемого эффекта.

Иными словами, при $N = 18$ и subject-level сравнении в схеме LOSO результаты следует читать не в логике жёсткой дихотомии «значимо / незначимо», а в логике согласованности направления эффекта, повторяемости ранговых соотношений и устойчивости выводов между несколькими аналитическими слоями. Такая ситуация типична для исследований с глубокой мультимодальной регистрацией, где цена каждого нового наблюдения высока, а различия между лучшими моделями оказываются малы по сравнению с межсубъектной вариативностью.

Поэтому содержательный вывод настоящей работы состоит не в том, что между семействами и конфигурациями нет различий, а в том, что при текущем объёме выборки эти различия нельзя статистически развести с достаточной уверенностью после FDR-коррекции. Для последующих исследований это означает, что следующий шаг должен быть связан не столько с усложнением отдельных архитектур, сколько с расширением выборки, если ставится задача убедительно различать близкие по качеству модели.

4.6 Капиллярная задержка лактата и пределы анализа чувствительности

Отдельного обсуждения требует задержка между локальными метаболическими изменениями в работающей мышце и их регистрацией по капиллярному лактату. Поэтому таргет LT2 в принципе содержит

дополнительную неопределённость, связанную не только с моделью, но и со способом его задания.

Коррекция такого таргета не может быть сведена к одному фиксированному сдвигу для всех испытуемых. Для индивидуальной поправки нужны данные, которых в настоящем протоколе не было: показатели транспорта лактата на уровне мышцы, метаболический профиль (VO_{2max} , VLa_{max}) или данные о сердечном выбросе и системной гемодинамике. Без них формульная коррекция стала бы не уточнением, а дополнительным недоказанным допущением.

Именно поэтому в работе не выполнялась искусственная коррекция времени наступления LT₂, а вместо этого был проведён анализ чувствительности с глобальным временным сдвигом таргета. Он показал плато ошибки по всем основным семействам моделей, однако интерпретировать это как физиологическую устойчивость к задержке лактата нельзя. Такой результат отражает прежде всего математическую инвариантность моделей к одинаковому глобальному сдвигу целевой переменной. Следовательно, для содержательной проверки этого эффекта нужен не общий, а индивидуальный параметр задержки для каждого испытуемого, что выходит за рамки настоящей работы.

4.7 Ограничения работы

Полученные результаты следует интерпретировать с учётом ряда ограничений, которые определяют как границы их переноса, так и направления дальнейшей работы. Наиболее очевидным ограничением является объём выборки: в исследование вошли 18 испытуемых. Этого оказалось достаточно для сопоставления точечных моделей в схеме LOSO и для выявления устойчивых направлений эффекта, однако недостаточно для надёжной индивидуальной калибровки доверительных интервалов. Как показано в приложении Б, при таком размере выборки интервальная оценка неопределённости закономерно получается избыточно широкой. Кроме того,

выбор лучших конфигураций и их количественная оценка выполнялись в рамках одного и того же LOSO-контура, поэтому полученные значения следует трактовать прежде всего как результаты внутреннего сравнительного исследования, а не как несмещённую внешнюю оценку окончательно отобранной модели. Следовательно, в настоящей работе практически значимым следует считать именно точечный прогноз близости к порогу, тогда как индивидуальная интервальная калибровка требует расширения выборки.

Второе ограничение связано с типом нагрузки. Все результаты получены на материале ступенчатого велоэргометрического теста, поэтому их перенос на другие виды спорта или неступенчатые протоколы не может считаться автоматически обоснованным. Физиологический профиль на других видах нагрузки отличается как по временной структуре, так и по соотношению локальных и системных компонентов. Вместе с тем в моделях намеренно не использовались абсолютное время теста и мощность нагрузки как самостоятельные входные каналы, а часть лучших конфигураций опиралась на относительно короткий контекст наблюдения. Это снижает вероятность того, что предсказание сводилось к простому распознаванию позиции внутри ступенчатого протокола, но не отменяет необходимости отдельной внешней проверки на других сценариях нагрузки.

Третье ограничение связано с тем, что каналы HHb, HBDiff и THb в используемой конфигурации NIRS-датчика не были доступны в документированном потоке реального времени, поэтому финальный файл эксперимента объединялся с данными вендорского экспорта. Это ограничивает переносимость полной модели в строго потоковый онлайн-контур.

Отдельно следует отметить ограничения, связанные с характеристиками обследованной группы. В исследование были включены здоровые физически активные взрослые 25 – 45 лет любительского уровня. Это означает, что полученные закономерности нельзя без дополнительной проверки распространять на спортсменов высокой квалификации, пожилые группы,

подростков или клинические популяции. Для всех этих категорий вероятны иные режимы вегетативного ответа, иная кинематика теста и иное соотношение между локальными мышечными и системными маркерами порогового перехода.

Из этих ограничений следуют и основные направления дальнейшей работы:

- Необходимо расширение выборки до 40 – 60 испытуемых, что позволит повысить статистическую мощность и перейти к содержательной индивидуальной калибровке интервальных оценок.
- Перспективным направлением является добавление протокола индивидуальной коррекции задержки LT2, основанного на независимых физиологических параметрах.
- Требуется внешняя репликация на других видах нагрузки и в других популяциях. При этом с прикладной точки зрения важен не только рост объёма выборки, но и формирование целевых подгрупп, для которых модель будет использоваться на практике. Для построения практически применимой модели целесообразно отдельно рассматривать достаточно однородные по возрасту, уровню подготовки и типу нагрузки группы, поскольку чрезмерная физиологическая неоднородность повышает вариативность ответа и затрудняет калибровку индивидуально полезного прогноза.
- Переход к нейросетевым архитектурам, обучаемым на более сырых мультимодальных временных рядах, а не только на заранее сформированном признаковом пространстве.
- С прикладной точки зрения следующим шагом должен стать переход от текущего пакетного анализа к потоковому режиму онлайн-предсказания.

Заключение

В настоящей работе разработан и верифицирован метод неинвазивного предсказания лактатных порогов LT1 и LT2 по данным носимых датчиков в условиях ступенчатого велоэргометрического теста. Метод основан на интеграции сигналов поверхностной электромиографии, ближней инфракрасной спектроскопии и variability сердечного ритма в задаче оценки времени до порогового события.

Показано, что задача неинвазивного онлайн-предсказания LT1 и LT2 является решаемой. Для лучших конфигураций ошибка локализации порога оставалась меньше длительности одной ступени используемого протокола, что свидетельствует о практической пользе подхода для задач оперативной оценки приближения к пороговой зоне вне лабораторных условий.

Установлено, что LT1 и LT2 не сводятся к одной и той же задаче с разными метками. Для LT1 наиболее устойчивый выигрыш обеспечивала мультимодальная интеграция сигналов и более целостное представление ЭМГ внутри окна. Для LT2 наряду с сильными мультимодальными конфигурациями существенную роль в ряде случаев играли системные признаки variability сердечного ритма.

Сопоставление классических и нейросетевых семейств показало, что лучшие представители обоих подходов в настоящей постановке близки по качеству. При этом решающее значение имели не тип архитектуры сам по себе, а качество признакового представления, состав модальностей и устойчивость модели на уровне отдельных испытуемых.

Дополнительный анализ показал, что отсутствие формально значимых различий после поправки на множественные сравнения отражает ограниченную статистическую мощность исследования. Анализ чувствительности временного сдвига таргета для LT2 выявил плато ошибки по основным семействам моделей, что указывает на необходимость индивидуализированного подхода к анализу задержки капиллярного лактата.

Полученные выводы относятся к ступенчатому велоэргометрическому протоколу, к выборке здоровых физически активных взрослых любительского уровня и к использованной сенсорной конфигурации. Перенос результатов на другие виды нагрузки, другие популяции и задачи прецизионного индивидуального назначения тренировочных интенсивностей требует отдельной проверки.

Перспективы дальнейшей работы связаны с расширением выборки, индивидуальной коррекцией задержки LT2, внешней репликацией на других типах нагрузки и популяциях, переходом к нейросетевым моделям на более сырых мультимодальных рядах и реализацией потокового режима онлайн-предсказания.

Таким образом, в работе решены основные поставленные задачи: разработан протокол синхронной регистрации мультимодальных физиологических сигналов при ступенчатом велоэргометрическом тесте, реализован алгоритм их предобработки и синхронизации, сформирован датасет для онлайн-предсказания близости к лактатным порогам, выполнено сопоставление классических и нейросетевых моделей в subject-level постановке, а также проведён интерпретационный анализ вклада признаков и модальностей. Это позволяет рассматривать предложенный подход как воспроизводимую основу для дальнейшего развития систем неинвазивной оценки пороговых зон нагрузки.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Lactate Thresholds and the Simulation of Human Energy Metabolism: Contributions by the Cologne Sports Medicine Group in the 1970s and 1980s / H. Wackerhage, S. Gehlert, H. Schulz [и др.] // *Frontiers in Physiology*. – 2022. – Т. 13. – С. 899670. – DOI: 10.3389/fphys.2022.899670.
2. Reference standards for power at lactate threshold 2 for cycle ergometry throughout the lifespan in Germany / J. Fiedler, M. Thron, S. Altmann [и др.] // *Journal of Sports Sciences*. – 2025. – Т. 43, № 16. – С. 1654–1664. – DOI: 10.1080/02640414.2025.2517913.
3. Lactate kinetics at the lactate threshold in trained and untrained men / L. A. Messonnier, C.-A. W. Emhoff, J. A. Fattor [и др.] // *Journal of Applied Physiology*. – 2013. – Т. 114, № 11. – С. 1593–1602. – DOI: 10.1152/jappphysiol.00043.2013.
4. Short-term training increases human muscle MCT1 and femoral venous lactate in relation to muscle lactate / A. Bonen, K. J. A. McCullagh, C. T. Putman [и др.] // *American Journal of Physiology – Endocrinology and Metabolism*. – 1998. – Т. 274, № 1. – С. E102–E107.
5. Brooks, G. A. What the Lactate Shuttle Means for Sports Nutrition / G. A. Brooks // *Nutrients*. – 2023. – Т. 15, № 9. – С. 2178. – DOI: 10.3390/nu15092178.
6. Detection of Ventilatory Thresholds using Near-Infrared Spectroscopy with a Polynomial Regression Model / C.-W. Lin, C.-F. Huang, J.-S. Wang [и др.] // *Saudi Journal of Biological Sciences*. – 2020. – Т. 27, № 9. – С. 2388–2394. – DOI: 10.1016/j.sjbs.2020.03.005.
7. Very Early Lactate Threshold in Healthy Young Men as Related to Oxygen Uptake Kinetics / K. Kominami, T. Nishijima, T. Okamoto [и др.] // *Medicine*. – 2015. – Т. 94, № 39. – С. e1559. – DOI: 10.1097/MD.0000000000001559.
8. The First Lactate Threshold Is a Limit for Heavy Occupational Work / P. Fasching, S. Rinnerhofer, G. Wultsch [и др.] // *Journal of Functional Morphology and Kinesiology*. – 2020. – Т. 5, № 3. – С. 66. – DOI: 10.3390/jfmk5030066.
9. Anaerobic Threshold Determination by Blood Lactate and Myoelectric Signals / A. Nagata, M. Muro, T. Moritani [и др.] // *Japanese Journal of Physiology*.

– 1981. – Т. 31. – С. 585–597.

10. Şayli, Ö. Correlation analysis between surface electromyography and continuous-wave near-infrared spectroscopy parameters during isometric exercise to volitional fatigue / Ö. Şayli, A. Akın, H. B. Çotuk // Turkish Journal of Electrical Engineering & Computer Sciences. – 2014. – Т. 22. – С. 780–793. – DOI: 10.3906/elk-1210-51.

11. Validity of a Muscle Specific Method to Evaluate the Anaerobic Threshold in Exercised Muscles / D. V. Popov, S. Yu. Kuznetsov, E. A. Orlova [и др.] // Human Physiology. – 2019. – Т. 45, № 2. – С. 174–179. – DOI: 10.1134/S0362119719020087.

12. Валидация метода для оценки анаэробного порога в работающей мышце / Д. В. Попов, С. Ю. Кузнецов, Е. А. Орлова [и др.] // Физиология человека. – 2019. – Т. 45, № 2. – С. 70–77. – DOI: 10.1134/S0131164619020085.

13. Racinais, S. Breakpoints in ventilation, cerebral and muscle oxygenation, and muscle activity during an incremental cycling exercise / S. Racinais, M. Buchheit, O. Girard // Frontiers in Physiology. – 2014. – Т. 5. – С. 142. – DOI: 10.3389/fphys.2014.00142.

14. Surface Electromyography Thresholds as a Measure for Performance Fatigability During Incremental Cycling in Patients With Neuromuscular Disorders / N. B. M. Voet, C. G. J. Saris, D. H. J. Thijssen [и др.] // Frontiers in Physiology. – 2022. – Т. 13. – С. 821584. – DOI: 10.3389/fphys.2022.821584.

15. Graham, R. B. The Assessment of Muscular Effort, Fatigue, and Physiological Adaptation Using EMG and Wavelet Analysis / R. B. Graham, M. P. Wachowiak, B. J. Gurd // PLOS ONE. – 2015. – Т. 10, № 8. – С. e0135069. – DOI: 10.1371/journal.pone.0135069.

16. A Comparative Study of EMG Indices in Muscle Fatigue Evaluation Based on Grey Relational Analysis during All-Out Cycling Exercise / L. Wang, Y. Wang, A. Ma [и др.] // BioMed Research International. – 2018. – Т. 2018. – С. 9341215. – DOI: 10.1155/2018/9341215.

17. Jamaluddin, F. N. A New Approach to Noninvasive-Prolonged Fatigue

Identification Based on Surface EMG Time-Frequency and Wavelet Features / F. N. Jamaluddin, F. Ibrahim, S. A. Ahmad // Journal of Healthcare Engineering. – 2023. – T. 2023. – C. 1951165. – DOI: 10.1155/2023/1951165.

18. Wang, G. The Analysis of Surface EMG Signals with the Wavelet-Based Correlation Dimension Method / G. Wang, Y. Zhang, J. Wang // Computational and Mathematical Methods in Medicine. – 2014. – T. 2014. – C. 284308. – DOI: 10.1155/2014/284308.

19. Data Augmentation of Surface Electromyography for Hand Gesture Recognition / P. Tsinganos, B. Cornelis, J. Cornelis [и др.] // Sensors. – 2020. – T. 20, № 17. – C. 4892. – DOI: 10.3390/s20174892.

20. Ferrari, M. A Brief Review on the History of Human Functional Near-Infrared Spectroscopy (fNIRS) Development and Fields of Application / M. Ferrari, V. Quaresima // NeuroImage. – 2012. – T. 63, № 2. – C. 921–935. – DOI: 10.1016/j.neuroimage.2012.03.049.

21. Which common NIRS variable reflects muscle estimated lactate threshold most closely? / L. Wang, T. Yoshikawa, T. Hara [и др.] // Applied Physiology, Nutrition, and Metabolism. – 2006. – T. 31, № 5. – C. 612–620. – DOI: 10.1139/H06-069.

22. Correlation of gas exchange threshold and first muscle oxyhemoglobin inflection point with time-to-exhaustion during heavy-intensity exercise / J. B. Coquart, P. Mucci, M. Lhermette [и др.] // The Journal of Sports Medicine and Physical Fitness. – 2017. – T. 57, № 3. – C. 171–178. – DOI: 10.23736/S0022-4707.16.06053-9.

23. Reinpöld, K. Agreement between Ventilatory Thresholds and Bilaterally Measured Vastus Lateralis Muscle Oxygen Saturation Breakpoints in Trained Cyclists: Effects of Age and Performance / K. Reinpöld, I. Rannama, K. Port // Sports. – 2024. – T. 12, № 2. – C. 40. – DOI: 10.3390/sports12020040.

24. Oxygenation threshold derived from near-infrared spectroscopy: reliability and its relationship with the first ventilatory threshold / S. van der Zwaard, R. T. Jaspers, I. J. Blokland [и др.] // PLOS ONE. – 2016. – T. 11, № 9. – C.

e0162914. – DOI: 10.1371/journal.pone.0162914.

25. Validation of a novel wearable, wireless technology to estimate oxygen levels and lactate threshold power in the exercising muscle / P. Farzam, Z. Starkweather, M. A. Franceschini // *Physiological Reports*. – 2018. – Т. 6, № 7. – C. e13664. – DOI: 10.14814/phy2.13664.

26. Evaluating a new wearable lactate threshold sensor in recreational to highly trained cyclists / M. Driller, N. Borges, D. Plews // *Sports Engineering*. – 2016. – Т. 19, № 3. – C. 229–235. – DOI: 10.1007/s12283-016-0198-6.

27. Estimating the Lactate Threshold Using Wireless Near-Infrared Spectroscopy and Threshold Detection Analyses / T. E. Cayot, S. G. Robinson, L. E. Davis [и др.] // *International Journal of Exercise Science*. – 2021. – Т. 14, № 4. – C. 284–294.

28. Quantification of Scaling Exponents and Crossover Phenomena in Nonstationary Heartbeat Time Series / C.-K. Peng, S. Havlin, H. E. Stanley [и др.] // *Chaos*. – 1995. – Т. 5, № 1. – C. 82–87. – DOI: 10.1063/1.166141.

29. Rogers, B. Fractal Correlation Properties of Heart Rate Variability as a Biomarker for Intensity Distribution and Training Prescription in Endurance Exercise: An Update / B. Rogers, T. Gronwald // *Frontiers in Physiology*. – 2022. – Т. 13. – C. 879071. – DOI: 10.3389/fphys.2022.879071.

30. Fractal correlation properties of HRV as a noninvasive biomarker to assess the physiological status of triathletes during simulated warm-up sessions at low exercise intensity: a pilot study / M. Schaffarczyk, B. Rogers, R. Reer [и др.] // *BMC Sports Science, Medicine and Rehabilitation*. – 2022. – Т. 14, № 1. – C. 203. – DOI: 10.1186/s13102-022-00596-x.

31. Tanner, V. Agreement Between Heart Rate Variability-Derived vs. Ventilatory and Lactate Thresholds: A Systematic Review with Meta-Analyses / V. Tanner, G. P. Millet, N. Bourdillon // *Sports Medicine – Open*. – 2024. – Т. 10, № 1. – C. 109. – DOI: 10.1186/s40798-024-00768-8.

32. Lactate and H⁺ effluxes from human skeletal muscles during intense, dynamic exercise / J. Bangsbo, L. Johansen, T. Graham [и др.] // *Journal of*

Physiology. – 1993. – T. 462. – C. 115–133.

33. MacLean, D. A. Muscle interstitial glucose and lactate levels during dynamic exercise in humans determined by microdialysis / D. A. MacLean, J. Bangsbo, B. Saltin // *Journal of Applied Physiology*. – 1999. – T. 87, № 4. – C. 1483–1490.

34. Comparison and Performance Validation of Calculated and Established Anaerobic Lactate Thresholds in Running / S. Ji, A. Sommer, W. Bloch [и др.] // *Medicina*. – 2021. – T. 57, № 10. – C. 1117. – DOI: 10.3390/medicina57101117.

35. Leg and arm lactate and substrate kinetics during exercise / G. van Hall, M. Jensen-Urstad, H. Rosdahl [и др.] // *American Journal of Physiology – Endocrinology and Metabolism*. – 2003. – T. 284, № 4. – C. E193–E205. – DOI: 10.1152/ajpendo.00273.2002.

36. Lactate and H⁺ uptake in inactive muscles during intense exercise in man / J. Bangsbo, T. Aagaard, M. Olsen [и др.] // *Journal of Physiology*. – 1995. – T. 488, № 1. – C. 219–229.

37. From data to decision: Machine learning determination of aerobic and anaerobic thresholds in athletes / M. Tomaszewski, A. Lukanova-Jakubowska, E. Majorczyk [и др.] // *PLOS ONE*. – 2024. – T. 19, № 8. – C. e0309427. – DOI: 10.1371/journal.pone.0309427.

38. Lundberg, S. M. A Unified Approach to Interpreting Model Predictions / S. M. Lundberg, S.-I. Lee // *Advances in Neural Information Processing Systems*. – 2017. – T. 30. – C. 4765–4774.

39. Breiman, L. Random Forests / L. Breiman // *Machine Learning*. – 2001. – T. 45, № 1. – C. 5–32. – DOI: 10.1023/A:1010933404324.

40. Chen, T. XGBoost: A Scalable Tree Boosting System / T. Chen, C. Guestrin // *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. – 2016. – C. 785–794. – DOI: 10.1145/2939672.2939785.

41. LightGBM: A Highly Efficient Gradient Boosting Decision Tree / G. Ke, Q. Meng, T. Finley [и др.] // *Advances in Neural Information Processing Systems*.

– 2017. – Т. 30. – С. 3146–3154.

42. Modeling lactate threshold in cycling – influence of sex, maximal oxygen uptake, and cost of cycling in young athletes / J. Fischer, F. Hävecker, S. Ji [и др.] // *European Journal of Applied Physiology*. – 2025. – Т. 125, № 6. – С. 2145–2158. – DOI: 10.1007/s00421-025-05744-y.

43. On Leveraging Machine Learning in Sport Science in the Hypothetico-deductive Framework / J. Rodu, A. F. DeJong Lempke, N. Kupperman [и др.] // *Sports Medicine – Open*. – 2024. – Т. 10, № 1. – С. 124. – DOI: 10.1186/s40798-024-00788-4.

44. Hochreiter, S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // *Neural Computation*. – 1997. – Т. 9, № 8. – С. 1735–1780. – DOI: 10.1162/neco.1997.9.8.1735.

45. Interpretable recurrent neural network models for dynamic prediction of the extubation failure risk in patients with invasive mechanical ventilation / Z. Zeng, X. Tang, Y. Liu [и др.] // *BioData Mining*. – 2022. – Т. 15, № 1. – С. 21. – DOI: 10.1186/s13040-022-00309-7.

46. Feasibility of the deep learning method for estimating the ventilatory threshold with electrocardiography data / K. Miura, S. Goto, Y. Katsumata [и др.] // *npj Digital Medicine*. – 2020. – Т. 3, № 1. – С. 141. – DOI: 10.1038/s41746-020-00348-6.

47. Bai, S. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling / S. Bai, J. Z. Kolter, V. Koltun // *arXiv preprint arXiv:1803.01271*. – 2018. – DOI: 10.48550/arXiv.1803.01271.

48. Temporal convolutional networks predict dynamic oxygen uptake response from wearable sensors across exercise intensities / R. Amelard, E. T. Hedge, R. L. Hughson // *npj Digital Medicine*. – 2021. – Т. 4, № 1. – С. 156. – DOI: 10.1038/s41746-021-00531-3.

49. Sundararajan, M. Axiomatic Attribution for Deep Networks / M. Sundararajan, A. Taly, Q. Yan // *Proceedings of the 34th International Conference on Machine Learning*. – 2017. – Т. 70. – С. 3319–3328.

50. Benjamini, Y. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing / Y. Benjamini, Y. Hochberg // Journal of the Royal Statistical Society: Series B (Methodological). – 1995. – T. 57, № 1. – С. 289–300. – DOI: 10.1111/j.2517-6161.1995.tb02031.x.

51. Angelopoulos, A. N. Conformal Prediction: A Gentle Introduction / A. N. Angelopoulos, S. Bates // Foundations and Trends in Machine Learning. – 2023. – T. 16, № 4. – С. 494–591. – DOI: 10.1561/22000000101.

52. Kimoto, A. A Wireless Multi-Layered EMG/MMG/NIRS Sensor for Muscular Activity Evaluation / A. Kimoto, H. Fujiyama, M. Machida // Sensors. – 2023. – T. 23, № 3. – С. 1539. – DOI: 10.3390/s23031539.

Приложение А

(справочное)

Полный состав оконных признаков

Ниже приведено полное соответствие технических обозначений (имён колонок в датасете) и физиологического смысла для всех признаков, используемых в моделях. Обозначения: **дист.** – дистальный электрод m. vastus lateralis; **прокс.** – проксимальный; **нагр.** – фаза нагрузки (нажатие педали); **восст.** – фаза восстановления (подъём педали).

Таблица А.1 – ЭМГ: временная область (16 признаков × 4 потока = 64)

Техническое обозначение	Поток	Физиологический смысл
z_vl_dist_load_rms	дист., нагр.	RMS – среднеквадратическое значение ЭМГ
z_vl_dist_load_mav	дист., нагр.	MAV – среднее абсолютное значение ЭМГ
z_vl_dist_load_wl	дист., нагр.	WL – длина волны (суммарное абс. изменение сигнала)
z_vl_dist_load_zcr	дист., нагр.	ZCR – частота нулевых пересечений
z_vl_dist_load_mdf	дист., нагр.	MDF – медианная частота спектра (Гц)
z_vl_dist_load_mnf	дист., нагр.	MNF – средняя (центроидная) частота спектра (Гц)
z_vl_dist_load_p_low	дист., нагр.	Доля мощности в полосе 20 – 50 Гц
z_vl_dist_load_p_mid	дист., нагр.	Доля мощности в полосе 50 – 150 Гц
z_vl_dist_load_p_high	дист., нагр.	Доля мощности в полосе 150 – 450 Гц
z_vl_dist_load_ratio_mid_high	дист., нагр.	Отношение p_mid / p_high
z_vl_dist_load_e_d2	дист., нагр.	Энергия вейвлетного субдиапазона d2 (~250 – 500 Гц)
z_vl_dist_load_e_d3	дист., нагр.	Энергия вейвлетного субдиапазона d3 (~125 – 250 Гц)
z_vl_dist_load_e_d4	дист., нагр.	Энергия вейвлетного субдиапазона d4 (~62 – 125 Гц)
z_vl_dist_load_e_d5	дист., нагр.	Энергия вейвлетного субдиапазона d5 (~31 – 62 Гц)
z_vl_dist_load_wavelet_entropy	дист., нагр.	Вейвлет-энтропия (неупорядоченность по субдиапазонам)
z_vl_dist_load_ratio_low_high	дист., нагр.	Отношение энергий (d4+d5) / (d2+d3)
z_vl_dist_rest_rms	дист., восст.	RMS ЭМГ в фазе восстановления
z_vl_dist_rest_mav	дист., восст.	MAV ЭМГ в фазе восстановления
z_vl_dist_rest_wl	дист., восст.	WL в фазе восстановления
z_vl_dist_rest_zcr	дист., восст.	ZCR в фазе восстановления
z_vl_dist_rest_mdf	дист., восст.	MDF в фазе восстановления
z_vl_dist_rest_mnf	дист., восст.	MNF в фазе восстановления

Техническое обозначение	Поток	Физиологический смысл
z_vl_dist_rest_p_low	дист., восст.	Доля мощности 20 – 50 Гц в фазе восстановления
z_vl_dist_rest_p_mid	дист., восст.	Доля мощности 50 – 150 Гц в фазе восстановления
z_vl_dist_rest_p_high	дист., восст.	Доля мощности 150 – 450 Гц в фазе восстановления
z_vl_dist_rest_ratio_mid_high	дист., восст.	Отношение p_{mid} / p_{high} (восст.)
z_vl_dist_rest_e_d2	дист., восст.	Энергия d2 в фазе восстановления
z_vl_dist_rest_e_d3	дист., восст.	Энергия d3 в фазе восстановления
z_vl_dist_rest_e_d4	дист., восст.	Энергия d4 в фазе восстановления
z_vl_dist_rest_e_d5	дист., восст.	Энергия d5 в фазе восстановления
z_vl_dist_rest_wavelet_entropy	дист., восст.	Вейвлет-энтропия (восст.)
z_vl_dist_rest_ratio_low_high	дист., восст.	Отношение $(d4+d5)/(d2+d3)$ (восст.)
z_vl_prox_load_rms	прокс., нагр.	RMS ЭМГ проксимального электрода (нагр.)
z_vl_prox_load_mav	прокс., нагр.	MAV ЭМГ проксимального электрода (нагр.)
z_vl_prox_load_wl	прокс., нагр.	WL проксимального электрода (нагр.)
z_vl_prox_load_zcr	прокс., нагр.	ZCR проксимального электрода (нагр.)
z_vl_prox_load_mdf	прокс., нагр.	MDF проксимального электрода (нагр.)
z_vl_prox_load_mnf	прокс., нагр.	MNF проксимального электрода (нагр.)
z_vl_prox_load_p_low	прокс., нагр.	Доля мощности 20 – 50 Гц (прокс., нагр.)
z_vl_prox_load_p_mid	прокс., нагр.	Доля мощности 50 – 150 Гц (прокс., нагр.)
z_vl_prox_load_p_high	прокс., нагр.	Доля мощности 150 – 450 Гц (прокс., нагр.)
z_vl_prox_load_ratio_mid_high	прокс., нагр.	Отношение p_{mid} / p_{high} (прокс., нагр.)
z_vl_prox_load_e_d2	прокс., нагр.	Энергия d2 (прокс., нагр.)
z_vl_prox_load_e_d3	прокс., нагр.	Энергия d3 (прокс., нагр.)
z_vl_prox_load_e_d4	прокс., нагр.	Энергия d4 (прокс., нагр.)
z_vl_prox_load_e_d5	прокс., нагр.	Энергия d5 (прокс., нагр.)
z_vl_prox_load_wavelet_entropy	прокс., нагр.	Вейвлет-энтропия (прокс., нагр.)
z_vl_prox_load_ratio_low_high	прокс., нагр.	Отношение $(d4+d5)/(d2+d3)$ (прокс., нагр.)
z_vl_prox_rest_rms	прокс., восст.	RMS ЭМГ проксимального электрода (восст.)
z_vl_prox_rest_mav	прокс., восст.	MAV ЭМГ проксимального электрода (восст.)
z_vl_prox_rest_wl	прокс., восст.	WL проксимального электрода (восст.)
z_vl_prox_rest_zcr	прокс., восст.	ZCR проксимального электрода (восст.)
z_vl_prox_rest_mdf	прокс., восст.	MDF проксимального электрода (восст.)
z_vl_prox_rest_mnf	прокс., восст.	MNF проксимального электрода (восст.)
z_vl_prox_rest_p_low	прокс., восст.	Доля мощности 20 – 50 Гц (прокс., восст.)

Техническое обозначение	Поток	Физиологический смысл
z_vl_prox_rest_p_mid	прокс., восст.	Доля мощности 50 – 150 Гц (прокс., восст.)
z_vl_prox_rest_p_high	прокс., восст.	Доля мощности 150 – 450 Гц (прокс., восст.)
z_vl_prox_rest_ratio_mid_high	прокс., восст.	Отношение p_mid / p_high (прокс., восст.)
z_vl_prox_rest_e_d2	прокс., восст.	Энергия d2 (прокс., восст.)
z_vl_prox_rest_e_d3	прокс., восст.	Энергия d3 (прокс., восст.)
z_vl_prox_rest_e_d4	прокс., восст.	Энергия d4 (прокс., восст.)
z_vl_prox_rest_e_d5	прокс., восст.	Энергия d5 (прокс., восст.)
z_vl_prox_rest_wavelet_entropy	прокс., восст.	Вейвлет-энтропия (прокс., восст.)
z_vl_prox_rest_ratio_low_high	прокс., восст.	Отношение (d4+d5)/(d2+d3) (прокс., восст.)

Таблица А.2 – ЭМГ: вариабельность амплитуды цикл-к-циклу (4 признака)

Техническое обозначение	Физиологический смысл
z_vl_dist_load_rms_cv	CV амплитуды RMS по циклам – дист., нагр.
z_vl_dist_rest_rms_cv	CV амплитуды RMS по циклам – дист., восст.
z_vl_prox_load_rms_cv	CV амплитуды RMS по циклам – прокс., нагр.
z_vl_prox_rest_rms_cv	CV амплитуды RMS по циклам – прокс., восст.

Таблица А.3 – Кинематика педалирования (11 признаков)

Техническое обозначение	Физиологический смысл
z_cadence_mean_rpm	Средняя каденс в окне (об/мин), z-норм.
z_cadence_cv	Коэффициент вариации каденса
z_load_duration_ms	Средняя длительность фазы нагрузки (мс)
z_rest_duration_ms	Средняя длительность фазы восстановления (мс)
z_load_rest_ratio	Отношение длительностей нагр./восст.
z_load_duration_cv	CV длительностей фаз нагрузки
z_rest_duration_cv	CV длительностей фаз восстановления
z_load_trend_cv_ratio_30s	Отношение CV последней трети к первой трети нагр. за 30 с
z_rest_trend_cv_ratio_30s	Отношение CV последней трети к первой трети восст. за 30 с
z_load_sampen_30s	Sample Entropy длительностей нагр. фаз за 30 с
z_rest_sampen_30s	Sample Entropy длительностей восст. фаз за 30 с

Таблица А.4 – NIRS – оконные признаки (15 признаков, Train.Red)

Техническое обозначение	Физиологический смысл
trainred_smo2_mean	Среднее SmO ₂ в окне (%)

Техническое обозначение	Физиологический смысл
trained_smo2_drop	Снижение SmO ₂ от начала окна
trained_smo2_slope	Линейный тренд SmO ₂ в окне
trained_smo2_std	Стандартное отклонение SmO ₂
trained_dsmo2_dt	Производная SmO ₂ по времени
trained_hhb_mean	Среднее дезоксигемоглобина HHb
trained_hhb_slope	Линейный тренд HHb в окне
trained_hhb_std	Стандартное отклонение HHb
trained_dhhb_dt	Производная HHb по времени
trained_hbdiff_mean	Среднее индекса оксигенации HbDiff (= HbO ₂ – HHb)
trained_hbdiff_slope	Линейный тренд HbDiff
trained_hbdiff_std	Стандартное отклонение HbDiff
trained_thb_mean	Среднее общего гемоглобина THb
trained_thb_slope	Линейный тренд THb
trained_thb_std	Стандартное отклонение THb

Таблица A.5 – NIRS – кумулятивные признаки (3 признака)

Техническое обозначение	Физиологический смысл
smo2_from_running_max	Падение SmO ₂ от текущего максимума сессии
hhb_from_running_min	Подъём HHb от текущего минимума сессии
smo2_rel_drop_pct	Относительное снижение SmO ₂ от базального уровня (%)

Таблица A.6 – HRV – вариабельность сердечного ритма (7 признаков)

Техническое обозначение	Физиологический смысл
hrv_mean_rr_ms	Среднее RR-интервала (мс)
hrv_sdnns_ms	SDNN – стандартное отклонение RR (мс)
hrv_rmssd_ms	RMSSD (мс)
hrv_sd1_ms	SD1 по диаграмме Пуанкаре (мс)
hrv_sd2_ms	SD2 по диаграмме Пуанкаре (мс)
hrv_sd1_sd2_ratio	Отношение SD1/SD2
hrv_dfa_alpha1	DFA- α 1

Таблица A.7 – Взаимодействия (3 признака, только EMG+NIRS+HRV)

Техническое обозначение	Формула	Физиологический смысл
feat_smo2_x_rr	$SmO_2_mean \times mean_RR / 10\,000$	Совместный маркер оксигенации и ЧСС
feat_smo2_x_dfa	$SmO_2_mean \times DFA-\alpha 1$	Взаимодействие оксигенации и автономной регуляции
feat_rr_per_watt	$mean_RR / \text{мощность_Вт}$	ЧСС, нормированная на мощность нагрузки

Таблица A.8 – Абсолютные признаки, исключаемые в варианте poabs (6 признаков)

Техническое обозначение	Описание
trainred_smo2_mean	Абсолютный уровень SmO ₂
trainred_hhb_mean	Абсолютный уровень HHb
trainred_hbdiff_mean	Абсолютный уровень HbDiff
trainred_thb_mean	Абсолютный уровень THb
hrv_mean_rr_ms	Абсолютный уровень ЧСС (через среднее RR)
feat_smo2_x_rr	Взаимодействие абсолютных уровней SmO ₂ и ЧСС

Таблица A.9 – Базальные физиологические показатели

Техническое обозначение	Физиологический смысл
age	Возраст (лет)
sex	Пол
height	Рост (см)
weight	Масса тела (кг)
bmi	Индекс массы тела
body_fat_pct	Процент жировой массы
phase_angle	Угол фазы биоимпеданса (°)
hrv_hr_baseline_bpm	ЧСС на калибровочной ступени 30 Вт (уд/мин)
hrv_rmssd_baseline_ms	RMSSD на калибровочной ступени 30 Вт (мс)
emg_vl_dist_baseline_rms	ЭМГ-RMS дистального электрода на 30 Вт
emg_vl_prox_baseline_rms	ЭМГ-RMS проксимального электрода на 30 Вт
nirs_smo2_baseline_mean	Средняя SmO ₂ на калибровочной ступени 30 Вт (%)

Приложение Б

(справочное)

Оценка неопределённости точечных предсказаний

Б.1 Назначение приложения

В основной главе результатов точечные модели рассматриваются как центральный объект анализа: оценивается их типичная ошибка локализации порога, согласованность по семействам, поведение в наборе финальных кандидатных моделей. Отдельным вспомогательным сюжетом является оценка неопределённости этих точечных предсказаний – в какой полосе вокруг точечного прогноза может лежать истинное время до достижения порога.

Этот вопрос рассматривается в работе как методологическая проверка, а не как самостоятельный практический инструмент. Основные сведения вынесены в данное приложение, чтобы основной текст главы не подменял вывод о работоспособности точечных моделей вторичным сюжетом об ограниченности интервальной оценки на текущей выборке.

Б.2 Используемая процедура

Для оценки неопределённости применялся вариант конформного предсказания со схемой поочерёдного исключения одного испытуемого. Содержательно процедура устроена так:

1. Для каждого из 18 испытуемых строится модель, обученная на остальных 17 участниках (та же схема валидации, что и в основной главе).
2. На исключённом испытуемом фиксируется фактическая ошибка точечного прогноза по основной метрике локализации порога.
3. По набору таких ошибок, полученных по всем 18 участникам, рассчитывается верхняя граница допустимого отклонения, обеспечивающая заявленный уровень покрытия. Полная ширина

доверительного интервала определяется этой границей и считается отдельно для каждой модели.

Такая схема выбрана из соображений согласованности с основной схемой валидации в работе: оценка неопределённости использует тот же принцип поочерёдного исключения, что и оценка точечного качества, и потому не требует отдельной калибровочной выборки сверх 18 участников.

Б.3 Полученные количественные характеристики

При номинальном уровне покрытия 80 % (требование, чтобы интервал с вероятностью 0.80 содержал истинное время до порога):

- эмпирическое покрытие на текущей выборке составляет приблизительно 89 %, то есть превышает номинальный уровень;
- медианная полная ширина интервала составляет около 780 секунд, что соответствует примерно ± 6.5 минут вокруг точечного прогноза.

При более мягком номинальном уровне покрытия 70 % эмпирическое покрытие также превышает номинальное (около 78 % против 70 %), а медианная ширина уменьшается, но остаётся значительной – порядка 540 секунд. При более строгих уровнях покрытия (90 % и выше) при выборке из 18 калибровочных испытуемых процедура теоретически ограничена и фактически сводится к максимальной наблюдаемой ошибке; такие уровни в работе не репортируются.

Для сопоставления: типичная точечная ошибка лучших моделей по тем же данным составляет порядка 120 секунд для задачи LT1 и порядка 105 секунд для задачи LT2, то есть приблизительно две минуты.

Б.4 Интерпретация: точечная ошибка и ширина интервала измеряют разное

Главное методологическое замечание состоит в том, что число «780 секунд» не следует читать как ошибку модели. Точечная ошибка и ширина доверительного интервала отвечают на разные вопросы:

Таблица Б.1 – Сопоставление точечной ошибки и ширины доверительного интервала

Показатель	Что измеряет
Типичная точечная ошибка (~120 секунд)	Насколько в среднем модель промахивается мимо истинного времени до порога.
Ширина доверительного интервала (~780 секунд при 80 % покрытия)	Какая по ширине полоса вокруг точечного прогноза необходима, чтобы с заявленной вероятностью гарантированно покрывать истинное значение на текущей выборке.

Иначе говоря, « ± 6.5 минут» – это гарантированная верхняя оценка разброса при заявленном уровне покрытия, а не «модель ошибается на 6.5 минут». Сама модель в типичном случае ошибается на величину, существенно меньшую – порядка двух минут.

Б.5 Почему интервал так широк при N=18

Конформная процедура поочерёдного исключения испытуемых обеспечивает формальную гарантию покрытия только за счёт ориентации фактически на наихудший случай в калибровочной выборке. Содержательно это означает следующее. При 18 калибровочных наблюдениях для гарантированного покрытия 80 % процедура вынуждена взять квантиль уровня примерно 0.88 из распределения индивидуальных ошибок. На выборке такого размера это почти эквивалентно тому, чтобы ориентироваться на одного-двух испытуемых с самой большой индивидуальной ошибкой: эти участники автоматически растягивают ширину интервала для всей выборки.

Этот эффект имеет чисто статистическую природу и не связан с качеством самой точечной модели. С увеличением калибровочной выборки тот же номинальный уровень покрытия 80 % достигается за счёт квантиля более низкого порядка, и интервал сужается. Для получения практически

узких индивидуальных интервалов при сохранении заявленного уровня покрытия требуется выборка существенно большего размера, чем доступна в задачах с детальным мультимодальным физиологическим сбором, и это относится к условию калибровки неопределённости, а не к ограничению самой модели.

Б.6 Вывод

Точечные модели в данной работе остаются практически осмысленным инструментом онлайн-оценки приближения к LT1 и LT2: их типичная ошибка существенно меньше длительности ступени нагрузочного протокола. Интервальный же слой при текущем размере калибровочной выборки даёт заведомо консервативную оценку и в данной работе рассматривается исключительно как методологическая проверка наличия осмысленного способа количественно описать неопределённость, а не как готовый инструмент для прецизионных индивидуальных рекомендаций.

Развитие интервальной оценки до прикладного уровня предполагает увеличение калибровочной выборки и относится к задачам, выходящим за рамки данной работы; перенос точечных результатов на иные виды нагрузки и популяции обсуждается отдельно в разделе 3.9 основной части.